

Bruno Maia de Oliveira Duarte

***Framework* para Imputação de Dados Faltantes
em Séries Espaço-temporais de Sensores Físicos**

São Paulo, SP

2025

Bruno Maia de Oliveira Duarte


***Framework* para Imputação de Dados Faltantes em Séries
Espaço-temporais de Sensores Físicos**

Trabalho de conclusão de curso apresentado
ao Departamento de Engenharia de Computa-
ção e Sistemas Digitais da Escola Politécnica
da Universidade de São Paulo para obtenção
do Título de Engenheiro.

Universidade de São Paulo – USP

Escola Politécnica

Departamento de Engenharia de Computação e Sistemas Digitais (PCS)



Orientadora: Profa. Dra. Anna Helena Reali Costa

Coorientadores: Dr. Fábio José Muneratti Ortega
Dr. Marcel Rodrigues de Barros

São Paulo, SP

2025

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Catálogo-na-publicação

Duarte, Bruno

Framework para Imputação de Dados Faltantes em Séries Espaço
temporais de Sensores Físicos / B. Duarte -- São Paulo, 2025.

54 p.

Trabalho de Formatura - Escola Politécnica da Universidade de São
Paulo. Departamento de Engenharia de Computação e Sistemas Digitais.

1.Séries Espaço-Temporais 2.Aprendizado de Máquina 3.Aprendizado
Profundo 4.Imputação I.Universidade de São Paulo. Escola Politécnica.
Departamento de Engenharia de Computação e Sistemas Digitais II.t.

*Dedico este trabalho à minha mãe, Aline, e à
minha avó, Elma, que foram os meus pilares
fundamentais durante toda a minha formação.*

Agradecimentos

Os agradecimentos principais são direcionados ao meu Senhor e Salvador, Jesus Cristo, pelos dons que me permitiram concluir este trabalho, e cuja presença esteve em todos os momentos.

Agradeço à minha mãe, Aline, por me apoiar incondicionalmente nos caminhos que culminaram na realização deste projeto, por meio do seu amor, da sua orientação, bem como pelo suporte emocional e material durante toda a minha trajetória. Que esta seja mais uma de nossas vitórias!

Estendo esses agradecimentos à minha avó, Elma, pelo apoio e pelo aconselhamento em toda a minha trajetória, bem como agradeço à minha família. Agradeço à minha companheira, Maria Carla, pelo apoio incondicional aos meus projetos e pela companhia em todos os momentos desta jornada, auxiliando-me a me reerguer após cada queda e a continuar lutando. Também sou grato aos amigos que fiz ao longo do curso pelos bons momentos de aprendizado e divertimento.

Expresso meus agradecimentos à Escola Politécnica da Universidade de São Paulo, especialmente aos professores e funcionários do Departamento de Engenharia de Computação e Sistemas Digitais (PCS) pelas valiosas lições e aprendizados durante todo o curso. Também direciono os agradecimentos ao Center for Artificial Intelligence (C4AI - USP/IBM/FAPESP) pela infraestrutura utilizada neste projeto, bem como aos professores e pesquisadores do grupo OceanML pela parceria e pelos ensinamentos.

Destaco minha profunda gratidão ao Dr. Fábio Ortega, meu coorientador, a quem agradeço pelo valioso aprendizado e pelo acompanhamento bastante próximo da minha pesquisa, nunca me deixando desamparado, e que resultou neste trabalho. Além dele, agradeço ao Dr. Marcel de Barros, que também coorientou este projeto, e cujas orientações foram de grande valia. Direciono meus agradecimentos também ao Prof. Dr. Artur Jordão, que me incentivou na pesquisa tanto durante suas aulas bastante motivadoras, como pelo aconselhamento para meu desenvolvimento como pesquisador.

Por fim, dedico um agradecimento bastante especial à minha orientadora, Profa. Dra. Anna Helena Reali Costa, uma mestra e pesquisadora brilhante, com quem foi uma honra trabalhar e aprender ao longo do desenvolvimento deste projeto. Sua competência e visão de futuro foram determinantes para a execução deste trabalho, e a constante motivação e incentivo por ela emanados foram imprescindíveis para despertar em mim o interesse e o gosto pela pesquisa científica.

A todos aqui mencionados, meus mais sinceros agradecimentos.

*“O todo sem a parte não é todo,
A parte sem o todo não é parte,
Mas se a parte o faz todo, sendo parte,
Não se diga que é parte, sendo todo.”*
- Gregório de Matos

Resumo

Dados faltantes são um desafio recorrente em séries temporais multivariadas espaço-temporais, especialmente em aplicações de monitoramento ambiental baseadas em redes de sensores físicos. A perda de observações compromete análises, aumenta incertezas e pode afetar a eficácia de modelos de previsão utilizados na identificação e mitigação de fenômenos extremos. Este Trabalho de Conclusão de Curso propõe um *framework* interativo para visualização e comparação de resultados de imputação em séries espaço-temporais, integrando, em um único ambiente, experimentos previamente obtidos por métodos estatísticos e por técnicas de *deep learning*. O *framework* consolida resultados sobre dois conjuntos de dados: uma simulação oceânica do modelo *ROMS* na região do campo Gato do Mato, na qual se analisa a variável altura da superfície do mar (*SSH*), e o *dataset Beijing AQI-36*, composto por séries de qualidade do ar em 36 estações de Pequim. São considerados diferentes cenários de falhas: percentuais sintéticos no *ROMS* e o padrão real de ausências no *AQI-36*. As imputações são realizadas por um método estatístico baseado em *k*-vizinhos mais próximos (*KNN*) e pelo modelo *Spatiotemporal Point Inference Network* (*SPIN*), sendo avaliadas por métricas como *Mean Absolute Error* (*MAE*) e *Mean Squared Error* (*MSE*). A aplicação web permite selecionar o conjunto de dados, o método de imputação e o cenário de falhas, bem como inspecionar, para cada ponto da malha de interesse, as séries original, degradada e imputada com suas respectivas métricas. Os resultados evidenciam que, no cenário controlado da simulação *ROMS* para a variável *SSH*, o método *KNN* é suficiente para capturar as dependências espaço-temporais e mantém erros reduzidos mesmo em altas taxas de falha, enquanto o *SPIN* oferece um arcabouço mais geral para cenários com padrões de ausência mais complexos. O *framework* visual resultante se destaca como ferramenta de apoio à análise e interpretação de técnicas de imputação, contribuindo para estudos que visam a aumentar a confiabilidade de sistemas de monitoramento e subsidiar ações de mitigação de fenômenos ambientais extremos.

Palavras-chave: dados faltantes; imputação; séries espaço-temporais; *deep learning*; monitoramento ambiental.

Abstract

Missing data is a recurring challenge in multivariate spatiotemporal time series, particularly in environmental monitoring applications that rely on networks of physical sensors. Data gaps compromise analyses, increase uncertainty, and may hinder the performance of forecasting models used to detect and mitigate extreme events. This work proposes an interactive framework for visualizing and comparing imputation results in spatiotemporal series, integrating into a single environment experiments produced with statistical methods and deep learning techniques. The framework consolidates results from two datasets: an ocean simulation generated by the *ROMS* model over the Gato do Mato offshore field, where the sea surface height (*SSH*) variable is examined, and the Beijing AQI-36 dataset, consisting of air-quality time series from 36 monitoring stations. Different missing-data scenarios are considered, including synthetic missing rates in ROMS and the real missing pattern present in AQI-36. Imputations are performed using a statistical K -nearest neighbours (*KNN*) method and the Spatiotemporal Point Inference Network (*SPIN*), and evaluated using metrics such as Mean Absolute Error (MAE) and Mean Squared Error (MSE). The web application allows users to select the dataset, imputation method, and missing-data scenario, as well as inspect, at each grid point, the original, missing, and imputed series together with their metrics. Results show that in the controlled ROMS simulation for the SSH variable, the KNN method sufficiently captures spatiotemporal dependencies and achieves low errors even under high missing rates, while SPIN provides a more general modelling framework suitable for scenarios with complex missing patterns. The resulting visual framework is a valuable tool for analysing and interpreting imputation methods, contributing to research aimed at improving the reliability of environmental monitoring systems and supporting mitigation strategies for extreme events.

Keywords: missing data; imputation; spatiotemporal time series; deep learning; environmental monitoring.

Lista de ilustrações

Figura 1 – Número anual de publicações	17
Figura 2 – Método dos Vizinhos Mais Próximos	21
Figura 3 – Esquema de um <i>Multilayer Perceptron</i>	22
Figura 4 – Séries Temporais Univariadas e Multivariadas	26
Figura 5 – Grafo Série Espaço-temporal	27
Figura 6 – Processo de Imputação Séries Espaço-temporal	28
Figura 7 – Taxonomia de Métodos MTSI	30
Figura 8 – Mapa dos pontos ROMS no Gato do Mato	33
Figura 9 – Mapa das estações Beijing AQI-36	34
Figura 10 – Diagrama de sequência do <i>framework</i> de imputação em séries espaço-temporais.	41

Lista de tabelas

Tabela 1 – Resultados dos métodos de imputação em notação científica para diferentes percentuais de falha no dataset ROMS (variável SSH).	45
---	----

Lista de abreviaturas e siglas

AQI-36	<i>Beijing Air Quality 36 Stations Dataset</i>
C4AI	<i>Center for Artificial Intelligence</i>
GAN	<i>Generative Adversarial Network</i>
GNN	<i>Graph Neural Network</i>
KNN	<i>K-Nearest Neighbours</i>
MAE	<i>Mean Absolute Error</i>
MLP	<i>Multilayer Perceptron</i>
MSE	<i>Mean Squared Error</i>
MTS	<i>Multivariate Time Series</i>
MTSI	<i>Multivariate Time Series Imputation</i>
PM2.5	Concentração de partículas inaláveis com diâmetro aerodinâmico inferior a 2,5 μm
ROMS	<i>Regional Ocean Model System</i>
RSSF	Rede de Sensores sem Fio
SSH	<i>Sea Surface Height</i> (altura da superfície do mar)
STTS	<i>Spatio-temporal Time Series</i>
SPIN	<i>Spatiotemporal Point Inference Network</i>

Lista de símbolos

t	Índice temporal de uma série
i, j	Índices de nós ou sensores na malha espacial
m	Número de pontos espaciais (sensores) considerados
K	Número de vizinhos utilizados no método KNN
$\mathbf{Z}$	Matriz (ou tensor) de séries temporais multivariadas
$\mathcal{G} = (V, E)$	Grafo que representa a malha de sensores, com vértices V e arestas E
$\mathbb{R}$	Conjunto dos números reais
$\in$	Símbolo de pertinência a um conjunto

Sumário

1	INTRODUÇÃO	14
1.1	Motivação	14
1.2	Objetivos	15
1.3	Justificativa	16
1.4	Organização do Trabalho	17
2	ASPECTOS CONCEITUAIS	19
2.1	Fundamentos de Aprendizado de Máquina e de Redes Neurais Artificiais	19
2.1.1	Aprendizado Supervisionado	19
2.1.2	Aprendizado pelo Vizinho Mais Próximo	20
2.1.3	Redes Neurais: O <i>Multilayer Perceptron</i>	21
2.1.4	Redes Neurais de Grafo	23
2.1.5	Arquitetura <i>Transformer</i> e o Mecanismo de Atenção	24
2.2	Modelagem de Séries Temporais	25
2.2.1	Séries Temporais Multivariadas	25
2.2.2	Modelagem de Séries Temporais no Espaço-Tempo	26
2.2.3	Imputação de Dados Faltantes	27
2.3	Métodos de <i>Deep Learning</i> para Imputação de Dados em Séries Temporais Multivariadas	28
2.3.1	Taxonomia das Técnicas	28
2.3.2	O Método SPIN: <i>Spatiotemporal Point Inference Network</i>	30
3	MATERIAIS E MÉTODO DO TRABALHO	32
3.1	Fonte de Dados	32
3.1.1	Simulação ROMS no Gato do Mato	32
3.1.2	<i>Dataset</i> de Qualidade do Ar: Beijing AQI-36	33
3.2	Geração de Falhas	34
3.3	Avaliação dos Modelos	35
4	ESPECIFICAÇÃO DE REQUISITOS	37
4.1	Requisitos Funcionais	37
4.2	Requisitos Não Funcionais	38
5	DESENVOLVIMENTO DO TRABALHO	39
5.1	Tecnologias Utilizadas	39

5.1.1	<i>Backend</i> e Processamento de Dados	39
5.1.2	<i>Frontend</i> e Visualização	39
5.1.3	Ambiente de Desenvolvimento e Integração	40
5.2	Projeto e Implementação	40
5.2.1	Estrutura geral do sistema	40
5.2.1.1	<i>Frontend</i>	40
5.2.1.2	<i>Backend</i>	42
5.2.1.3	Módulo de dados e experimentos	42
5.2.2	Fluxo operacional do <i>framework</i>	43
5.2.3	Decisões de projeto	43
5.3	Testes e Avaliação	44
5.3.1	Visualização dos Resultados no <i>Framework</i>	44
5.3.2	Estudo de Caso: Comparação entre KNN e SPIN no ROMS	45
5.3.3	Discussão dos Resultados	45
6	CONSIDERAÇÕES FINAIS	47
6.1	Contribuições	48
6.2	Perspectivas de Continuidade	48
	 REFERÊNCIAS	 50

1 Introdução

Tarefas de previsão baseadas em dados de *Spatio-temporal Time Series* (STTS, do inglês, séries espaço-temporais) têm ampla aplicação em áreas como Meteorologia, Oceanografia, Engenharia de Tráfego, Engenharia Elétrica, entre outros (SHI et al., 2015; SHCHEPETKIN; MCWILLIAMS, 2005; YUAN; LI, 2021; CAVUS; ALLAHHAM, 2025). Sobretudo, o uso de redes de sensores sem fio (RSSF) para o monitoramento de variáveis físicas trouxe luz a problemas modelados por STTS, como ocorre no caso da captação de altura da superfície do mar (BARROS et al., 2024), ou para observar a qualidade do ar em metrópoles (ZHANG et al., 2017).

Com as mudanças climáticas provocando cada vez mais fenômenos extremos destrutivos (KOCHKOV et al., 2024), como fortes ressacas em regiões litorâneas (BARROS et al., 2023), bem como a poluição do ar em áreas metropolitanas (ZHANG et al., 2017), há o interesse no monitoramento de variáveis físicas distribuídas no espaço para posterior análise dos dados coletados, a fim de pautar políticas públicas, ou ações de mitigação dos efeitos negativos desses eventos.

Para que isso seja possível, é imprescindível buscar a manutenção da integridade dos dados coletados, a partir da mitigação do efeito das perdas de informação, que usualmente ocorrem quando se trata de sensores físicos. Nesse sentido, este Trabalho de Conclusão de Curso visa a desenvolver uma ferramenta visual de um processo chamado de “imputação de dados”, capaz de tornar séries espaço-temporais com dados faltantes em regulares, a partir de métodos estatísticos e de aprendizado profundo, bem como avaliar o desempenho deles nessas tarefas.

Além disso, deseja-se avaliar métodos de imputação selecionados, além de apresentar um novo *dataset* para futuras avaliações de métodos de imputação. Neste trabalho, far-se-á tanto uma abordagem científica de estudo de métodos de aprendizado de máquina para preenchimento de lacunas em séries temporais multivariadas (MTS, do inglês, *Multivariate Time Series*), quanto de engenharia na construção de uma ferramenta capaz de automatizar e visualizar testes personalizáveis desses métodos, seguindo uma abordagem de Engenharia de *Software*.

1.1 Motivação

Dados faltantes, falhas de transmissão e irregularidades são fenômenos onipresentes no monitoramento de dados oceânicos e meteorológicos, em particular quando esses sensores são instalados em ambientes remotos ou de difícil acesso (LI et al., 2023; CINI;

MARISCA; ALIPPI, 2022). Essas interrupções comprometem a continuidade das séries espaço-temporais e podem afetar diretamente a precisão de modelos utilizados para previsão de eventos extremos, tomada de decisão operacional e estudos ambientais. Nesses casos, torna-se necessária a reconstrução artificial dos valores ausentes, processo conhecido como imputação de dados.

Tradicionalmente, técnicas de imputação têm se apoiado em modelos físicos ou estatísticos. Embora modelos físicos apresentem alta precisão em contextos bem definidos, sua aplicabilidade tende a ser limitada a cenários específicos. Por outro lado, abordagens estatísticas oferecem maior generalidade, porém, frequentemente, entregam desempenho inferior em fenômenos dinâmicos e altamente variáveis.

Nesse contexto, métodos baseados em aprendizado de máquina surgem como alternativa promissora, devido à sua capacidade de extrair padrões complexos a partir dos dados e generalizar para diferentes condições (CINI; MARISCA; ALIPPI, 2022). Em especial, modelos de *deep learning* (LECUN; BENGIO; HINTON, 2015) vêm demonstrando resultados expressivos em tarefas de previsão e reconstrução de séries temporais, abrindo espaço para avanços também na imputação de dados ambientais.

Apesar desses progressos, a literatura ainda carece de avaliações sistemáticas que comparem, de forma padronizada, diferentes métodos de imputação sob múltiplas condições experimentais e em *datasets* ambientais de relevância prática. Adicionalmente, há uma oportunidade pouco explorada de integrar informações provenientes de retroanálises numéricas aos processos de imputação, potencialmente aumentando sua consistência física e precisão.

Diante desse cenário, a motivação deste trabalho advém tanto da necessidade de se compreender como diferentes métodos se comportam em condições de falha variadas quanto da ausência de ferramentas acessíveis que permitam visualizar e comparar, de maneira integrada, os resultados em séries espaço-temporais reais e simuladas.

1.2 Objetivos

O presente Trabalho de Conclusão de Curso tem como objetivo desenvolver um *framework* interativo destinado à comparação, análise e à visualização de resultados de imputação de dados faltantes em séries espaço-temporais, considerando diferentes taxas de falha previamente experimentadas. O *framework* integra resultados obtidos por métodos estatísticos e pelos baseados em aprendizado profundo consagrados aplicados aos *datasets* ROMS e Beijing AQI-36, de modo a oferecer ao usuário uma ferramenta unificada para avaliação quantitativa e visual da qualidade das imputações.

Para atingir o objetivo geral, estabelecem-se os seguintes objetivos específicos:

1. **Avaliar comparativamente métodos de imputação em séries espaço-temporais:** Investigar o desempenho de diferentes técnicas estatísticas e de aprendizado profundo aplicadas à imputação de dados faltantes, analisando resultados previamente gerados em distintas taxas de falha e permitindo identificar o comportamento relativo de cada método.
2. **Analisar o impacto das diferentes taxas de falha sobre o desempenho das técnicas:** Examinar como a variação da quantidade de dados faltantes influencia a acurácia e a robustez dos métodos avaliados, possibilitando compreender a sensibilidade das abordagens a diferentes níveis de ausência de dados.
3. **Apresentar simulações do *dataset* ROMS na região de interesse para exploração de petróleo no campo Gato do Mato:** Utilizar dados oceânicos simulados em malha regular provenientes do modelo ROMS para construir séries espaço-temporais completas, adequadas aos experimentos de imputação, permitindo análises comparativas entre métodos a partir de dados representativos de condições ambientais reais da área de exploração.
4. **Validar a qualidade das imputações utilizando séries completas conhecidas:** Comparar, de forma sistemática, os valores imputados com os dados originais (*ground truth*), utilizando métricas como *Mean Absolute Error* (MAE) e *Mean Squared Error* (MSE), além de visualizações diretas das séries reconstruídas, a fim de mensurar a qualidade das imputações realizadas.
5. **Desenvolver e disponibilizar um *framework* web para análise e visualização de imputações:** Projetar e implementar uma aplicação web que possibilite ao usuário selecionar datasets, escolher métodos de imputação, definir a taxa de falha a ser analisada, visualizar a distribuição espacial dos pontos, examinar séries completas, séries com falhas e séries imputadas, além de consultar métricas quantitativas associadas a cada experimento. A ferramenta consolida, em um único ambiente, os resultados experimentais, apoiando análises comparativas e estudos futuros na área.

1.3 Justificativa

A consolidação de técnicas de imputação em séries espaço-temporais requer não apenas o desenvolvimento de novos métodos, mas também a existência de ferramentas que possibilitem sua avaliação sistemática, transparente e comparável. O interesse crescente da comunidade científica na modelagem e previsão de fenômenos ambientais por meio de aprendizado de máquina, evidenciado pela evolução anual de publicações na área de séries temporais multivariadas irregulares apresentada na Figura 1, reforça a necessidade


de protocolos padronizados para análise e validação desses métodos (SEU; KANG; LEE, 2022; WANG et al., 2025; GUO et al., 2024).

Apesar desse aumento de interesse, a literatura ainda carece de instrumentos que permitam ao pesquisador comparar diferentes técnicas de imputação a partir de resultados experimentais consolidados, visualizar suas reconstruções espaço-temporais e interpretar métricas de erro em conjunto com aspectos estruturais das séries. Trabalhos que propõem novos modelos geralmente apresentam apenas seus próprios experimentos, conduzidos sob condições específicas, o que dificulta a comparação direta entre métodos estatísticos, modelos físicos e abordagens baseadas em *deep learning*.

Nesse contexto, justifica-se o desenvolvimento de um *framework* aberto que reúna, em um ambiente único, as principais etapas envolvidas na análise comparativa de imputação. Entre essas etapas incluem-se a seleção de *datasets*, a escolha do método, a inspeção visual das séries completas e imputadas e o acesso às métricas de desempenho correspondentes. Tal ferramenta atende a uma demanda metodológica da área, pois oferece aos pesquisadores um meio padronizado e interativo para examinar resultados de imputação provenientes de múltiplos experimentos previamente executados, aumentando a reprodutibilidade das análises e facilitando investigações futuras.

Ao disponibilizar visualizações espaço-temporais, métricas quantitativas consolidadas e mecanismos intuitivos de comparação, o sistema proposto contribui para a maturidade metodológica do campo, permitindo avaliar com maior rigor a eficácia das técnicas de imputação aplicadas a dados ambientais reais e simulados.

Figura 1 – Número anual de publicações sobre MTSI de 2018 a 2024.



Fonte: (GUO et al., 2024)

1.4 Organização do Trabalho

Este trabalho está estruturado em seis capítulos. No Capítulo 2, são apresentados os fundamentos teóricos necessários para o desenvolvimento deste projeto, incluindo conceitos de aprendizado de máquina, modelagem de séries espaço-temporais e uma análise dos

principais métodos de imputação, bem como a descrição dos algoritmos selecionados para avaliação.

No Capítulo 3, são detalhados os materiais e métodos empregados, abrangendo a caracterização do *dataset* ROMS e do conjunto de dados Beijing AQI-36, a técnica utilizada para mascaramento das séries, o delineamento dos experimentos conduzidos para diferentes taxas de falha e as métricas adotadas para avaliação dos resultados de imputação.

O Capítulo 4 apresenta a análise de requisitos necessária ao desenvolvimento do *framework* visual proposto, descrevendo os requisitos funcionais e não funcionais que orientaram sua concepção.

No Capítulo 5, é descrito o processo de desenvolvimento do sistema, incluindo as tecnologias utilizadas, a implementação da aplicação *web*, os testes realizados e um estudo de caso que ilustra a utilização do *framework* para análise dos experimentos de imputação.

Por fim, o Capítulo 6 apresenta as considerações finais, discutindo as contribuições do trabalho, suas limitações e possíveis direções para pesquisas futuras.

2 Aspectos Conceituais

Este capítulo apresenta os fundamentos teóricos necessários para se compreender os métodos de modelagem e imputação empregados neste trabalho. Discutem-se conceitos essenciais de aprendizado de máquina, estruturas de dados temporais e espaço-temporais, bem como técnicas clássicas e modernas de imputação. O objetivo é construir uma base sólida para a metodologia e os experimentos apresentados nos capítulos seguintes.

2.1 Fundamentos de Aprendizado de Máquina e de Redes Neurais Artificiais

Esta seção introduz os princípios matemáticos do aprendizado supervisionado e a organização típica dos conjuntos de treinamento, validação e teste. Em seguida, apresenta métodos fundamentais como o k -nearest neighbour e arquiteturas de aprendizado profundo, incluindo *multilayer perceptron*, mecanismos de atenção, modelos do tipo *Transformer* e redes neurais de grafos, preparando conceitos utilizados posteriormente.

2.1.1 Aprendizado Supervisionado

O aprendizado supervisionado pode ser formalmente definido como o processo de estimar uma função que relaciona um conjunto de variáveis independentes a uma variável dependente, a partir de exemplos rotulados. Seja

$$X = \{x_1, x_2, \dots, x_N\}$$

o conjunto de vetores de entrada, em que cada x_i é composto por atributos que descrevem uma observação, e seja

$$Y = \{y_1, y_2, \dots, y_N\}$$

o conjunto correspondente de valores de saída. A base de dados consiste nos pares (x_i, y_i) , nos quais $x_i \in X$ representa as variáveis independentes e $y_i \in Y$ representa a variável dependente que se deseja prever.

Assume-se que os pares (x_i, y_i) são amostras independentes e identicamente distribuídas. O objetivo do aprendizado supervisionado consiste em estimar uma função $f : X \rightarrow Y$, parametrizada por um conjunto de hiperparâmetros θ , de modo que a estimativa $\hat{y} = f(x; \theta)$ reproduza adequadamente os valores reais para novas observações. Essa função deve capturar a relação subjacente entre as variáveis de entrada e de saída, garantindo boa capacidade de generalização (JAMES et al., 2023; BISHOP, 2006; GOODFELLOW; BENGIO; COURVILLE, 2016).

O processo de aprendizado envolve três etapas principais. Na fase de treinamento, ajustam-se os parâmetros internos do modelo utilizando uma parcela dos pares (x_i, y_i) . Em seguida, utiliza-se um conjunto de validação para selecionar os hiperparâmetros θ , avaliando o comportamento da função aprendida e prevenindo *overfitting*. Por fim, o desempenho final do modelo é avaliado em um conjunto de teste, composto por observações não utilizadas nas fases anteriores, permitindo estimar sua capacidade real de generalização. Assim, o aprendizado supervisionado consiste na estimação de uma função $f(x; \theta)$ que represente a dependência entre X e Y e produza previsões confiáveis para novas amostras.

2.1.2 Aprendizado pelo Vizinho Mais Próximo

O método do vizinho mais próximo é um dos algoritmos mais simples e intuitivos no contexto do aprendizado supervisionado. Sua ideia central consiste em prever o valor de saída para uma nova observação com base em exemplos anteriores localizados próximos no espaço das variáveis de entrada. Na literatura, esse algoritmo é caracterizado como um método não paramétrico que utiliza a estrutura dos próprios dados, sem impor uma forma funcional específica para a relação entre entrada e saída (JAMES et al., 2023; BISHOP, 2006).

Considere um conjunto de entradas $X = \{x_1, x_2, \dots, x_N\}$ e seus valores de saída correspondentes $Y = \{y_1, y_2, \dots, y_N\}$. Dada uma nova observação x , o algoritmo identifica os K elementos de X mais próximos de x segundo uma métrica de distância, usualmente a distância euclidiana. Denotando por $\mathcal{N}_K(x)$ o conjunto desses vizinhos, a previsão em problemas de regressão é dada por


$$f(x) = \frac{1}{K} \sum_{x_i \in \mathcal{N}_K(x)} y_i. \quad (2.1)$$

Em tarefas de classificação, o valor previsto para x é determinado pela classe mais frequente entre seus vizinhos. O método se adapta naturalmente à distribuição local das observações, tornando sua previsão sensível à estrutura geométrica dos dados. A Figura 2 representa como o KNN pode preencher dados faltantes.

O vizinho mais próximo também pode ser empregado como técnica de imputação de valores faltantes. Quando uma observação possui um valor ausente, identifica-se o conjunto de vizinhos completos mais semelhantes segundo as variáveis disponíveis, e o valor a ser imputado é estimado pela média dos valores presentes nos vizinhos selecionados. Essa abordagem se baseia na suposição de que observações próximas compartilham padrões similares, permitindo reconstruir valores ausentes utilizando a estrutura local dos dados.

Assim, o método do vizinho mais próximo constitui uma solução simples e eficaz tanto para previsão quanto para imputação, especialmente em contextos nos quais a

Figura 2 – Método dos Vizinhos Mais Próximos



Fonte: o próprio autor.

relação entre variáveis é complexa ou não linear, dispensando a definição de um modelo paramétrico explícito.

2.1.3 Redes Neurais: O *Multilayer Perceptron*

As redes neurais artificiais constituem um dos componentes centrais do aprendizado profundo, desempenhando papel fundamental na modelagem de relações complexas em espaços de alta dimensão (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016; ROBERTS; YAIDA; HANIN, 2022). Muitos autores definem uma rede neural como uma função parametrizada composta pela aplicação sucessiva de transformações lineares e funções de ativação não lineares, o que permite a aproximação de funções sem forma analítica explícita (GOODFELLOW; BENGIO; COURVILLE, 2016; ROBERTS; YAIDA; HANIN, 2022).

Formalmente, uma rede neural implementa a seguinte função:

$$f(x; \theta) \quad (2.2)$$

em que x representa o vetor de entrada e θ reúne os parâmetros do modelo. O objetivo do aprendizado é encontrar um conjunto θ^* que torne a rede capaz de aproximar a função que governa os dados:

$$f(x; \theta^*) \approx f(x) \quad (2.3)$$

No contexto das redes neurais multicamadas, conhecidas como *Multilayer Perceptron* (MLP), as transformações são organizadas em camadas sucessivas. Para cada camada l , aplica-se primeiramente uma transformação linear:

$$y^{(l)} = w^{(l)} x^{(l-1)} + b^{(l)} \quad (2.4)$$

seguida pela aplicação de uma função de ativação não linear:

$$x^{(l)} = \sigma(y^{(l)}) \quad (2.5)$$

O fluxo dessas operações está ilustrado na Figura 3, que apresenta a propagação das entradas através das camadas, evidenciando a composição hierárquica característica do MLP.

As funções de ativação exercem papel central no aprendizado, pois introduzem não linearidades necessárias para capturar estruturas complexas nos dados. Entre as funções mais utilizadas encontram-se ReLU, $\tanh$ e GELU, amplamente discutidas no contexto do aprendizado profundo (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016).


O processo de aprendizado é formulado como a minimização de uma função de perda $L(\theta)$, realizada tipicamente por meio do método do gradiente descendente:

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta) \quad (2.6)$$

onde η é a taxa de aprendizado. O cálculo eficiente desses gradientes é realizado pelo algoritmo de retropropagação, que utiliza a regra da cadeia para transmitir o erro da camada de saída às camadas anteriores (GOODFELLOW; BENGIO; COURVILLE, 2016).

As redes neurais apresentam propriedades de aproximação universal, composição hierárquica e alta adaptabilidade, características que justificam sua ampla utilização em tarefas de regressão, classificação e processos gerativos (GOODFELLOW; BENGIO; COURVILLE, 2016; ROBERTS; YAJDA; HANIN, 2022).

Figura 3 – Esquema de um *Multilayer Perceptron*



Fonte: o próprio autor.

2.1.4 Redes Neurais de Grafo

As *Graph Neural Networks* (GNNs) emergem como uma classe de modelos projetados para processar dados estruturados em forma de grafos, explorando explicitamente as relações entre entidades e seus vizinhos imediatos. De acordo com formulações consolidadas na literatura (SCARSELLI et al., 2009), esses modelos estendem a capacidade das redes neurais tradicionais ao incorporar informações estruturais provenientes das conexões entre nós, permitindo a modelagem de dependências espaciais complexas.

Uma GNN opera sobre um grafo $G = (V, E)$, no qual cada nó $i \in V$ possui uma representação vetorial inicial $\mathbf{x}_i^{(0)}$ e pode, opcionalmente, existir um vetor de atributos para cada aresta $\mathbf{e}_{ij}$ associada ao par de nós $(i, j) \in E$. O objetivo da rede é atualizar iterativamente os estados dos nós ao longo de L camadas, de modo que a representação final encode as relações topológicas e semânticas presentes no grafo.

O princípio fundamental que rege as GNNs é o mecanismo de *message passing*. Nele, cada nó coleta informações de seus vizinhos por meio de funções parametrizadas de mensagem e atualização. Esse processo pode ser dividido em duas etapas: (i) agregação das mensagens recebidas dos vizinhos e (ii) atualização do estado do nó com base nas mensagens agregadas.

A etapa de agregação é expressa por:

$$\mathbf{m}_i^{(\ell)} = \bigoplus_{j \in \mathcal{N}(i)} \phi^{(\ell)} \left(\mathbf{x}_i^{(\ell-1)}, \mathbf{x}_j^{(\ell-1)}, \mathbf{e}_{ij} \right), \quad (2.7)$$

em que $\phi^{(\ell)}$ é a função de mensagem da camada ℓ , $\mathcal{N}(i)$ é o conjunto de vizinhos de i , $\mathbf{e}_{ij}$ representa atributos opcionais de aresta e $\bigoplus$ denota uma função de agregação invariante à ordem (como soma, média ou máximo).

A mensagem agregada é então incorporada ao estado do nó por meio da função de atualização:

$$\mathbf{x}_i^{(\ell)} = \psi^{(\ell)} \left(\mathbf{x}_i^{(\ell-1)}, \mathbf{m}_i^{(\ell)} \right), \quad (2.8)$$

em que $\psi^{(\ell)}$ define como a nova representação do nó é construída a partir da anterior e das mensagens recebidas.

Combinando as Equações (2.7) e (2.8), a dinâmica completa do *message passing* ao longo de L camadas é descrita por:

$$\mathbf{x}_i^{(\ell)} = \psi^{(\ell)} \left(\mathbf{x}_i^{(\ell-1)}, \bigoplus_{j \in \mathcal{N}(i)} \phi^{(\ell)} \left(\mathbf{x}_i^{(\ell-1)}, \mathbf{x}_j^{(\ell-1)}, \mathbf{e}_{ij} \right) \right), \quad \ell = 1, \dots, L. \quad (2.9)$$

Essa formulação evidencia que a profundidade da rede determina o alcance da vizinhança considerada por cada nó, permitindo que padrões estruturais de múltiplas ordens sejam incorporados às representações internas. Além disso, diferentes escolhas para $\phi^{(\ell)}$, $\psi^{(\ell)}$ e $\oplus$ resultam em arquiteturas amplamente conhecidas, como *Graph Attention Networks* e variantes baseadas em difusão ou propagação residual.

Ao possibilitar a integração de informações topológicas e atributos de séries espaço-temporais distribuídas em redes de sensores, as GNNs se tornaram ferramentas essenciais para tarefas de previsão, detecção de anomalias e imputação de dados, especialmente em domínios como meteorologia, oceanografia, transporte e sistemas energéticos, onde a estrutura relacional desempenha papel fundamental.

2.1.5 Arquitetura *Transformer* e o Mecanismo de Atenção

A arquitetura *Transformer* tornou-se uma das estruturas centrais do aprendizado profundo moderno, especialmente em tarefas que envolvem dados sequenciais. Muitos autores destacam que sua relevância decorre da substituição de arquiteturas recorrentes e convolucionais por um mecanismo de atenção capaz de modelar dependências de longo alcance com alta eficiência computacional (VASWANI et al., 2017). Esse mecanismo permite que o modelo identifique, em cada etapa do processamento, quais partes da sequência são mais informativas para a construção de uma representação contextual.

O *Transformer* organiza-se em blocos compostos por camadas de *self-attention* e camadas totalmente conectadas (*feedforward layers*), intercaladas por normalização e conexões residuais. Essa estrutura possibilita que as representações sejam processadas de forma paralela, evitando as limitações das arquiteturas recorrentes. A *self-attention* atua relacionando cada elemento da sequência a todos os demais.

O mecanismo de atenção utiliza três matrizes aprendidas: *queries* Q , *keys* K e *values* V . A importância relativa entre os elementos da sequência é medida pelo produto interno entre *queries* e *keys*, normalizado pela dimensão latente:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (2.10)$$

Esse mecanismo é ampliado pela *multi-head attention*, em que múltiplas projeções independentes são processadas simultaneamente:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(h_1, h_2, \dots, h_H)W^O. \quad (2.11)$$

Como o *Transformer* opera de maneira paralela, ele necessita de informações adicionais sobre a ordem dos elementos. Para isso, utiliza-se o *positional encoding*, somado às entradas, garantindo que o modelo represente a estrutura sequencial.

A combinação entre *self-attention*, paralelismo, *positional encodings* e camadas *feedforward* faz do *Transformer* uma arquitetura versátil, adequada a tarefas de previsão, classificação, imputação e processos gerativos, especialmente na presença de dependências espaço-temporais complexas (JIN et al., 2024; YANG et al., 2024).

2.2 Modelagem de Séries Temporais

Nesta seção, são definidas formalmente séries temporais univariadas e multivariadas, explorando sua estrutura matricial e as dependências entre variáveis e instantes de tempo. Em seguida, apresenta-se a extensão desses conceitos para séries espaço-temporais, destacando como relações de localidade podem ser modeladas por grafos e incorporadas às análises.

2.2.1 Séries Temporais Multivariadas


Uma série temporal univariada pode ser entendida como uma sequência de observações de uma única variável ao longo do tempo, representada como $\{X_t\}_{t=1}^L$, na qual $X_t \in \mathbb{R}$ denota a observação no instante t e L é o número total de registros. Esse tipo de série apresenta dependência temporal entre observações consecutivas, característica amplamente discutida na literatura (MORETTIN; TOLOI, 2022).

A extensão natural desse conceito leva à série temporal multivariada, em que múltiplas variáveis são observadas simultaneamente ao longo do tempo. Nesse caso, a série é descrita como $\mathcal{M} = \{\mathbf{Z}_t\}_{t=1}^L$, sendo $\mathbf{Z}_t = [Z_{1,t}, Z_{2,t}, \dots, Z_{K,t}]^\top \in \mathbb{R}^K$ o vetor de valores observados no instante t , com K representando o número de variáveis monitoradas. A organização matricial dos dados pode ser expressa por $\tilde{\mathbf{Z}} \in \mathbb{R}^{L \times K}$, onde cada linha corresponde ao tempo e cada coluna a uma das variáveis analisadas. Essa formulação é amplamente utilizada em métodos clássicos e contemporâneos para modelagem multivariada (WEI, 2019; BARROS, 2024).

O vetor de tempos associado pode ser escrito como $\mathbf{T} = [t_1, t_2, \dots, t_L]$, embora seja comum adotar a suposição de amostragem regular e alinhada entre todas as variáveis, o que permite a simplificação para $\mathbf{T} = [1, 2, \dots, L]$. Sob essa hipótese, irregularidades no conjunto de dados aparecem como lacunas na matriz $\tilde{\mathbf{Z}}$ e são usualmente tratadas por técnicas de imputação ou mascaramento.

Séries temporais multivariadas exibem simultaneamente dependência temporal e dependência cruzada entre variáveis.

Figura 4 – Séries Temporais Univariadas e Multivariadas



Fonte: o próprio autor.

2.2.2 Modelagem de Séries Temporais no Espaço-Tempo

Uma série temporal espaço-temporal (STTS) pode ser vista como um caso particular da série temporal multivariada, no qual cada componente do vetor de observações corresponde a uma localização no espaço. Dessa forma, valores coletados simultaneamente em diferentes posições geográficas formam um vetor no instante t , preservando a estrutura multivariada discutida anteriormente. Essa interpretação é amplamente utilizada em análises espaço-temporais (WEI, 2019; LOPES; DELBEM; SOUSA, 2021).

Seja um conjunto de m locais monitorados. Para cada instante t , é possível organizar as observações espaciais no seguinte vetor:


$$\begin{bmatrix} Z_{1,t} \\ Z_{2,t} \\ \vdots \\ Z_{m,t} \end{bmatrix} = \begin{bmatrix} \text{Série temporal para o espaço 1} \\ \text{Série temporal para o espaço 2} \\ \vdots \\ \text{Série temporal para o espaço m} \end{bmatrix}.$$

Assim, a estrutura espaço-temporal completa pode ser representada pela matriz $\tilde{\mathbf{Z}} \in \mathbb{R}^{L \times m}$, cujas linhas correspondem aos instantes de tempo e cujas colunas representam as localizações no espaço. Esse arranjo captura simultaneamente duas dimensões de variação: a evolução temporal de cada local e as diferenças espaciais entre múltiplas regiões observadas.

Além da representação matricial, uma STTS pode ser descrita por um grafo espaço-temporal, no qual cada localização espacial é modelada como um nó e suas relações geográficas ou funcionais são representadas por arestas. Em cada instante t , obtém-se um grafo espacial cujos nós carregam os valores $Z_{i,t}$; ao longo do tempo, esses grafos formam uma sequência conectada por arestas temporais, como ilustrado na Figura 5. Essa construção explicita tanto a dependência espacial quanto a dependência temporal, permitindo modelagens que exploram vizinhança geográfica, propagação de fenômenos e

dinâmicas locais.

Figura 5 – Grafo Série Espaço-temporal



Fonte: o próprio autor

2.2.3 Imputação de Dados Faltantes

A ocorrência de valores faltantes é um desafio recorrente na análise de séries temporais, incluindo aquelas estruturadas no espaço e no tempo. Antes da aplicação de técnicas estatísticas mais elaboradas, modelos baseados em aprendizado profundo ou métodos gerativos, é comum recorrer a estratégias clássicas de imputação, frequentemente denominadas métodos *naïve*. Essas abordagens assumem comportamentos simples nos dados e, apesar de suas limitações, são amplamente utilizadas como linha de base experimental e como mecanismos preliminares de pré-processamento.

Entre os procedimentos mais empregados destacam-se:


- **Imputação pela média.** Valores ausentes são substituídos pela média das observações disponíveis de uma variável. A técnica é simples, porém reduz a variabilidade da série e tende a distorcer sua distribuição original, já que não incorre em dependências temporais ou espaciais.
- **Interpolação linear ou polinomial.** A reconstrução dos valores faltantes é realizada conectando observações adjacentes por funções determinísticas, como segmentos lineares ou polinômios de baixa ordem. Assume-se que o comportamento entre pontos vizinhos seja suficientemente regular para permitir tal estimativa, o que pode não ocorrer em séries complexas.

- **Imputação por K -Vizinhos Mais Próximos (KNN).** A estimativa é obtida a partir das observações mais próximas segundo alguma métrica de distância. O valor imputado costuma ser a média dos vizinhos selecionados. Embora possa capturar padrões mais ricos que a média simples, a técnica demanda maior custo computacional e depende fortemente da escolha da métrica.

Apesar de suas limitações, esses métodos desempenham papel importante na comparação com abordagens mais avançadas e na caracterização dos efeitos da complexidade do método sobre a tarefa de imputação.

A Figura 6 apresenta um esquema geral do processo de imputação em séries espaço-temporais, destacando o fluxo entre o conjunto de dados original com falhas e a série reconstruída pelo modelo.

Figura 6 – Processo de Imputação Séries Espaço-temporal



Fonte: o próprio autor.

2.3 Métodos de *Deep Learning* para Imputação de Dados em Séries Temporais Multivariadas

Aqui são apresentadas categorias modernas de modelos de imputação baseados em aprendizado profundo, organizadas segundo suas estratégias de previsão ou geração. São discutidas arquiteturas amplamente utilizadas, destacando seus mecanismos de captação de dependências temporais e espaço-temporais, bem como o papel dessas metodologias em cenários com padrões complexos de falhas.

2.3.1 Taxonomia das Técnicas

Pesquisas recentes organizam o campo da imputação de séries temporais multivariadas sob uma taxonomia unificada que separa modelos segundo a natureza do processo de reconstrução, destacando abordagens preditivas e gerativas (WANG et al., 2025; YANG et al., 2024). Essas classificações evidenciam como avanços recentes em *deep learning* têm ampliado a capacidade de capturar dependências complexas no tempo e no espaço,

permitindo a construção de modelos mais robustos para lidar com padrões heterogêneos de falhas em dados reais.

Modelos preditivos operam aprendendo diretamente uma função de mapeamento que estima valores ausentes a partir das observações disponíveis. Dentro dessa categoria, arquiteturas recorrentes, convolucionais e baseadas em grafos constituem blocos fundamentais. O modelo *BRITS* é um exemplo clássico dessa linha, empregando redes recorrentes bidirecionais para tratar valores faltantes de maneira explícita no processo de atualização dos estados temporais (CAO et al., 2018). Outro representante importante é o *TimesNet* (WU et al., 2023), que utiliza convoluções especializadas para extrair padrões multi-escala e capturar dependências periódicas e não estacionárias em séries complexas. Ainda no grupo preditivo, modelos baseados em grafos têm desempenhado papel central na imputação espaço-temporal pela capacidade de incorporar relações estruturais entre sensores, como exemplificado pelo *GRIN* (CINI; MARISCA; ALIPPI, 2022).

Modelos baseados em mecanismos de atenção constituem outro ramo relevante, aproveitando a habilidade de ponderar seletivamente dependências longínquas e correlacionadas no tempo. Dentro dessa linha destaca-se o *SAITS* (DU; CÔTÉ; LIU, 2023), que emprega blocos de auto-atenção mascarada para reconstruir valores ausentes de modo eficiente e interpretável.


A classe de métodos gerativos expande essa taxonomia ao modelar explicitamente distribuições de probabilidade subjacentes. O modelo *CSDI* (TASHIRO et al., 2021) exemplifica essa abordagem ao aplicar modelos de difusão condicionada para capturar incertezas de imputação e reconstruir séries coerentes com o comportamento temporal e espacial observado. Outra família relevante envolve arquiteturas variacionais e adversariais, caso dos modelos baseados em VAE ou GAN, que exploram representações latentes para amostrar reconstruções plausíveis.

Entre os modelos contemporâneos, destaca-se o *PriSTI* (LIU et al., 2023), que integra mecanismos condicionados de difusão com operadores espaço-temporais para lidar com padrões de ausência severos e relações geográficas explícitas. A utilização de atenção espacial e temporal combinada com priorização de contexto global permite ao modelo reconstruir sequências mesmo sob taxas elevadas de falhas.

Por fim, métodos híbridos que unem atenção e redes neurais de grafos têm representado um avanço importante no estado da arte. Dentro dessa classe, o modelo *SPIN* (MARISCA; CINI; ALIPPI, 2022) desponta como uma das abordagens mais completas, ao incorporar simultaneamente dependências temporais de longo alcance, relações estruturais entre sensores e mecanismos de agregação espacial. Essa combinação permite capturar variações locais e globais em séries espaço-temporais, resultando em um desempenho superior diante de múltiplos padrões de falhas e diferentes regimes de variabilidade. Assim, o *SPIN* constitui atualmente uma das arquiteturas de referência para imputação em

cenários espaço-temporais multivariados.

Figura 7 – Taxonomia de Métodos MTSI



Fonte: o próprio autor.

2.3.2 O Método SPIN: *Spatiotemporal Point Inference Network*

O método *SPIN* foi proposto como uma arquitetura projetada para imputação de séries espaço-temporais em cenários onde os sensores estão distribuídos no espaço e apresentam padrões de falhas complexos. A proposta parte da observação de que métodos convencionais de imputação tendem a tratar o componente espacial de forma limitada ou assumem estrutura regular entre sensores, enquanto séries reais exibem conectividade irregular e relações heterogêneas. Assim, o *SPIN* modela explicitamente dependências locais e globais tanto no espaço quanto no tempo, o que permite estimar valores ausentes em pontos específicos a partir de uma representação conjunta dessas dinâmicas (MARISCA; CINI; ALIPPI, 2022).

O modelo organiza o problema como uma tarefa de inferência ponto a ponto, em que cada observação ausente é tratada como uma consulta que deve ser respondida por meio de um mecanismo de agregação que considera vizinhos espaciais, vizinhos temporais e a interação entre ambos. Para isso, o *SPIN* utiliza dois componentes principais: um módulo de extração temporal e um módulo de agregação espacial. O primeiro emprega operadores baseados em *self-attention* para capturar dependências temporais de longo alcance, permitindo que cada ponto no tempo acesse contexto global ao longo da série. Já

o módulo espacial se apoia na estrutura de vizinhança da malha de sensores, aplicando operadores de passagem de mensagens para combinar informações de sensores próximos de modo adaptativo.

Esses dois caminhos são combinados por meio de um mecanismo de fusão que gera uma representação espaço-temporal unificada. Dado um ponto ausente, o modelo consulta essa representação utilizando *embeddings* que descrevem sua localização e seu instante temporal. A estimativa final é produzida por uma cabeça de regressão que opera sobre o vetor consultado. Esse desenho permite que cada ponto seja inferido de forma independente, sem a necessidade de reconstruir a série inteira, o que torna o método eficiente e flexível mesmo sob padrões irregulares de falhas.

Além disso, o *SPIN* incorpora máscaras explícitas de presença e ausência durante o processo de atenção, o que evita que o modelo seja enviesado por imputações anteriores. Esse mecanismo de mascaramento garante que apenas valores observados sejam utilizados como fonte de informação, preservando a consistência estatística da reconstrução.

O conjunto dessas decisões arquiteturais torna o *SPIN* uma abordagem potente para imputação em séries espaço-temporais. A capacidade de combinar operadores de atenção com mecanismos inspirados em *graph neural networks* permite capturar interações longínquas no tempo e proximidades estruturais no espaço, fornecendo reconstruções robustas em cenários com alta frequência de falhas, sensores desconectados ou variabilidade intensa. Essas características explicam o desempenho superior reportado em experimentos recentes com dados ambientais, mobilidade urbana e redes de sensores geográficos.

3 Materiais e Método do Trabalho

No presente capítulo, são descritos os materiais e métodos empregados no desenvolvimento deste trabalho. Inicialmente, apresentam-se os *datasets* utilizados, incluindo a simulação oceânica ROMS aplicada à região do Gato do Mato e o *dataset* ambiental Beijing AQI-36. Em seguida, detalha-se o processo de modelagem de falhas aplicado às séries espaço-temporais, bem como os procedimentos adotados para construção dos cenários de imputação. Por fim, são expostos os critérios e métricas utilizados para avaliação dos métodos, estabelecendo o protocolo experimental que orienta as análises discutidas nos capítulos posteriores.

3.1 Fonte de Dados

Nesta seção, são introduzidos os *datasets* de estudos, o ROMS e o Beijing AQI-36.

3.1.1 Simulação ROMS no Gato do Mato

Neste trabalho, utiliza-se um *dataset* gerado a partir de uma simulação numérica com o *Regional Ocean Modeling System* (ROMS), modelo amplamente empregado para representar a dinâmica oceânica em diferentes escalas. A formulação numérica do ROMS é detalhada na literatura especializada (SHCHEPETKIN; MCWILLIAMS, 2005), sendo aqui utilizada apenas como fonte estruturada de dados espaço-temporais para experimentação em imputação.


O domínio considerado corresponde à região do campo Gato do Mato, na Baía de Santos, onde pontos fixos foram distribuídos em um *grid* regular, atuando como *boias virtuais*. Em cada ponto, extrai-se uma série temporal contínua da altura da superfície do mar (*sea surface height*, SSH). Essa variável é especialmente adequada para experimentos de imputação, pois apresenta variabilidade temporal suave, dependência espacial bem definida e correlações estruturadas entre regiões adjacentes.

Assim, o conjunto de dados resultante consiste em múltiplas séries temporais sincronizadas em diferentes localizações, caracterizando uma série espaço-temporal (STTS). Essa estrutura permite avaliar métodos de imputação que exploram dependências tanto no tempo quanto no espaço, incluindo modelos que utilizam grafos, mecanismos de atenção ou arquiteturas que consideram vizinhanças espaciais.

O objetivo, portanto, não é analisar processos físicos associados à circulação oceânica, mas utilizar o ROMS como fonte controlada e completa de dados para experimentos

comparáveis entre técnicas de imputação, possibilitando mascaramento artificial, reconstrução supervisionada e validação quantitativa dos resultados.

Figura 8 – Mapa dos pontos ROMS no Gato do Mato



Fonte: o próprio autor.

3.1.2 Dataset de Qualidade do Ar: Beijing AQI-36


O segundo conjunto de dados utilizado neste trabalho é o *Beijing Air Quality 36 Stations Dataset* (AQI-36), composto por séries temporais multivariadas registradas por 36 estações de monitoramento distribuídas pela cidade de Pequim. O *dataset* inclui medições de concentração de poluentes, como $PM_{2.5}$, definido como a concentração de partículas inaláveis com diâmetro aerodinâmico inferior a 2,5 micrômetros, além de variáveis meteorológicas relevantes para análise ambiental (ZHENG et al., 2015).

Do ponto de vista de aprendizado de máquina, o AQI-36 é particularmente útil por apresentar padrões naturais de correlação espacial entre estações próximas e forte variabilidade temporal, características essenciais para avaliar métodos de imputação em dados espaço-temporais. Cada estação fornece uma sequência de observações sincronizadas no tempo, formando um conjunto de séries temporais que compartilham dependências tanto horizontais quanto verticais.

Como o *dataset* contém registros reais sujeitos a falhas de transmissão, manutenção e ruídos operacionais, ele representa um cenário complementar ao ROMS: enquanto o ROMS fornece dados completos e controlados para experimentos com mascaramento sintético, o AQI-36 permite avaliar a capacidade dos métodos de lidar com ausências que emergem naturalmente em aplicações reais de monitoramento ambiental.

Assim, o AQI-36 complementa a análise ao fornecer um caso concreto de série espaço-temporal irregular, permitindo examinar o desempenho dos modelos em contextos com padrões de falhas não uniformes e maior variabilidade estatística.

Figura 9 – Mapa das estações Beijing AQI-36



Fonte: o próprio autor.

3.2 Geração de Falhas

Para avaliar métodos de imputação de maneira supervisionada, parte-se de séries temporais completas, às quais são aplicadas falhas sintéticas cujo valor verdadeiro é previamente conhecido. A degradação dos dados é realizada por meio de uma máscara aplicada às séries originais, gerando versões incompletas que posteriormente permitem medir a qualidade da reconstrução.

Neste trabalho, adotam-se simultaneamente dois padrões complementares de ausência: falhas gerais distribuídas ao longo do *dataset* e falhas em bloco. As falhas gerais consistem na remoção aleatória de uma fração dos valores, refletindo perdas pontuais

comuns em registros operacionais, como leituras corrompidas ou pequenas interrupções de amostragem. Esse padrão esparsa permite avaliar a capacidade do modelo de reconstruir valores isolados explorando dependências locais, tanto temporais quanto espaciais.

Em paralelo, são introduzidas falhas contínuas ao longo do tempo, caracterizando a chamada *block missingness*. Nesse caso, trechos inteiros de uma série são removidos, simulando interrupções de transmissão, períodos de manutenção ou falhas persistentes de sensores. Como tais ausências rompem a continuidade temporal, sua reconstrução exige mecanismos capazes de explorar não apenas as relações sequenciais, mas também a estrutura espacial do *dataset*, recorrendo a informações provenientes de outras localizações.

A combinação desses dois padrões de falha cria um ambiente experimental mais desafiador e fiel às condições reais de coleta de dados. Enquanto ausências gerais testam a habilidade do modelo em preencher pontos isolados, as falhas em bloco avaliam sua robustez frente a segmentos extensos de dados ausentes. Essa estratégia combinada é particularmente relevante para métodos espaço-temporais, incluindo arquiteturas baseadas em *attention*, grafos e modelos profundos, permitindo uma comparação mais abrangente e realista entre diferentes abordagens de imputação.

3.3 Avaliação dos Modelos

A avaliação dos métodos de imputação é conduzida comparando-se, de forma quantitativa, os valores reconstruídos com os valores verdadeiros disponíveis antes da aplicação da máscara de falhas. Para isso, utilizam-se métricas consolidadas na análise de séries temporais, em particular o erro absoluto médio (MAE) e o erro quadrático médio (MSE), que mensuram a discrepância entre valores imputados e reais.

Dado um conjunto de observações verdadeiras $\{y_t\}_{t=1}^T$ e seus correspondentes imputados $\{\hat{y}_t\}_{t=1}^T$, define-se o MAE como

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |y_t - \hat{y}_t|, \quad (3.1)$$

e o MSE como

$$\text{MSE} = \frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2. \quad (3.2)$$

Essas métricas são computadas exclusivamente sobre os pontos mascarados, garantindo que a avaliação reflita somente a capacidade do método de reconstruir valores ausentes.

No caso do *dataset* ROMS, a avaliação é realizada sobre seis meses de simulação contínua, sendo o mês de março reservado para teste. Os modelos são ajustados sobre os meses anteriores e avaliados utilizando quatro níveis controlados de degradação sintética: 25%, 30%, 50% e 75% de dados faltantes. Esses diferentes percentuais permitem examinar progressivamente a robustez dos modelos à medida que a quantidade de informação disponível diminui, cenário particularmente relevante em aplicações espaço-temporais.

No *dataset* AQI-36, a avaliação segue estrutura semelhante, porém as falhas analisadas incluem as ausências reais presentes no conjunto de dados, originadas de interrupções na medição, perda de transmissão e limitações operacionais das estações. A reconstrução é então comparada diretamente aos valores registrados, complementando o estudo com um cenário em que o padrão de falhas não é controlado, mas emerge naturalmente do processo de coleta.

Ao combinar um conjunto sintético e totalmente controlado (ROMS) com um conjunto real e irregular (AQI-36), obtém-se uma avaliação abrangente da capacidade de generalização dos métodos de imputação. Esse protocolo permite investigar desde a sensibilidade a diferentes taxas de degradação até a habilidade de lidar com padrões complexos de falhas que ocorrem em ambientes reais de monitoramento.

4 Especificação de Requisitos

Este capítulo apresenta os requisitos funcionais e não funcionais do *framework* desenvolvido para visualização, comparação e avaliação de métodos de imputação aplicados a séries espaço-temporais. O sistema tem como objetivo permitir que o usuário explore diferentes *datasets*, métodos e percentuais de falhas, analisando graficamente os resultados de imputação e suas métricas associadas.

4.1 Requisitos Funcionais

Os requisitos funcionais definem as operações que o sistema deve realizar. No contexto deste trabalho, o *framework* deve oferecer mecanismos de seleção, visualização e comparação entre resultados de imputação produzidos por métodos estatísticos e métodos baseados em *deep learning*. Os requisitos funcionais são:

1. **Seleção do *dataset*:** O sistema deve permitir ao usuário selecionar entre os conjuntos de dados disponíveis (ROMS e AQI-36), exibindo informações gerais sobre cada um.
2. **Seleção do método de imputação:** O sistema deve possibilitar a escolha entre métodos implementados, incluindo o método estatístico KNN e o método baseado em aprendizado profundo SPIN.
3. **Seleção do percentual de falhas:** No caso do *dataset* ROMS, o sistema deve permitir ao usuário escolher entre percentuais pré-definidos de dados faltantes (25%, 30%, 50% e 75%) e carregar automaticamente os resultados correspondentes.
4. **Visualização das séries temporais:** O sistema deve exibir, para um ponto selecionado do *grid* espacial, as séries temporal original, a série com falhas e a série imputada, permitindo comparação visual direta.
5. **Exibição da estrutura espaço-temporal:** O sistema deve apresentar um mapa ou *grid* espacial interativo que permita ao usuário navegar entre diferentes localizações e selecionar pontos específicos para análise.
6. **Apresentação de métricas:** O sistema deve exibir as métricas associadas à imputação (MAE e MSE), já calculadas previamente para cada combinação de método, *dataset* e nível de falha.
7. **Exploração de dimensões espaciais:** O sistema deve permitir ao usuário alternar entre diferentes posições do *dataset* espaço-temporal, possibilitando análise comparativa entre múltiplas localidades.

4.2 Requisitos Não Funcionais

Os requisitos não funcionais descrevem propriedades desejáveis relacionadas ao uso, desempenho e confiabilidade da aplicação. No contexto deste trabalho, destacam-se:

1. **Usabilidade:** A interface gráfica deve ser intuitiva, clara e de fácil navegação, permitindo que usuários explorem os dados e resultados sem necessidade de conhecimento técnico avançado.
2. **Eficiência:** A aplicação deve carregar rapidamente os dados, séries e métricas associadas, garantindo boa responsividade na navegação espacial e temporal.
3. **Reprodutibilidade:** Todas as combinações de métodos, percentuais de falha e *datasets* devem ser carregadas a partir de resultados previamente armazenados, garantindo consistência entre diferentes execuções.
4. **Confiabilidade dos métodos:** Apenas métodos consolidados e previamente validados (como KNN e SPIN) devem ser disponibilizados para comparação no *framework*, assegurando que os resultados exibidos sejam provenientes de arquiteturas bem estabelecidas.
5. **Portabilidade:** O sistema deve ser compatível com navegadores modernos, permitindo acesso multiplataforma sem necessidade de instalação adicional pelo usuário final.

5 Desenvolvimento do Trabalho

5.1 Tecnologias Utilizadas

O desenvolvimento do *framework* proposto exigiu a integração de diferentes ferramentas de *software*, tanto para o processamento e organização dos dados quanto para a construção da interface gráfica utilizada na exploração dos resultados de imputação. Esta seção apresenta as principais tecnologias empregadas e o papel desempenhado por cada uma no sistema.

5.1.1 *Backend* e Processamento de Dados

O *backend* foi desenvolvido em *Python* utilizando o *framework* *FastAPI* para disponibilização dos dados e resultados pré-computados ao *frontend*. A escolha do *FastAPI* ocorre devido à sua leveza, facilidade de integração com aplicações modernas em *JavaScript* e suporte nativo a operações assíncronas que permitem respostas rápidas às requisições feitas pela interface gráfica.

Para manipulação e organização dos dados oceânicos simulados, foi usado o pacote *xroms*, baseado em *xarray*, que simplifica o acesso às variáveis produzidas pelo ROMS e facilita operações sobre domínios espaço-temporais estruturados. Bibliotecas como *NumPy* e *Pandas* também foram empregadas para manipulação matricial e tabular das séries temporais.

Embora o treinamento dos modelos não faça parte do fluxo operacional do *framework*, este trabalho utilizou *PyTorch* e *PyTorch Geometric* para implementação e ajuste do método SPIN. Essas ferramentas fornecem abstrações adequadas para construção de modelos de *deep learning*, incluindo operações específicas para redes neurais de grafos que são fundamentais para o mecanismo de *message passing* adotado pelo SPIN.

5.1.2 *Frontend* e Visualização

A interface gráfica foi desenvolvida em *React* com *TypeScript* que oferecem modularidade, escalabilidade e segurança na tipagem durante a criação dos componentes da aplicação. O uso de *React* permite uma interface interativa em que a seleção do *dataset*, do método de imputação e do percentual de falhas se reflete imediatamente nas visualizações exibidas ao usuário.

Para composição visual e estilização, adotou-se o *framework* *TailwindCSS* que possibilita a criação de interfaces responsivas de maneira prática. A exibição das séries

temporais foi implementada com bibliotecas de gráficos como *Recharts*, adequadas para visualização intuitiva das curvas correspondentes à série original, à série com falhas e à série imputada.

A visualização espacial dos pontos da malha do ROMS foi construída com o auxílio de *Cartopy*, ferramenta consolidada de geoprocessamento em *Python* que permite gerar projeções cartográficas, desenhar linhas de costa e representar domínios espaciais estruturados. As figuras produzidas com *Cartopy* são integradas ao *frontend*, permitindo que o usuário visualize o *grid* e selecione os pontos de interesse para análise das séries temporais imputadas.

5.1.3 Ambiente de Desenvolvimento e Integração

O ambiente do sistema foi estruturado com suporte da ferramenta *Docker* que permite a execução reprodutível do *frontend* e do *backend* facilitando a distribuição da aplicação. O versionamento do código foi gerenciado com *Git* armazenado em repositório remoto para acompanhamento da evolução do projeto.

A combinação dessas tecnologias permitiu a construção de um *framework* robusto, modular e extensível capaz de integrar dados espaço-temporais, resultados de imputação e ferramentas interativas de visualização em uma única plataforma acessível ao usuário.

5.2 Projeto e Implementação

A implementação do *framework* foi conduzida a partir de um modelo de arquitetura cliente-servidor, organizado em três camadas principais: *frontend*, *backend* e módulo de dados e experimentos. Essa separação estrutural tem como objetivo assegurar modularidade, facilitar a manutenção do sistema e permitir que a lógica de interação com o usuário, o acesso aos resultados e o gerenciamento dos experimentos permaneçam independentes entre si. A Figura 10 apresenta, de forma sintética, o fluxo de comunicação entre os componentes do sistema.


5.2.1 Estrutura geral do sistema

O sistema foi concebido como uma ferramenta de exploração e visualização de resultados de imputação em séries espaço-temporais. Para isso, sua organização interna distribui responsabilidades entre três módulos cooperantes.

5.2.1.1 *Frontend*

A camada de interface, desenvolvida em *React* com *TypeScript*, é responsável pela interação direta com o usuário. Ela fornece uma experiência de navegação fluida, permitindo

Figura 10 – Diagrama de sequência do *framework* de imputação em séries espaço-temporais.



Fonte: o próprio autor.

selecionar o *dataset* desejado (ROMS ou AQI-36), visualizar metadados relevantes e escolher o método de imputação e o cenário de falhas a serem analisados. Além disso, o *frontend* apresenta a estrutura espacial do *dataset* por meio de mapas gerados a partir de figuras produzidas com *Cartopy*, o que possibilita ao usuário selecionar pontos específicos do *grid* e, em seguida, examinar simultaneamente a série original, a série com falhas e a série

imputada.

A aplicação mantém um estado interno que sincroniza as escolhas feitas pelo usuário ao longo da navegação. Essa lógica reativa permite que cada seleção, seja do método de imputação, do cenário de falhas ou do ponto espacial, atualize imediatamente as visualizações apresentadas, sem a necessidade de recarregar a aplicação ou solicitar processamento adicional ao servidor.

5.2.1.2 *Backend*

A camada de lógica de negócio foi implementada em *Python* com o *framework FastAPI*. Sua função central consiste em atuar como intermediária entre o *frontend* e o módulo de dados e experimentos. O *backend* disponibiliza ao cliente informações estruturais dos *datasets*, organiza e retorna os resultados pré-computados de imputação e garante a consistência entre as combinações selecionadas pelo usuário. Dessa forma, cada requisição enviada pelo *frontend* é analisada e traduzida em consultas adequadas aos arquivos armazenados.

Importante destacar que essa camada não executa etapas de treinamento ou inferência em tempo de execução. Todos os experimentos de imputação — envolvendo métodos estatísticos como KNN e modelos baseados em *deep learning*, como SPIN — foram previamente processados. Assim, o papel do *backend* é exclusivamente o de disponibilizar, de maneira organizada, as séries e métricas correspondentes às escolhas feitas durante a navegação.

5.2.1.3 Módulo de dados e experimentos

O módulo de dados e experimentos constitui o repositório responsável por armazenar as séries originais, as séries com falhas e os resultados das imputações realizadas. Esse módulo reúne, para cada combinação de *dataset*, método, cenário de falhas e ponto espacial, os seguintes elementos: a série temporal completa, a série degradada pelo processo de falhas, a série reconstruída pelo método de imputação e as métricas correspondentes, particularmente MAE e MSE. Além disso, preserva metadados essenciais, como coordenadas dos pontos do *grid*, índices temporais e informações sobre os cenários de falhas utilizados.

Para o dataset ROMS, foram adotados quatro cenários de falhas sintéticas de 25%, 30%, 50% e 75% de dados faltantes, além de um cenário de teste temporal referente ao mês de março. No caso do AQI-36, as falhas originais do *dataset* foram mantidas, preservando a característica realista da aplicação prática.

5.2.2 Fluxo operacional do *framework*

O fluxo operacional do *framework*, ilustrado na Figura 10, descreve a trajetória percorrida pelo usuário desde o primeiro contato com a interface até a visualização das séries imputadas. Inicialmente, o usuário seleciona o *dataset* desejado. Essa escolha aciona uma requisição do *frontend* ao *backend*, que consulta o módulo de dados para obter informações como extensão temporal, quantidade de pontos espaciais e tipos de falha disponíveis. A interface é atualizada com essas informações, permitindo que o usuário prossiga.

Em etapa subsequente, o usuário escolhe o método de imputação a ser analisado, podendo optar entre o método estatístico KNN e o método SPIN baseado em *deep learning*. Essa seleção é registrada no estado interno do *frontend*. Em seguida, o usuário define o cenário de falhas desejado. Para o ROMS, essa escolha corresponde ao percentual de degradação utilizado; para o AQI-36, o próprio padrão de falhas do *dataset* é adotado.

Após essas seleções, o *frontend* solicita ao *backend* a estrutura espacial correspondente ao *dataset*, que consiste na lista de pontos do domínio e nas suas coordenadas. Essas informações permitem à interface renderizar o mapa da região estudada. Quando o usuário seleciona um ponto específico, o *frontend* envia ao servidor uma requisição contendo o identificador do ponto, o *dataset*, o método e o cenário de falhas selecionados. O *backend*, por sua vez, consulta o módulo de dados e experimentos e retorna a série original, a série com falhas, a série imputada e as métricas de erro.

Esses dados são então apresentados em um painel integrado, permitindo uma comparação simultânea das três séries. A visualização resultante facilita a inspeção qualitativa da reconstrução e permite relacionar as métricas quantitativas ao comportamento temporal do método em um ponto específico do domínio espacial.

5.2.3 Decisões de projeto

A adoção de pré-processamento completo dos experimentos de imputação constituiu uma decisão central no desenvolvimento do *framework*. Ao optar por realizar previamente todas as combinações de imputação e armazenar seus resultados, eliminou-se a necessidade de execução de modelos durante o uso da ferramenta, garantindo maior responsividade e estabilidade da interface.

Outra decisão de projeto relevante foi a escolha por uma arquitetura desacoplada. A clara separação entre *frontend*, *backend* e módulo de dados possibilita que novos métodos de imputação sejam incorporados ao sistema sem alterações estruturais significativas. A adição de novos experimentos ou novos conjuntos de dados é realizada de forma independente, bastando atualizar o módulo de dados e assegurar que o *backend* consiga expor suas informações.

Por fim, a representação espacial explícita por meio de mapas reforça o caráter espaço-temporal dos conjuntos de dados utilizados. A possibilidade de selecionar pontos diretamente no *grid* facilita a compreensão da estrutura espacial e permite uma análise mais rica das reconstruções. A padronização das métricas em MAE e MSE assegura comparabilidade entre métodos e cenários, o que se alinha aos objetivos de avaliação sistemática propostos no início deste trabalho.

5.3 Testes e Avaliação

Esta seção apresenta os testes realizados com o *framework* desenvolvido e discute os resultados de imputação obtidos pelos métodos KNN e SPIN no *dataset* ROMS sob diferentes percentuais de falhas. A análise contempla tanto aspectos qualitativos, observados diretamente na interface visual do sistema, quanto aspectos quantitativos, avaliados pelas métricas MAE, MSE e RMSE.

5.3.1 Visualização dos Resultados no *Framework*

O *framework* permite ao usuário inspecionar, de forma interativa, a qualidade das imputações realizadas em diferentes pontos do domínio espacial. Após a seleção do *dataset*, do método de imputação e do cenário de falhas, o sistema apresenta três séries temporais sobrepostas:

- a série original, que serve como referência para avaliação;
- a série com falhas (originais ou sintéticas, dependendo do *dataset*);
- a série imputada pelo método selecionado.

Essas séries são exibidas juntamente com os valores das métricas MAE, MSE e RMSE para o ponto escolhido. Essa visualização permite verificar tanto o erro absoluto da imputação quanto eventuais distorções introduzidas na amplitude ou dinâmica temporal do sinal. Para o *dataset* ROMS, essa inspeção torna-se particularmente útil, pois a variável utilizada (altura da superfície do mar) apresenta variações suaves e espacialmente correlacionadas, permitindo identificar rapidamente desvios produzidos pelos métodos.

Além disso, a possibilidade de alternar entre diferentes percentuais de falhas sintéticas (25%, 30%, 50%, 75%) permite avaliar a robustez dos métodos em cenários progressivamente mais adversos. De forma complementar, a sobreposição espacial no mapa auxilia a identificar se determinados pontos apresentam maior sensibilidade à falta de dados.

5.3.2 Estudo de Caso: Comparação entre KNN e SPIN no ROMS

A seguir são apresentados os resultados quantitativos para os métodos KNN e SPIN, considerando percentuais crescentes de falhas (25%, 30%, 50% e 75%) no *dataset* ROMS. Em cada caso, as métricas foram calculadas sobre o período reservado para teste.

Tabela 1 – Resultados dos métodos de imputação em notação científica para diferentes percentuais de falha no dataset ROMS (variável SSH).

Percentual de Falha	<i>KNN</i>	<i>SPIN</i>
25%	MAE = 5.99×10^{-3}	MAE = 4.81×10^{-2}
	MSE = 6.29×10^{-5}	MSE = 3.24×10^{-3}
	RMSE = 7.93×10^{-3}	RMSE = 5.69×10^{-2}
30%	MAE = 6.03×10^{-3}	MAE = 5.04×10^{-2}
	MSE = 6.36×10^{-5}	MSE = 3.64×10^{-3}
	RMSE = 7.97×10^{-3}	RMSE = 6.03×10^{-2}
50%	MAE = 6.58×10^{-3}	MAE = 5.10×10^{-2}
	MSE = 7.72×10^{-5}	MSE = 3.77×10^{-3}
	RMSE = 8.78×10^{-3}	RMSE = 6.14×10^{-2}
75%	MAE = 7.30×10^{-3}	MAE = 4.95×10^{-2}
	MSE = 9.71×10^{-5}	MSE = 3.50×10^{-3}
	RMSE = 9.85×10^{-3}	RMSE = 5.92×10^{-2}

5.3.3 Discussão dos Resultados

Os testes realizados neste trabalho tiveram como objetivo comparar o desempenho de diferentes métodos de imputação frente a múltiplas taxas de falha previamente configuradas, tanto no dataset ROMS quanto no Beijing AQI-36. Para o conjunto oceânico, utilizou-se a variável *Sea Surface Height* (SSH), cujas características físicas desempenham papel importante na interpretação dos resultados.

A SSH é uma variável controlada no contexto do modelo ROMS, apresentando dinâmica contínua, suavidade temporal e coerência espacial entre os nós da malha. Esse comportamento se reflete em variações relativamente regulares, sem descontinuidades abruptas ou não linearidades intensas. Por esse motivo, a estrutura espaço-temporal da SSH tende a ser mais previsível, o que influencia diretamente a adequação dos métodos de imputação avaliados.

Os resultados obtidos mostram que, para essa variável específica, o método *K*-Nearest Neighbors (*KNN*) apresentou desempenho notavelmente sólido. Sua natureza baseada em vizinhança permite capturar tanto dependências espaciais — identificando valores próximos entre nós adjacentes — quanto dependências temporais, uma vez que as

janelas de dados preservam a continuidade temporal inerente ao fenômeno. Assim, mesmo sem recorrer a modelos complexos de aprendizado profundo, o *KNN* mostrou-se suficiente para reconstruções consistentes da SSH, alcançando erros competitivos em comparação com técnicas mais elaboradas.

Esse comportamento reforça o fato de que a adequação do método de imputação depende da natureza da variável analisada. Para variáveis mais suaves e regulares, como a SSH, métodos estatísticos simples podem apresentar desempenho semelhante ou até superior ao de modelos avançados quando a relação sinal-ruído é favorável e a estrutura espaço-temporal é bem comportada.

Por outro lado, nos experimentos envolvendo o dataset Beijing AQI-36 — composto por variáveis atmosféricas mais voláteis e sujeitas a episódios irregulares — observou-se maior diferenciação entre os métodos. Técnicas baseadas em *deep learning*, como o SPIN e a PriSTI, tenderam a responder melhor a condições de falha severa, sobretudo devido à sua capacidade de capturar não linearidades, padrões multivariados e relações de longo alcance entre observações. Essa complementaridade entre os métodos destaca a importância de um *framework* que permita comparar, visualizar e interpretar tais comportamentos de maneira integrada.

No conjunto, os resultados validam a proposta do trabalho: a construção de um ambiente unificado que possibilita ao usuário não apenas inspecionar as reconstruções visualmente, mas também compreender por que determinadas abordagens apresentam melhor desempenho em certos cenários. A análise comparativa revelou que:

- para variáveis fisicamente controladas, como a SSH, métodos simples como o *KNN* podem ser suficientes e até competitivos;
- para variáveis mais ruidosas e com eventos extremos, modelos de *deep learning* tendem a oferecer maior robustez;
- a variação da taxa de falha impacta significativamente o desempenho de todos os métodos, e o *framework* desenvolvido facilitou essa análise de forma interativa e clara.

Assim, os testes demonstraram não apenas o desempenho das técnicas avaliadas, mas também o papel fundamental do *framework* como ferramenta de apresentação e interpretação de resultados experimentais, reforçando seu valor como instrumento de pesquisa e apoio à tomada de decisão em contextos ambientais.

6 Considerações Finais

O presente Trabalho de Conclusão de Curso teve como objetivo principal o desenvolvimento de um *framework* interativo voltado à apresentação, comparação e análise visual de resultados de imputação em séries espaço-temporais. A partir dos dados simulados do modelo ROMS para a região do campo Gato do Mato e dos dados atmosféricos do Beijing AQI-36, foi possível construir um ambiente unificado para inspecionar de forma clara o comportamento de diferentes métodos de imputação sob múltiplas taxas de falha.

O trabalho atingiu plenamente esse objetivo geral. O *framework* implementado permite que o usuário explore séries completas, séries com falhas e séries imputadas, comparando métodos estatísticos e técnicas de aprendizado profundo por meio de métricas quantitativas (MAE, MSE, RMSE) e visualizações diretas das reconstruções. Essa capacidade de integração e apresentação atende aos requisitos estabelecidos na introdução, promovendo uma análise comparativa acessível, estruturada e reproduzível.

No que diz respeito aos objetivos específicos, o projeto possibilitou a avaliação comparativa de técnicas estatísticas e métodos de *deep learning*, atendendo ao primeiro objetivo. A análise das diferentes taxas de falha foi igualmente realizada, permitindo compreender a sensibilidade de cada método à ausência de dados, conforme previsto no segundo objetivo.

O terceiro objetivo, que é apresentar simulações do dataset ROMS para a região do campo Gato do Mato, foi atendido por meio da elaboração de séries espaço-temporais derivadas do modelo numérico, utilizadas como base para os experimentos. Isso conferiu realismo às análises e garantiu que os testes se apoiassem em dados representativos das condições oceânicas do ambiente de interesse.

O quarto objetivo, referente à validação das imputações, também foi plenamente alcançado. O *framework* oferece visualizações diretas das séries reconstruídas e calcula métricas em relação ao *ground truth*, possibilitando uma avaliação quantitativa e qualitativa das técnicas.

Por fim, o quinto objetivo, que era desenvolver uma aplicação web para análise e visualização, foi concretizado com a entrega de um *framework* visual que permite selecionar datasets, configurar taxas de falha, escolher métodos de imputação e visualizar de forma intuitiva a dinâmica espaço-temporal dos dados. Assim, todos os objetivos centrais definidos na introdução foram contemplados.

6.1 Contribuições

As contribuições deste trabalho se concentram na integração entre fundamentação teórica, prática experimental e desenvolvimento de ferramenta interativa.

A principal contribuição é o *framework* visual criado especificamente para apoiar a apresentação e a análise comparativa de resultados de imputação. Diferentemente de ferramentas voltadas à execução de testes automáticos, o *framework* enfatiza a interpretação dos resultados, oferecendo ao usuário uma forma clara de compreender como cada técnica reconstrói séries espaço-temporais sob diferentes condições de falha. A interface facilita a navegação entre pontos da malha, a inspeção simultânea das séries original, faltante e imputada, e a consulta imediata de métricas, contribuindo para a transparência e a interpretabilidade das abordagens estudadas.

No eixo experimental, o trabalho consolida e organiza resultados provenientes de métodos estatísticos e técnicas de *deep learning* sob um protocolo comum de avaliação. Essa padronização permite estabelecer comparações consistentes entre abordagens heterogêneas, contribuindo para a compreensão de suas forças e limitações. A investigação sistemática do impacto das taxas de falha reforça essa contribuição ao evidenciar como diferentes níveis de ausência influenciam a performance das técnicas.

No eixo aplicado, a construção das séries ROMS para a região do campo Gato do Mato constitui uma contribuição relevante, fornecendo um conjunto de dados espacialmente estruturado e fisicamente consistente para estudos posteriores envolvendo reconstrução de variáveis oceânicas.

Todas essas contribuições são fruto de pesquisa, abrangendo desde a concepção da arquitetura do *framework* até a elaboração das visualizações, preparação dos dados e organização dos resultados.

6.2 Perspectivas de Continuidade

A continuidade deste trabalho pode seguir diferentes direções, tanto no aperfeiçoamento do *framework* quanto na ampliação de sua aplicação científica.

Do ponto de vista técnico, o *framework* pode ser estendido para incorporar novas técnicas de imputação, novas métricas de avaliação e recursos adicionais de visualização, como comparações lado a lado, animações temporais ou mapas interativos mais detalhados. Também se abre a possibilidade de integração com novos *datasets*, incluindo séries observacionais reais provenientes de redes meteorológicas, sensores oceanográficos e sistemas ambientais urbanos.

No âmbito científico, os resultados deste trabalho criam base sólida para pesquisas

que investigam a influência de dados faltantes na detecção e na previsão de fenômenos ambientais críticos. Dados ausentes afetam a qualidade de modelos utilizados em oceanografia operacional, meteorologia, qualidade do ar e monitoramento de eventos extremos. Um *framework* dedicado à avaliação visual e quantitativa das imputações contribui para a melhoria da confiabilidade desses modelos, favorecendo ações de mitigação, planejamento de operações marítimas, respostas emergenciais e políticas públicas relacionadas a fenômenos extremos e mudanças climáticas.

Assim, este trabalho não apenas atende aos objetivos propostos, mas também estabelece fundamentos que ampliam sua relevância acadêmica, técnica e socioambiental, apontando caminhos promissores para pesquisa e desenvolvimento contínuos.

Referências

BARROS, M. et al. Early Detection of Extreme Storm Tide Events Using Multimodal Data Processing. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 38, n. 20, p. 21923–21931, mar. 2024. ISSN 2374-3468. Number: 20. Disponível em: <https://ojs.aaai.org/index.php/AAAI/article/view/30194>. Citado na página 14.

BARROS, M. R. et al. Embracing Data Irregularities in Multivariate Time Series with Recurrent and Graph Neural Networks. In: NALDI, M. C.; BIANCHI, R. A. C. (Ed.). *Intelligent Systems*. Cham: Springer Nature Switzerland, 2023. p. 3–17. ISBN 978-3-031-45368-7. Citado na página 14.

BARROS, M. R. d. *Incorporando as irregularidades de dados em séries temporais multivariadas*. Tese (tese) — Universidade de São Paulo, nov. 2024. Disponível em: <https://www.teses.usp.br/teses/disponiveis/3/3141/tde-21082025-134723/>. Citado na página 25.

BISHOP, C. M. *Pattern recognition and machine learning*. New York: Springer, 2006. (Information science and statistics). ISBN 978-0-387-31073-2. Citado 2 vezes nas páginas 19 e 20.

CAO, W. et al. BRITS: Bidirectional Recurrent Imputation for Time Series. *Advances in Neural Information Processing Systems*, v. 31, 2018. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2018/hash/734e6bfcd358e25ac1db0a4241b95651-Abstract.html. Citado na página 29.

CAVUS, M.; ALLAHHAM, A. Spatio-Temporal Attention-Based Deep Learning for Smart Grid Demand Prediction. *Electronics*, v. 14, n. 13, p. 2514, jan. 2025. ISSN 2079-9292. Publisher: Multidisciplinary Digital Publishing Institute. Disponível em: <https://www.mdpi.com/2079-9292/14/13/2514>. Citado na página 14.

CINI, A.; MARISCA, I.; ALIPPI, C. *Filling the Gaps: Multivariate Time Series Imputation by Graph Neural Networks*. arXiv, 2022. ArXiv:2108.00298. Disponível em: <http://arxiv.org/abs/2108.00298>. Citado 3 vezes nas páginas 14, 15 e 29.

DU, W.; CÔTÉ, D.; LIU, Y. SAITS: Self-attention-based imputation for time series. *Expert Systems with Applications*, v. 219, p. 119619, jun. 2023. ISSN 0957-4174. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0957417423001203>. Citado na página 29.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep learning*. Cambridge, Mass: The MIT press, 2016. (Adaptive computation and machine learning). ISBN 978-0-262-03561-3. Citado 3 vezes nas páginas 19, 21 e 22.

GUO, S. et al. *An Experimental Evaluation of Imputation Models for Spatial-Temporal Traffic Data*. arXiv, 2024. ArXiv:2412.04733 [cs] version: 1. Disponível em: <http://arxiv.org/abs/2412.04733>. Citado na página 17.

JAMES, G. et al. *An introduction to statistical learning: with applications in Python*. Cham, Switzerland: Springer, 2023. (Springer texts in statistics). ISBN 978-3-031-39189-7 978-3-031-38746-3. Citado 2 vezes nas páginas 19 e 20.

JIN, M. et al. A Survey on Graph Neural Networks for Time Series: Forecasting, Classification, Imputation, and Anomaly Detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, p. 1–20, 2024. ISSN 1939-3539. Conference Name: IEEE Transactions on Pattern Analysis and Machine Intelligence. Disponível em: <https://ieeexplore.ieee.org/document/10636792/?arnumber=10636792>. Citado na página 25.

KOCHKOV, D. et al. Neural general circulation models for weather and climate. *Nature*, v. 632, n. 8027, p. 1060–1066, ago. 2024. ISSN 1476-4687. Publisher: Nature Publishing Group. Disponível em: <https://www.nature.com/articles/s41586-024-07744-y>. Citado na página 14.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep Learning. *Nature*, v. 521, n. 7553, p. 436–444, maio 2015. ISSN 1476-4687. Publisher: Nature Publishing Group. Citado 3 vezes nas páginas 15, 21 e 22.

LI, X. et al. Data Imputation for Sparse Radio Maps in Indoor Positioning. In: *2023 IEEE 39th International Conference on Data Engineering (ICDE)*. Anaheim, CA, USA: IEEE, 2023. p. 2235–2248. ISBN 979-8-3503-2227-9. Disponível em: <https://ieeexplore.ieee.org/document/10184665/>. Citado 2 vezes nas páginas 14 e 15.

LIU, M. et al. PriSTI: A Conditional Diffusion Framework for Spatiotemporal Imputation. In: . Anaheim, CA, USA: IEEE, 2023. p. 1927–1939. ISBN 979-8-3503-2227-9. Conference Name: 2023 IEEE 39th International Conference on Data Engineering (ICDE) Place: Anaheim, CA, USA Publisher: IEEE. Disponível em: <https://ieeexplore.ieee.org/document/10184808/>. Citado na página 29.

LOPES, G. R.; DELBEM, A. C.; SOUSA, J. B. de. Introdução à análise de dados geoespaciais com python. *Sociedade Brasileira de Computação*, 2021. Disponível em: <https://scholar.google.com/scholar?cluster=7507044442140935667&hl=en&oi=scholar>. Citado na página 26.

MARISCA, I.; CINI, A.; ALIPPI, C. Learning to Reconstruct Missing Data from Spatiotemporal Graphs with Sparse Observations. *Advances in Neural Information Processing Systems*, v. 35, p. 32069–32082, dez. 2022. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2022/hash/cf70320e93c08b39b1b29a348097a376-Abstract-Conference.html. Citado 2 vezes nas páginas 29 e 30.

MORETTIN, P. A.; TOLOI, C. M. C. *Análise de séries temporais*. 3. ed. São Paulo: Editora Edgard Blucher, 2022. v. 1. ISBN 978-85-212-1351-2. Citado na página 25.

ROBERTS, D. A.; YAIDA, S.; HANIN, B. *The Principles of Deep Learning Theory: An Effective Theory Approach to Understanding Neural Networks*. 1. ed. Cambridge University Press, 2022. ISBN 978-1-009-02340-5 978-1-316-51933-2. Disponível em: <https://www.cambridge.org/core/product/identifier/9781009023405/type/book>. Citado 2 vezes nas páginas 21 e 22.

SCARSELLI, F. et al. The Graph Neural Network Model. *IEEE Transactions on Neural Networks*, v. 20, n. 1, p. 61–80, jan. 2009. ISSN 1941-0093. Disponível em: <https://ieeexplore.ieee.org/document/4700287>. Citado na página 23.

SEU, K.; KANG, M.-S.; LEE, H. An Intelligent Missing Data Imputation Techniques: A Review. *JOIV : International Journal on Informatics Visualization*, v. 6, n. 1-2, p. 278–283, maio 2022. ISSN 2549-9904. Disponível em: <http://joiv.org/index.php/joiv/article/view/935>. Citado na página 17.

SHCHEPETKIN, A. F.; MCWILLIAMS, J. C. The regional oceanic modeling system (ROMS): a split-explicit, free-surface, topography-following-coordinate oceanic model. *Ocean Modelling*, v. 9, n. 4, p. 347–404, jan. 2005. ISSN 1463-5003. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1463500304000484>. Citado 2 vezes nas páginas 14 e 32.

SHI, X. et al. Convolutional LSTM Network: a machine learning approach for precipitation nowcasting. In: *Proceedings of the 29th International Conference on Neural Information Processing Systems - Volume 1*. Cambridge, MA, USA: MIT Press, 2015. (NIPS'15, v. 1), p. 802–810. Citado na página 14.

TASHIRO, Y. et al. *CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation*. arXiv, 2021. ArXiv:2107.03502 [cs]. Disponível em: <http://arxiv.org/abs/2107.03502>. Citado na página 29.

VASWANI, A. et al. Attention Is All You Need. In: *Advances in Neural Information Processing Systems 30*. Long Beach, California (USA): [s.n.], 2017. p. 5998–6008. Citado na página 24.

WANG, J. et al. Deep learning for multivariate time series imputation: a survey. In: *Proceedings of the Thirty-Fourth International Joint Conference on Artificial Intelligence*. Montreal, Canada: [s.n.], 2025. (IJCAI '25), p. 10696–10704. ISBN 978-1-956792-06-5. Disponível em: <https://doi.org/10.24963/ijcai.2025/1187>. Citado 2 vezes nas páginas 17 e 28.

WEI, W. W. S. *Multivariate time series analysis and applications*. Hoboken: John Wiley & Sons, 2019. (Wiley series in probability and statistics). ISBN 978-1-119-50294-4 978-1-119-50293-7 978-1-119-50295-1. Citado 2 vezes nas páginas 25 e 26.

WU, H. et al. *TimesNet: Temporal 2D-Variation Modeling for General Time Series Analysis*. arXiv, 2023. ArXiv:2210.02186 [cs]. Disponível em: <http://arxiv.org/abs/2210.02186>. Citado na página 29.

YANG, Y. et al. *A Survey on Diffusion Models for Time Series and Spatio-Temporal Data*. arXiv, 2024. ArXiv:2404.18886 [cs]. Disponível em: <http://arxiv.org/abs/2404.18886>. Citado 2 vezes nas páginas 25 e 28.

YUAN, H.; LI, G. A Survey of Traffic Prediction: from Spatio-Temporal Data to Intelligent Transportation. *Data Science and Engineering*, v. 6, n. 1, p. 63–85, mar. 2021. ISSN 2364-1541. Disponível em: <https://doi.org/10.1007/s41019-020-00151-z>. Citado na página 14.

ZHANG, S. et al. Cautionary tales on air-quality improvement in Beijing. *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, v. 473, n. 2205, p. 20170457, set. 2017. Publisher: Royal Society. Disponível em: <https://royalsocietypublishing.org/doi/10.1098/rspa.2017.0457>. Citado na página 14.

ZHENG, Y. et al. Forecasting Fine-Grained Air Quality Based on Big Data. In: . [s.n.], 2015. Disponível em: <https://www.microsoft.com/en-us/research/publication/forecasting-fine-grained-air-quality-based-on-big-data/>. Citado na página 33.