

Italo Roberto Lui
Luiz Fernando de Almeida Mota
Raul Ribeiro Shan Tai

Deteccção de Golpes “Rug Pull” em Criptoativos usando Análise de Sentimentos

São Paulo, SP

2025

Italo Roberto Lui
Luiz Fernando de Almeida Mota
Raul Ribeiro Shan Tai

Deteccção de Golpes “Rug Pull” em Criptoativos usando Análise de Sentimentos

Trabalho de conclusão de curso apresentado
ao Departamento de Engenharia de Computa-
ção e Sistemas Digitais da Escola Politécnica
da Universidade de São Paulo para obtenção
do Título de Engenheiro.

Universidade de São Paulo – USP

Escola Politécnica

Departamento de Engenharia de Computação e Sistemas Digitais (PCS)

Orientador: Profa. Dra. Anarosa Alves Franco Brandão

Coorientador: Dr. João Paulo Aragão Pereira

São Paulo, SP

2025

Resumo

Na década atual, o crescimento na acessibilidade do mercado de criptomoedas e facilidade para a criação de criptoativos levou a um aumento na frequência de fraudes e golpes utilizando técnicas de engenharia social e manipulação de mercado. O objetivo do projeto é a elaboração de um modelo de detecção de golpes do tipo *Rug Pull* em criptoativos da plataforma de *blockchain* Solana, integrando diferentes técnicas de avaliação de riscos para a apresentação de uma análise de dados fundamentada e multimodal. O modelo proposto reúne três análises complementares: (i) o histórico de precificação do ativo, por meio de detecção de anomalias utilizando uma rede neural LSTM; (ii) a classificação do token como suspeito ou não, com base em suas características *on-chain* avaliadas por um modelo XGBoost; e (iii) a análise de sentimento de postagens em redes sociais relacionadas ao token, visando identificar possíveis sinais de manipulação de opinião pública ou de mercado. O modelo de análises foi desenvolvido e testado com sucesso, e seus resultados foram comparados aos de *datasets* verificados. Uma plataforma de visualização de dados também foi desenvolvida para melhor exibir os resultados.

Palavras-chave: Solana. *Rug Pull*. *Blockchain*. Detecção de golpe. Aumento de gradiente. LSTM. Análise de sentimento. *Late Fusion*. Aprendizado de máquina.

Abstract

Exit scams and frauds using social engineering and market manipulation techniques have become more frequent throughout the current decade, due to the increased accessibility of the cryptocurrency market and ease of cryptoasset creation. This project aims to develop a model to detect rug pull events in cryptoassets on the Solana blockchain platform, integrating multiple risk assessment methods in order to present a justified and multimodal risk analysis. The proposed model combines three complementary analyses: (i) historical price behavior and anomaly detection using an LSTM neural network; (ii) classification of the token as suspicious or not, based on its on-chain characteristics evaluated by an XGBoost model; and (iii) sentiment analysis of social media posts related to the token, aimed at identifying potential signs of public opinion or market manipulation. The detection model was developed and successfully tested against verified cryptoassets datasets. A graphical interface was also built to improve data visualization.

Keywords: Solana. Rug Pull. Blockchain. Fraud detection. Gradient boosting. LSTM. Sentiment analysis. Late Fusion. Machine learning.

Lista de ilustrações

Figura 1 – Diagrama de alto nível representando o resultado esperado do projeto.	13
Figura 2 – Fluxo de comunicação e interação dos agentes com os diferentes ambientes.	20
Figura 3 – Sequência de tarefas para a realização do projeto.	25
Figura 4 – Importância global das variáveis do modelo XGBoost segundo o método SHAP.	38
Figura 5 – Exemplo de explicação local do modelo para um token específico utilizando gráfico SHAP <i>waterfall</i> .	38
Figura 6 – Últimos 2 meses do <i>Token Shoggoth</i>	41
Figura 7 – Detector de Anomalia, com detecções em grandes variações, junto com seu preço e seu preço previsto junto com o volume.	42
Figura 8 – Distribuição residual, com valor médio e valores $3 \cdot \sigma$ acima e abaixo do valor.	42
Figura 9 – Gráfico do decaimento temporal do peso que uma postagem tem para uma análise de sentimentos atualizada em função das horas desde sua postagem.	45
Figura 10 – Gráfico da distribuição de probabilidade para a quantidade de usuários gerados para uma base de postagens simulada.	49
Figura 11 – Gráfico da distribuição de probabilidade para a quantidade de seguidores determinada para cada usuário para uma base de postagens simulada.	50
Figura 12 – Gráfico da distribuição de probabilidade para a quantidade de seguidores determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.	50
Figura 13 – Gráfico da distribuição de probabilidade para a idade da conta determinada para cada usuário para uma base de postagens simulada.	51
Figura 14 – Gráfico da distribuição de probabilidade para a idade da conta determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.	51
Figura 15 – Gráfico da distribuição de probabilidade para a frequência de postagens por hora determinada para cada usuário para uma base de postagens simulada.	52
Figura 16 – Gráfico da distribuição de probabilidade para a frequência de postagens por hora determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.	52

Figura 17 – Gráfico da distribuição de probabilidade para a idade das postagens para uma base de postagens simulada.	53
Figura 18 – Gráfico da distribuição de probabilidade para a idade das postagens para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.	53
Figura 19 – Gráfico da distribuição de probabilidade para a quantidade de postagens criadas para uma base de postagens simulada, no caso médio de 500 usuários simulados gerados.	54
Figura 20 – Gráfico de detecção de poucas, porém visíveis, anomalias na precificação.	57
Figura 21 – Distribuição residual, com uma frequência significativa abaixo de $\mu - 3 \cdot \sigma$	57
Figura 22 – <i>Landing Page</i> da Interface Gráfica	58
Figura 23 – Página de análise - Seção de Informações	59
Figura 24 – Página de análise - Seção de <i>Holder</i>	59
Figura 25 – Página de análise - Seção de <i>XGBoost</i>	60
Figura 26 – Página de análise - Seção de Detecção de Anomalias	61
Figura 27 – Página de análise - Seção de Análise de Sentimento	61
Figura 28 – Página de análise - Seção Final de Riscos agregados	62

Lista de abreviaturas e siglas

ABSA	Aspect Based Sentiment Analysis (Análise de Sentimento Baseada em Aspectos)
AI	Artificial Intelligence (Inteligência Artificial)
AMM	Automated Market Maker (Formador de Mercado Automatizado)
API	Application Programming Interface (Interface de Programação de Aplicações)
AUC-ROC	Area Under the Curve - Receiver Operating Characteristic (Área Sob a Curva - Característica de Operação do Receptor)
DeFi	Decentralized Finance (Finanças Descentralizadas)
DEX	Decentralized Exchange (Corretora de Criptomoedas Descentralizada)
ETH	Ethereum
FOMO	Fear of Missing Out (Medo de Ficar de Fora)
GB	Gradient Boosting (Aumento de Gradiente)
ICO	Initial Coin Offerings (Oferta Inicial de Moedas)
LLM	Large Language Model (Grande Modelo de Linguagem)
LM	Language Model (Modelo de Linguagem)
LP	Liquidity Provider (Provedor de Liquidez)
LSTM	Long Short-Term Memory (Memória de Curto Longo Prazo)
ML	Machine Learning (Aprendizado de Máquina)
SLM	Small Language Model (Pequeno Modelo de Linguagem)
SOL	Solana
SolRPDS	Solana Rug Pull DataSet (Conjunto de Dados de Puxada de Tapete em Solana)
SPL	Solana Program Library
TVL	Total Value Locked (Valor Total Bloqueado)
XGBoost	eXtreme Gradient Boosting (Aumento Extremo de Gradiente)

Sumário

1	INTRODUÇÃO	11
1.1	Motivação	11
1.2	Objetivos	13
1.3	Justificativa	14
1.4	Organização do Trabalho	15
2	ASPECTOS CONCEITUAIS	17
2.1	Conceitos	17
2.2	Revisão de Literatura	21
3	MÉTODO DO TRABALHO	25
4	ESPECIFICAÇÃO DE REQUISITOS	27
4.1	Requisitos Funcionais	27
4.2	Requisitos Não Funcionais	27
4.3	CrITÉrios de Sucesso	28
4.4	Validação e Testes	28
5	DESENVOLVIMENTO DO TRABALHO	29
5.1	Tecnologias Utilizadas	29
5.2	Projeto e Implementação	32
5.3	Metodologia de Fusão de Modelos	32
5.3.1	Descrição da Estratégia <i>Late Fusion</i>	32
5.4	Modelo de Classificação On-Chain com XGBoost Probabilístico	34
5.4.1	Contexto e Motivação	34
5.4.2	Abordagem Baseada em XGBoost	35
5.4.3	Comparativo entre XGBoost e Random Forest	35
5.4.4	Treinamento e Calibração do Modelo	36
5.4.5	Interpretação e Integração com o Modelo Híbrido	38
5.5	Precificação Histórica de Ativos	39
5.5.1	Detecção de Anomalias em Ativos	40
5.5.2	Aplicação do Detector em um Estudo de Caso	41
5.6	Análise de Sentimentos de <i>Tweets</i>	42
5.6.1	Peso Agregado e Sentimento Público	43
5.6.2	Geração e Organização de <i>Tweets</i>	47
5.7	Resultados	55

5.7.1	Seção On-Chain	55
5.7.2	Seção LSTM	57
5.7.3	Interface Gráfica do Sistema	58
6	CONSIDERAÇÕES FINAIS	63
6.1	Conclusões do Projeto de Formatura	63
6.2	Contribuições	63
6.3	Perspectivas de Continuidade	64
	 REFERÊNCIAS	 65

1 Introdução

1.1 Motivação

A popularidade do mercado de criptomoedas cresce a cada ano, e com isso, o contato da população geral com as tecnologias e meios de troca dos criptoativos também aumenta consideravelmente, elevando também o risco de golpes e fraudes que prejudicam investidores. Um dos golpes mais comuns atualmente é o “Rug Pull”, ou puxada de tapete, um tipo de golpe no mercado de criptoativos em que os desenvolvedores de um projeto fraudulento abandonam abruptamente (ou ao longo de um período de tempo) a iniciativa e retiram os fundos investidos pelos usuários, deixando-os com ativos severamente desvalorizados (ARS TECHNICA, 2024; CERTIK, 2022). Esse tipo de fraude ocorre frequentemente em plataformas DeFi (finanças descentralizadas) e muitas vezes é impulsionado por influenciadores digitais que promovem o projeto para seus seguidores, gerando uma falsa sensação de credibilidade e *Fear of Missing Out* - a percepção, por parte dos investidores, de que estão perdendo uma grande oportunidade. Esses influenciadores, que podem estar cientes ou não do golpe, usam seu alcance para atrair novos participantes, elevando o valor do ativo antes que os golpistas drenem a liquidez (SOLIDUS LABS RESEARCH, c. 2025).

Diante desse cenário, cresce a demanda por ferramentas capazes de identificar padrões suspeitos de forma sistemática e confiável. Projetos voltados à automatização da detecção e análise de risco constituem uma área recente no desenvolvimento aplicado ao mercado financeiro e empregam métricas e técnicas preditivas variadas, frequentemente baseadas no comportamento histórico de preços como principal indicador de risco (MOURA et al., 2024; RAMOS; GOLUB, 2017). No entanto, muitos desses sistemas ainda carecem de maior acessibilidade, interpretabilidade e flexibilidade, elementos essenciais para oferecer suporte efetivo a investidores e instituições diante da sofisticação crescente dos golpes. Plataformas mais acessíveis para avaliação de risco incluem métricas de segurança referentes às características do criptoativo, mas também apresentam pouca flexibilidade no modelo e nas técnicas de avaliação utilizadas (COINMARKETCAP, c. 2025a; QUILLAI NETWORK, c. 2025). Esforços recentes têm buscado aprimorar os sistemas de detecção de golpes por meio de técnicas mais robustas e integradas. Estudos que combinam métodos de previsão baseados em *machine learning* com análises tradicionais de contratos inteligentes e dados de *blockchain* têm demonstrado resultados promissores (KALACHEVA et al., 2024; MAZORRA; ADAN; DAZA, 2022; YAREMUS et al., 2025). Esse avanço metodológico também impulsionou a criação de *datasets* dedicados, que reúnem e documentam características recorrentes em casos de *rug pull*, facilitando pesquisa e validação empírica (ALHAIDARI et al., 2025).

Paralelamente, a crescente influência das redes sociais no ecossistema de finanças descentralizadas passou a ser reconhecida como um componente essencial na prevenção e detecção de fraudes, dado seu papel na disseminação de informações, na criação de *hype* e na manipulação de comportamento de investidores (LIU et al., 2025).

A contínua exploração de novos modelos de detecção e proteção de potenciais investidores e participantes em plataformas DeFi é uma tarefa em destaque atualmente, o que leva a primeiro plano a potencialidade para uma plataforma de detecção que consiga orquestrar efetivamente diferentes técnicas de análise (previsões usando técnicas de *machine learning*, análises de contrato, identificação de riscos em redes sociais, entre outros) para fornecer resultados acessíveis e compreensíveis para o público geral.

Casos recentes reforçam a urgência de abordagens automatizadas de detecção de riscos em ambientes de alta velocidade e baixa regulação, como é o caso da blockchain Solana. Em 2024, o token **\$LIBRA** tornou-se um dos maiores exemplos contemporâneos de *rug pull* (CNN, c. 2025), após captar milhões de dólares em liquidez e, em seguida, ter seus pools drenados em questão de minutos. O evento expôs a dificuldade de investidores em identificar riscos técnicos invisíveis em contratos que, à primeira vista, aparentavam legitimidade e conformidade com padrões mínimos de governança.

Além disso, outros criptoativos recentes ganharam grande visibilidade por razões distintas, demonstrando como o componente social - incluindo o discurso político - pode amplificar a percepção de valor e, ao mesmo tempo, aumentar a vulnerabilidade dos investidores. Um exemplo emblemático é o token **TRUMP** na Solana. Embora não tenha sido classificado como golpe, o ativo apresentou dinâmica de mercado fortemente influenciada por narrativas políticas e polarização social, gerando picos abruptos de volume, engajamento e volatilidade. Esse caso ilustra como discussões públicas intensas, figuras públicas e eventos políticos podem atuar como catalisadores de movimentos de mercado, alterando a percepção de risco e favorecendo ambientes propícios para manipulação discursiva.

A combinação de um caso explícito de fraude, como o ocorrido com **\$LIBRA**, com exemplos de ativos altamente sensíveis ao contexto sociopolítico, como o token **TRUMP**, ressalta a importância de ferramentas capazes de integrar múltiplas modalidades analíticas - técnicas, temporais e socioemocionais. Esses episódios evidenciam a necessidade de métodos que permitam detectar sinais precoces de risco, mesmo quando o fator crítico não é o contrato em si, mas o ecossistema de influência que o circunda, reforçando assim a motivação para o desenvolvimento do sistema proposto neste trabalho.

1.2 Objetivos

O objetivo do projeto é a elaboração de um modelo de detecção e previsão de golpes do tipo “*Rug Pull*” (ou puxada de tapete) em criptoativos, utilizando diferentes técnicas de avaliação de riscos para a apresentação de uma análise de dados fundamentada, incluindo um índice de risco agregado para o criptoativo. Dada a prevalência desse tipo de golpe nas criptomoedas baseadas em Solana (SOL), o foco do sistema será na investigação e avaliação de características apresentadas por ativos nesta rede ([SOLIDUS LABS RESEARCH, c. 2025](#)).

O modelo deve contemplar o histórico de precificação do ativo e os indicadores de sua disponibilização no mercado, e também utilizar técnicas de análise de sentimento do mercado por meio de uma inteligência artificial. A análise de sentimento deve ser conduzida sobre publicações referentes ao criptoativo em redes sociais como X (antigamente Twitter), permitindo assim uma visão panorâmica e sensível à volatilidade, integrando-se com o meio de promoção e comunicação mais comum no ecossistema DeFi. O desenvolvimento de um modelo apropriado para a previsão de golpes do tipo Rug Pull no contexto de criptoativos utilizará informações relacionadas a golpes passados já conhecidos no mercado ([ALHAIDARI et al., 2025](#)).

O diagrama de alto nível a seguir ilustra o resultado final esperado do projeto.




Figura 1 – Diagrama de alto nível representando o resultado esperado do projeto.

Ao final do projeto, além da elaboração e implementação do modelo, busca-se realizar uma análise de desempenho da tecnologia desenvolvida, além do impacto de cada aspecto da modelagem e da massa de dados, para traçar conclusões como, por exemplo:

Incluir a análise de sentimentos tornou o modelo 50% mais lento, mas aumentou em 5% a acurácia medida.

Essa análise poderá ser realizada através de testes retroativos (“back-tests”), bem como variando os parâmetros do modelo e aplicando-o sobre o mesmo conjunto de dados.

1.3 Justificativa

Os dados de precificação de diferentes criptomoedas já são compilados e disponibilizados em APIs de plataformas para acompanhamento de criptoativos, como Quill Check ([QUILLAI NETWORK, c. 2025](#)), um website dedicado à análise de risco de tokens e criptomoedas, ou CoinMarketCap ([COINMARKETCAP, c. 2025a](#)), que apresenta a variação de preço, sentimento público e dados de disponibilidade de tokens registrados, incluindo volume de trocas, quantidade de tokens livres para troca e concentrações de posse. Além disso, o aumento na acessibilidade das operações de troca de criptomoedas promoveu um crescimento no número de *memecoins* e na frequência de golpes e fraudes nos ambientes de troca descentralizados ([CERTIK, 2022](#); [ARS TECHNICA, 2024](#)), fomentando também esforços para a detecção de indicadores de risco e classificação em larga escala de ocorrências de *rug pulls* ([ALHAIDARI et al., 2025](#)).

Em outros projetos realizados com a finalidade de detectar golpes como Pump and Dump - cujo comportamento do ativo é semelhante ao Rug Pull - em tempo real, fontes como as citadas ou como as presentes no mercado Poloniex de troca de criptomoedas foram utilizadas. Tais projetos focam tipicamente na união de técnicas de *machine learning* com análises tradicionais de ativos para a predição a partir de dados de troca exclusivamente ([MAZORRA; ADAN; DAZA, 2022](#); [MOURA et al., 2024](#); [RAMOS; GOLUB, 2017](#)), mas esforços mais recentes buscam integrar e agrupar dados relevantes para o sentimento de mercado junto à pipeline de detecção, como mensagens em grupos da plataforma de mensagens Telegram ([BOLZ et al., 2024](#)), que anunciam eventos relevantes ao valor e distribuição do token, e servem como gatilho primário para a detecção. Este projeto busca uma integração similar, mas através da determinação do sentimento de mercado com processamento de notícias e atualizações em redes sociais.

A evolução, diversificação e comparação de modelos de previsão proposta neste projeto, portanto, busca proteger investidores de técnicas manipulativas presentes no mercado financeiro, tornando mais acessíveis formas de defesa e detecção de fraudes e golpes tornados comuns no contexto da crescente digitalização e expansão do público interessado no investimento através de criptomoedas. Além disso, incorporar análise de sentimentos no conteúdo de plataformas sociais para determinar a opinião pública dos investidores e seu impacto nos preços dos tokens e na detecção de fraudes é uma linha de ação recomendada em projetos anteriores para o desenvolvimento da área de estudo ([KALACHEVA et al., 2024](#)), podendo resultar em descobertas significativas e melhorias de desempenho notáveis ([LIU et al., 2025](#)).

A popularização de *memecoins* como parte da cultura de troca dos criptoativos levou a um aumento considerável de ambientes voláteis, com pouca legislação e com grande foco na comunicação entre a comunidade de interessados. Além disso, Solana (SOL) se mostrou uma plataforma fértil para a disseminação de golpes como *rug pull*, principalmente considerando suas taxas reduzidas para transações e *exchanges* com alta acessibilidade quando comparadas às outras plataformas. Pesquisas recentes identificam que as parcelas de tokens que exibem características de esquemas de *pump-and-dump* e *rug pulls* pode chegar a 98.7% de todos os tokens listados em *exchanges DeFi* populares (SOLIDUS LABS RESEARCH, c. 2025). Isso indica que plataformas e *tokens* baseados em Solana apresentam uma grande oportunidade para análise dos golpes investigados.

1.4 Organização do Trabalho

O trabalho foi segmentado em diversos capítulos:

- O capítulo 2 apresenta conceitos elementares para a detecção de golpes de *Rug Pull*, bem como uma introdução à abordagem adotada.
- O capítulo 3 apresenta o processo de desenvolvimento do trabalho através de suas diferentes fases e a determinação das principais fases propostas.
- O capítulo 4 define requisitos, apontando objetivos, demandas e métricas para a avaliação do sucesso deste trabalho.
- O capítulo 5 apresenta o processo de desenvolvimento do trabalho, desde as tecnologias utilizadas até a implementação e os testes realizados.
- O capítulo 6 apresenta o balanço final do trabalho, os resultados atingidos e não atingidos, as deliberações acerca do processo e os próximos passos que podem ser realizados com base no trabalho.

2 Aspectos Conceituais

2.1 Conceitos

Golpes do tipo *Rug Pull* exploram a confiança da comunidade envolvida em ambientes DeFi, a influência de figuras públicas e a escassez de regulamentação no setor, causando grandes prejuízos financeiros para os investidores. Indicadores comuns desse tipo de golpe são tokens:

- Listados a baixo custo em ambientes de negociação
- Sem processo de auditoria
- Sem processo de verificação de idoneidade
- Com crescimentos consideráveis e frequentes do valor em pouco tempo
- Com marketing muito agressivo do projeto associado
- Com alta concentração dos ativos disponíveis sob controle de uma única pessoa, entidade ou grupo
- Em que os desenvolvedores possuem a capacidade de emissão de novos títulos
- Com taxas assimétricas de compra e venda

Dessa forma, a base para o modelo de avaliação de risco é a integração de verificações em três âmbitos referentes às criptomoedas analisadas (ou seja, o uso de três fontes de dados distintas):

- Dados de mercado ([COINMARKETCAP](#), c. 2025b), como, mas não limitados a:
 - Precificação histórica do ativo: O valor determinado do token. O valor que os clientes pagam pode ser fixado pelo emissor ou flutuante, devido a oferta e demanda de mercado;
 - Market cap: Representa o valor total de todos os tokens em circulação, e pode ser calculado como o produto entre a quantidade de tokens disponíveis para troca e o preço unitário de um token;
 - Pool de liquidez: A liquidez de um ativo é sua capacidade/facilidade de ser convertido em dinheiro para o investidor. A *pool* de liquidez é um conjunto de fundos na forma de tokens, assegurados por um programa SPL, que fornece

liquidez para corretores de criptomoedas descentralizados, atenuando a falta de liquidez típica de sistemas assim. Esses tokens são fornecidos pelos ganhos passivos de usuários (*liquidity providers*, ou LPs), e limitam os efeitos de *slippage*, ou seja, a diferença de preço entre a criação de uma ordem de compra ou venda e a sua execução, devido à alta volatilidade do mercado de criptomoedas;

- Concentração e número de investidores: Ativos altamente concentrados possuem maiores riscos de remoção repentina de liquidez;
 - Transações públicas: Mantidas no *ledger*/livro de ordens descentralizado chamado blockchain, com identidades anonimizadas.
- Atributos técnicos do ativo, como, mas não limitados a:
 - Possibilidade de emissão (Mint)
 - Possibilidade de remoção (Burn)
 - Taxas de compra e venda assimétricas
 - Presença de endereços especiais
 - Presença de mecanismo de autodestruição
 - Publicações que reflitam a opinião pública quanto ao ativo, como postagens na rede social X/Twitter (referidos como *Tweets*).

Sobre esta última, serão aplicadas técnicas de análise de sentimento para atribuir um score relacionado à probabilidade de que determinado criptoativo esteja associado a um Rug Pull.

Formalmente, um golpe de *rug pull*, ou puxada de tapete, é definido como uma manobra maliciosa no setor de criptoativos, na qual desenvolvedores de criptomoedas abandonam um projeto e fogem com os fundos dos investidores, provocando uma queda intensa na liquidez do ativo (COINMARKETCAP, c. 2025b). Esse tipo de golpe pode ocorrer em um momento pontual, caracterizando um *hard rug pull*, ou pode ocorrer ao longo de um período de tempo mais longo, no que é referido como *soft rug pull* (CERTIK, 2022). Isso é mais frequente em ambientes DeFi e em DEXs, nos quais o token é criado e disponibilizado para pares de negociação com moedas conhecidas, como Solana (SOL) ou Ethereum (ETH). Quando uma quantidade significativa de investidores trocam seus ativos pelo token listado, os criadores drenam todo o pool de liquidez, derrubando o preço da moeda para zero.

Esse tipo de golpe é mais comum em DEXs, pois elas são um tipo de corretora que permite que os usuários listem tokens gratuitamente e, muitas vezes, com pouca ou nenhuma auditoria. Indicadores fortes de tokens usados para *rug pulls* são liquidez baixa, ausência de processos de auditoria durante sua criação, falta de *pool* de liquidez (ou *pool*

de liquidez não bloqueada por certo período), quantidades significativas de tokens sendo mantidas com a equipe de desenvolvimento, estímulo do *Fear of Missing Out* (FOMO) através de técnicas de geração de *hype*, subidas consideráveis no preço em poucas horas e pré-venda de tokens.

Existem diferentes formas de se classificar um período de movimentações de mercado como indicativas de um golpe de *rug pull*, e cada forma requer a análise de diferentes variáveis. As duas formas mais comuns (KALACHEVA et al., 2024; MAZORRA; ADAN; DAZA, 2022; YAREMUS et al., 2025) para aplicações automatizadas são:

- **Idle (ou Inatividade):** Uma instância do golpe *rug pull* é definida como uma ocorrência de um token sem um par de operações de compra e venda (troca) durante um certo período após o início das trocas. Isso significa que tokens obtidos previamente não foram vendidos, e não foram comprados mais tokens, o que é um indicador de baixa atividade e liquidez.
- **Total Value Locked (TVL, ou Valor Total Trancado):** O *Total Value Locked* é uma métrica usada no mercado de finanças descentralizadas para medir o valor total de criptomoedas que estão depositadas sobre o token em múltiplas plataformas e aplicativos (COINEXT, 2025). Essa métrica indica a quantidade de ativos que estão sendo utilizados para formar um *pool* de liquidez e garantir empréstimos. A TVL é comumente usada como avaliação da saúde financeira e segurança dos projetos, pois um TVL alto sugere que existe alta participação dos usuários, muitos ativos confiados à plataforma e alta confiabilidade do projeto. Ela é definida como o produto da quantidade total de tokens "trancados" e do valor de mercado dos tokens.

Uma instância do golpe *rug pull* é definida como uma queda do índice TVL de $p\%$ do seu maior valor durante um certo período após o início das trocas. Matematicamente, associando o *rug pull* à queda de liquidez do token, e definindo $MD \leq p$ como a queda máxima do índice TVL (YAREMUS et al., 2025):

$$MD = \frac{|TVL(\tau) - TVL(t_0)|}{TVL(t_0)}, \quad (2.1)$$

sendo t_0 o instante com o menor valor de TVL identificado e τ o instante com o maior valor de TVL identificado, ambos dentro de um período determinado.

A abordagem de detecção por TVL é apontada como sendo mais apropriada para detecção de casos negativos de *rug pull* e de casos positivos para tokens com baixa atividade em DEXs específicas, enquanto a abordagem de detecção por inatividade é mais adequada para a detecção de casos positivos, principalmente em tokens com alta atividade de troca. A identificação por TVL também requer uma fonte de dados com informações sobre a

liquidez do token analisado (e isso não é mantido por todas as corretoras), o que se mostra uma restrição para seu uso. Levando em consideração os fatores apresentados, a abordagem *Idle* foi selecionada para a classificação de um *token* como tendo ou não uma instância de *rug pull* no contexto do sistema desenvolvido.

Para o projeto, pretende-se utilizar uma arquitetura multiagentes especializados, como representada pela seguinte figura:




Figura 2 – Fluxo de comunicação e interação dos agentes com os diferentes ambientes.

A partir dos dados da cadeia, presentes no ambiente DeFi, os sistemas agregadores coletam dados da blockchain, como histórico de transações, liquidez, e propriedades dos tokens, centralizando a informação e fornecendo-as por meio de APIs. A agregação de dados ocorre separadamente para todos os agentes, e dados de agentes distintos são totalmente isolados até que o agente coordenador realize sua avaliação.

O sistema é composto por 4 agentes, dos quais 3 são especialistas de domínio e um deles é responsável por coordenar os demais:

- **Agente Coordenador:** Integra as análises de precificação, atributos e sentimentos, e realiza a atribuição de um *score* de risco agregado a partir dos resultados atribuídos pelos demais agentes. Além disso, este agente é capaz de justificar o resultado fornecido, considerando os diferentes dados fornecidos por outros agentes presentes no sistema;
- **Agente para Análise de Precificação:** Analisa o histórico de preços e padrões de mercado, buscando anomalias e/ou pontos de mudança, além de padrões típicos do pump-and-dump, como por exemplo, manipulação de liquidez. Isso é feito utilizando a arquitetura de rede neural recorrente LSTM (*Long Short-Term Memory*), projetada para identificar padrões sequenciais complexos, viabilizando a previsão de valores e detecção de anomalias (indicativas de *rug pull*);
- **Agente para Análise de Atributos:** Avalia as características técnicas do token, como padrões de governança, permissões dos desenvolvedores e atributos de segurança.
- **Agente para Análise de Sentimentos:** Coleta dados de redes sociais (principalmente X/Twitter) para analisar o sentimento do mercado em relação ao token, bem como observar padrões de marketing e compará-los com esquemas comprovados de pump-and-dump.

Por fim, quando o agente coordenador receber as conclusões de cada agente, deve ser realizada a atribuição de um score, relacionado à probabilidade do token ser um golpe de "*rug pull*". Ao final, a pontuação é disponibilizada por meio de uma API, permitindo que outras aplicações e/ou plataformas pesquisem e acessem o risco associado a um token.

Na prática, pretende-se utilizar o Magentic-One, uma extensão do framework Microsoft AutoGen para estruturar essa metodologia. O Magentic-One se revelou um arcabouço avançado e versátil para a orquestração de agentes, permitindo sua integração e coordenação por meio de uma comunicação facilitada e a consolidação dos dados em um pipeline eficiente, além de lidar com tarefas complexas de tomada de decisão. Além disso, o AutoGen, focado na automação e geração de código, permitirá a construção de modelos personalizados para cada agente, que podem ser compostos por modelos de linguagem servidos localmente (FOURNEY et al., 2024).

2.2 Revisão de Literatura

A popularização das criptomoedas e a ampliação dos meios de investimento associados a esse mercado atraíram tanto novos investidores quanto agentes mal-intencionados, que buscam explorar vulnerabilidades técnicas e comportamentais para aplicar golpes.

Esse cenário foi agravado por uma série de transformações recentes no ecossistema: a intensificação das campanhas de oferta inicial de moedas (ICO), a rápida evolução das plataformas de finanças descentralizadas (DeFi) e das corretoras descentralizadas (DEX), o crescimento acelerado das *memecoins* e a forte integração entre atividades de investimento e redes sociais ou aplicativos de mensagens. Em conjunto, esses fatores ampliaram significativamente as oportunidades para fraudes e práticas de engenharia social no ambiente cripto. Essas expansões também fomentaram, porém, o desenvolvimento de novos e poderosos métodos de detecção de golpes e fraudes, integrando conhecimento psicológico, técnicas de segurança computacional em blockchain, técnicas de processamento e análise de dados, Inteligência Artificial (AI) e Machine Learning.

O crescimento da acessibilidade do ecossistema de criptomoedas também permitiu um recrudescimento das *memecoins*. Esses ativos, caracterizados pela alta volatilidade e dependência na criação de *hype* em redes sociais e fóruns, popularizaram ambientes de trocas com pouca segurança garantida por lei e com retornos altamente especulativos. Plataformas e *tokens* baseados em Solana (SOL) são extremamente atrativos para projetos dessa natureza, pois esboçam menores taxas de transações e *exchanges* com maior acessibilidade aos usuários quando comparadas às outras plataformas. Isso também colaborou para a disseminação de golpes como *rug pull* e *pump-and-dump*, sendo que entre 93.0% e 98.7% de todos os tokens listados em certas *exchanges* descentralizadas exibem características que identificam os ativos como esquemas fraudulentos ([SOLIDUS LABS RESEARCH, c. 2025](#)).

No caso do blockchain Solana, plataformas de lançamento de criptomoedas como *pump.fun* destacam ainda mais esse problema, permitindo a criação e troca gratuita (ou por taxas baixíssimas) e imediata de moedas, assim como o seu lançamento em DEXs após elas obterem tração e capitalização de mercado suficiente para passarem pelo processo de auditoria dessas plataformas descentralizadas. De forma complementar, a plataforma *pump.fun* lança as moedas pelo método de lançamento justo, no qual todos os tokens são criados simultaneamente, sem uma pré-venda, o que previne certas categorias de golpes. Uma consequência direta da acessibilidade e facilidade do lançamento de moedas, porém, é a alta taxa de fracasso, falta de tração e alta recorrência do abandono das moedas criadas, além da suscetibilidade aos *soft rug pulls*, nos quais os criadores retiram apenas seus próprios tokens, mantendo certa liquidez no projeto, mas abandonando esforços de continuá-lo. Fraudes desse tipo são mais difíceis de identificar, mesmo que as plataformas de lançamento disponibilizem indicadores como a concentração de tokens ([CERTIK, 2022](#); [ARS TECHNICA, 2024](#)).

Diferentes golpes na troca de tokens de forma centralizada ou descentralizada podem ocorrer tanto por vulnerabilidades no código da própria criptomoeda, exploração de características do blockchain, falta de procedimentos nas corretoras de criptomoedas

ou fraudes diretamente perpetradas por elas. No caso dos esquemas de *rug pull*, que são de interesse para o presente projeto, a principal vulnerabilidade explorada é a psicológica, aplicando técnicas de engenharia social e geração de *hype/Fear of Missing Out*, seguidas pela retirada de fundos e abandono do projeto, tipicamente em suas fases iniciais, não muito tempo após a listagem do token.

Certos projetos (RAMOS; GOLUB, 2017; MOURA et al., 2024) exploram estratégias tradicionais de detecção de golpes com técnicas de Machine Learning, detectando sinais de *pump-and-dump* nas fases iniciais de um projeto. O cerne dessas táticas é a análise de trocas e operações referentes à criptomoeda analisada em uma dada *exchange*, acompanhando o livro de ordens para a determinação de padrões de compra ou venda e possíveis manipulações de mercado. Esses modelos conseguem, mesmo com uma visão parcial das vendas e compras totais, detectar riscos de esquemas de *pump-and-dump* na fase inicial dos projetos com 60% a 83% de acurácia em casos reais. Isso é realizado através de uma previsão da precificação do token até 24 horas após a análise, considerando o volume, quantidade e tipo das transações como indicadores da tendência de mercado, o que também é imprescindível para definir e detectar possibilidades de *rug pull*. Também é usual a aplicação de técnicas para a predição de preços futuros na avaliação de possíveis riscos no investimento. Nesse caso, são frequentemente implementadas redes neurais, que detectam padrões e anomalias na precificação de um determinado ativo, como as de arquitetura *Long Short Term Memory*, ou LSTM (OLAH, 2015).

Outros avaliadores de risco também aplicam a técnica de *Gradient Boosting* (e variações, como *Extreme Gradient Boosting*) para regressão e classificação de criptomoedas com modelos de *Machine Learning* (KALACHEVA et al., 2024; YAREMUS et al., 2025). Esse método consiste na união de múltiplos modelos mais fracos para a obtenção de um modelo mais robusto, que possa ter vantagens de todos os seus componentes. O método pode ser aplicado tanto para a união de dados de troca de uma determinada criptomoeda em diferentes corretores de criptomoedas, quanto para o uso conjunto de modelos e definições distintas de identificação do golpe de *rug pull* em si. O uso de técnicas de *Gradient Boosting* com dados de duas *exchanges* e duas definições de *rug pull* mostrou-se promissor nesses casos, resultando em valores F_1 entre 80% e 89%. Detectores mais robustos (MAZORRA; ADAN; DAZA, 2022) conseguem, em um escopo menor, ao equilibrar três tipos de detecção de *rug pull*, chegar a valores F_1 entre 94% e 96% para previsões de um dado corretor de criptomoedas.

Com a integração crescente entre investimentos em criptomoedas e projetos com comunicações e atualizações realizadas por grupos de aplicativos como Telegram (particularmente comum no caso de *memecoins*), também cresce o investimento em detecções automatizadas de golpes que levem em consideração essas informações na análise de risco realizada (BOLZ et al., 2024). Dessa forma, dados diários de troca e precificação

em *exchanges*, análises de risco e auditoria de *scanners* (COINMARKETCAP, c. 2025a; QUILLAI NETWORK, c. 2025) e o histórico de mensagens de grupos oficiais dos projetos associados às criptomoedas são considerados na *pipeline* de avaliação de risco. A avaliação passa a depender da categorização e identificação apropriada de intenção e sentimento nas mensagens enviadas, com resultados altamente dependentes do tratamento dos dados e do momento da análise, com acurácia variando entre 40% e 70% meia hora antes de eventos de *pump*.

Dado o maior interesse na detecção automatizada de golpes e aplicação de soluções utilizando técnicas de inteligência artificial para classificação de ativos, existe uma necessidade crescente de fontes de dados unificadas e rotuladas, principalmente no que tange a confiabilidade das moedas, e quais podem ser amplamente categorizadas como *rug pulls* ou não. Para a agregação de tokens suspeitos, a base de dados *Solana Rug Pull Dataset* (SolRPDS) apresenta uma listagem de 62.895 *pools* de liquidez suspeitas e 22.195 tokens com padrões de *rug pull* através da análise de 3.69 bilhões de transações na blockchain Solana entre os anos de 2021 e 2024 (ALHAIDARI et al., 2025). Cada *pool* e token é listado como ativo ou inativo, incluindo as diferentes métricas usadas para a estipulação de risco de *soft* ou *hard rug pull*.

Diferentes análises comparativas foram realizadas entre Modelos de Linguagem (*Language Models*, ou LMs) para identificar e distinguir seus desempenhos em Análise de Sentimento Baseada em Aspectos (ABSA), aplicada frequentemente para fins acadêmicos (ZHOU et al., 2024; LIU et al., 2025). Os resultados dos testes auxiliam na escolha apropriada de um LM para a análise de sentimento durante a *pipeline* de avaliação de risco para criptomoedas, considerando o contexto de utilização (comunicação formal, na forma de notícias, e comunicação informal, na forma de *tweets*). Também pode haver uma preferência por modelos construídos com bases que obtiveram bom desempenho, mas com treinamento direcionado para linguagem referente à troca de criptomoedas (NGUYEN; VU; NGUYEN, 2020). Além disso, alguns dos modelos utilizados como base não possuem a capacidade de classificação textual integrada, o que pode tornar necessário o uso de modelos e bibliotecas auxiliares que façam uso desses modelos para implementar a capacidade de análise de sentimentos propriamente dita (PEREZ et al., 2024; JIANG et al., 2024). A forma como instruções são preparadas para modelos de linguagem também altera o resultado consideravelmente, e diferentes modelos foram elaborados para a prática de engenharia de *prompts*, como o *framework Prompt Canvas* (HEWING; LEINHOS, 2024), usado regularmente em aplicações científicas e provas de conceito.

3 Método do trabalho

A ilustração apresenta a sequência que será seguida para a realização do projeto.




Figura 3 – Sequência de tarefas para a realização do projeto.

1. **Concepção:** Definição do problema, objetivos e justificativa do uso de para detectar golpes de "*rug pull*". Inclui a identificação de dados relevantes.
2. **Busca por projetos semelhantes:** Pesquisa de trabalhos acadêmicos, artigos e modelos de machine learning já utilizados na detecção de fraudes em criptomoedas e análise de sentimentos. Isso ajuda a identificar metodologias eficazes e evitar problemas já enfrentados por outros.
3. **Elaboração de requisitos:** Definição dos requisitos funcionais e não funcionais do modelo, como informações e análises esperadas, precisão esperada, velocidade de processamento e atraso de sincronização com APIs de dados de mercado, redes sociais e redes de notícias.
4. **Elaboração de macro-arquitetura:** Desenho da arquitetura do sistema, incluindo a escolha do(s) framework(s) de machine learning, pipeline de pré-processamento e módulos para análise de sentimentos.
5. **Implementação:** Desenvolvimento do código-fonte, treinamento do modelo de IA com dados históricos.
6. **Validação e Verificação:** Avaliação do desempenho do modelo em dados de teste. Ajuste de hiperparâmetros e análise de possíveis vieses nos dados.
7. **Realização de testes:** Testes finais em um ambiente retroativo ou em tempo real com dados de mercado atualizados. Verificação de estabilidade, desempenho e capacidade de detectar padrões suspeitos em diferentes criptoativos.

4 Especificação de Requisitos

Esta seção descreve os requisitos funcionais e não funcionais do sistema proposto para a detecção de golpes do tipo *Rug Pull* e *Pump-and-Dump* em criptoativos, utilizando análise de sentimento, dados de mercado e informações on-chain. A especificação busca garantir que o modelo desenvolvido atenda aos objetivos de desempenho, precisão e confiabilidade definidos no escopo do projeto.

4.1 Requisitos Funcionais

Os requisitos funcionais descrevem as funções que o sistema deve executar.

- **RF01:** O sistema deve coletar dados de mercado (preço, volume e liquidez) por meio de APIs públicas.
- **RF02:** O sistema deve extrair e armazenar informações de tokens, incluindo permissões de proprietário, funções de *mint* e *freeze*, e bloqueio de liquidez.
- **RF03:** O sistema deve coletar e processar postagens de redes sociais para análise de sentimento, utilizando modelos de linguagem.
- **RF04:** O modelo deve calcular uma pontuação de risco (*Risk Score*) para cada ativo analisado, considerando as dimensões de preço, características do token e análise de sentimento.
- **RF05:** O sistema deve realizar *backtests* históricos utilizando dados de golpes já conhecidos para validação do modelo.

4.2 Requisitos Não Funcionais

Os requisitos não funcionais tratam das restrições e qualidades esperadas do sistema.

- **RNF01:** O processamento deve ser modularizado para permitir a substituição ou atualização independente dos modelos de cada dimensão (mercado, token e sentimento).
- **RNF02:** O sistema deve armazenar logs detalhados de execução e resultados, assegurando reprodutibilidade dos experimentos.

4.3 Critérios de Sucesso

O sucesso do projeto será avaliado com base nos seguintes critérios:

1. **Comparabilidade:** O modelo deve apresentar resultados comparáveis a abordagens existentes de detecção de fraudes.
2. **Interpretação:** O sistema deve fornecer explicações interpretáveis das decisões, destacando quais dimensões mais contribuíram para o risco detectado.

4.4 Validação e Testes

A validação do modelo incluirá:

- **Backtests históricos** com tokens fraudulentos e não fraudulentos.
- **Comparações de desempenho** com modelos de referência (*baseline models*).
- **Análises temporais** para verificar a capacidade do modelo em detectar padrões de risco.

5 Desenvolvimento do Trabalho

Este capítulo descreve as etapas envolvidas no desenvolvimento do sistema de detecção de golpes do tipo *Rug Pull* em criptoativos, abordando desde a coleta e pré-processamento dos dados até a integração dos modelos preditivos. O desenvolvimento segue uma abordagem *top-down*, em que as etapas de alto nível são inicialmente definidas e detalhadas progressivamente.

5.1 Tecnologias Utilizadas

Para a orquestração dos diferentes módulos de análise e inteligência artificial que compõem o sistema, foi utilizado o *framework* **AutoGen**, da Microsoft. Essa estrutura de código aberto é apropriada para a criação e implementação de sistemas com múltiplos agentes autônomos (ou para ação conjunta com usuários humanos) e escaláveis para a resolução de tarefas complexas de forma coordenada. Considerando os casos de uso específicos do sistema proposto neste trabalho, o orquestrador **Magentic-One** incluído na biblioteca Autogen foi utilizado como base para a construção do detector. Esse sistema inclui nativamente agentes para navegação na Internet, manipulação de arquivos, entrada multimodal, geração de código, uso de ferramentas, formulação de respostas estruturadas e coordenação de tarefas, além de facilitar o desenvolvimento de agentes personalizados e a inclusão de modelos locais, o que permite acelerar o desenvolvimento do projeto sem abandonar o controle granular dos passos de ação e a capacidade de análise a nível de código (FOURNEY et al., 2024).

Para a viabilização da análise de sentimento de diferentes textos referentes aos tokens a serem analisados, também é necessário ter alternativas para a disponibilização de *endpoints* locais de APIs que permitam a comunicação e o envio de *prompts* para o LM responsável pela análise de sentimento. Dada a preferência por soluções locais e gratuitas, duas ferramentas foram utilizadas em diferentes etapas do desenvolvimento:

- **LM Studio:** Uma plataforma gratuita de código fechado que lineariza o processo de pesquisar, comparar, baixar, carregar, executar localmente e servir interfaces de comunicação de diferentes LMs de forma rápida. Utilizado durante a etapa inicial de desenvolvimento do módulo de orquestração por sua interface gráfica simples, pela rapidez em descobrir e baixar modelos e pela facilidade de comunicação e aprendizado do software;
- **Ollama:** Uma ferramenta gratuita de código aberto que permite criar, compartilhar e executar LMs localmente através de uma interface de linha de comando. Tem

suporte a uma grande variedade de modelos e parâmetros de execução, principalmente para modelos populares e de código aberto. Priorizada para etapas posteriores do desenvolvimento por sua leveza, por ser de código aberto e pela integração existente através de extensões entre Ollama e AutoGen.

No que diz respeito ao sistema de avaliação e previsão da precificação do ativo, é ideal que a rede neural utilizada para detectar anomalias e padrões tenha a capacidade de observar e aprender com longas séries temporais, examinando, por exemplo, um período de precificação de até 3 meses (quando disponível). Dessa forma, a forma de análise de precificação escolhida foi um modelo **LSTM** (*Long Short Term Memory*), que permite a manutenção de uma "memória" para padrões distantes temporalmente dentro da análise de uma criptomoeda (OLAH, 2015).

Como a arquitetura do sistema integra diferentes agentes especialistas de domínio para a determinação de risco das diferentes frentes de análise do ativo com um agente geral, que possui a tarefa de coordenação e atribuição de um *score* final com base nos resultados dos outros agentes, o modelo de linguagem que atua como base dos agentes do *framework* Magentic-One deve ter a capacidade de atuar de forma generalista e específica, quando necessário. O modelo de linguagem multimodal implementado por padrão pelo Magentic-One é o modelo GPT-4o, mas levando em consideração a preferência por soluções de código aberto e locais, o modelo ideal apontado para o sistema é o **Mixtral 8x7B Instruct** (para uso liberado de acordo com a licença Apache 2.0), que conta com uma arquitetura do tipo MOE (*Mixture of Experts*, igual ao modelo Mistral 7B), viabilizando aplicações gerais e específicas no mesmo fluxo. Seu uso revelou boa compreensão de instruções e raciocínio para classificação e fornecimento de scores, assim como uma menor carga computacional ao operar somente com dados tabulares e textuais. Testes anteriores também demonstraram que o modelo Mixtral 8x7B supera modelos de uso geral como LLaMa 2B e GPT 3.5o na maioria dos casos, tanto em sua versão original quanto na instruída (JIANG et al., 2024). Por conta de limitações computacionais durante o processo de desenvolvimento do teste do sistema, outros modelos foram configurados e utilizados em conjunto com o sistema, como o modelo Mistral 7B Instruct ou GPT OSS. Durante o desenvolvimento, o modelo mais utilizado foi o **GPT OSS (20B)**, que promoveu análises consistentes e razoáveis com as informações fornecidas.

Para a criação de instruções para as LMs utilizadas no sistema, é utilizado o *framework* *Prompt Canvas* (HEWING; LEINHOS, 2024), preferido pela sua versatilidade para diferentes casos de uso e nível de especificidade variável para tarefas de diferentes patamares de importância e granularidade. A flexibilidade do modelo também permite a diferenciação de tratamento para diferentes casos atípicos e pontos de interesse na resposta do modelo de linguagem.

Para a realização da análise de sentimentos, é necessário escolher uma LM para a tarefa de classificar textos e categorizar os sentimentos positivos e negativos apresentados. Uma metodologia interessante para o uso proposto é a ABSA (*Aspect-Based Sentiment Analysis*, ou Análise de Sentimentos Baseada em Aspectos). Enquanto a análise de sentimentos tradicional permite a classificação de um texto completo como positivo, negativo ou neutro, técnicas de ABSA permitem a classificação do sentimento de um texto considerando um aspecto específico. Isso permite distinguir a positividade ou negatividade com respeito a um ativo de interesse.

Análises comparativas realizadas entre diferentes modelos de linguagem (ZHOU et al., 2024) dentro do contexto das tarefas de ABSA mostram que, com pouco ou nenhum ajuste fino, LLMs (*Large Language Models*) podem tipicamente ter desempenho comparável ou superior às SLMs (*Small Language Models*), com foco no modelo LLaMA3-8B-Instruct e suas variações (LIU et al., 2025). Outras categorias de LLMs possuem arquiteturas apropriadas para a tarefa de análise de sentimentos, como as baseadas em BERT (*Bidirectional Encoder Representations from Transformers*) e RoBERTa (*Robustly Optimized BERT Pretraining Approach*). Modelos preparados com base nestes para o propósito de análise de *tweets* em inglês em contextos informais, como BERTweet (NGUYEN; VU; NGUYEN, 2020), alcançaram boas métricas de desempenho.

Apesar da existência de modelos treinados especificamente para a análise de sentimento em contextos relacionados ao mercado de criptomoedas, muitos deles não foram testados extensivamente e incluídos em outros projetos. Dado esse panorama, o modelo **BERTweet** foi considerado como a melhor escolha para a análise de sentimentos das fontes do sistema de detecção de *rug pull*.

Como o BERTweet não possui nativamente a capacidade de análise de sentimento textual, foi selecionada a ferramenta *pysentimiento* (PEREZ et al., 2024), que disponibiliza funções para *opinion mining* e tarefas de processamento natural de linguagem de textos em inglês, espanhol, italiano e português, como análise de sentimento, análise de emoção, detecção de ironia e detecção de discurso de ódio. A ferramenta utiliza como base o modelo BERTweet, com treinamento e ajuste fino para análise de sentimentos para textos em inglês, e apresenta desempenho comparável ao de outras ferramentas para análise de sentimentos, como TweetNLP, Stanza, Flair, TextBlob e o algoritmo VADER.

Para o versionamento do sistema principal e da interface do sistema, foi utilizado o Git, com hospedagem de código-fonte no Github. Os resultados do desenvolvimento foram disponibilizados em repositórios públicos do Github, especificados na interface do sistema (LUI; MOTA; TAI, 2025).

Finalmente, para a implementação da interface do sistema, foi utilizado o *framework* Flask, que voltado para o desenvolvimento web leve, flexível e veloz em conjunto com a linguagem Python (que foi amplamente utilizada para o processamento de dados de

diferentes módulos do sistema), permitindo a estruturação rápida de uma página web pela qual o sistema pode ser acessado.

5.2 Projeto e Implementação

O processo operacional do sistema proposto pode ser dividido em quatro etapas:

1. **Coleta e Integração de Dados:** obtenção de dados, incluindo históricos de preços e volume, metadados de tokens e publicações em redes sociais ou sites de notícias.
2. **Pré-processamento e Extração de Características:** tratamento e transformação dos dados em atributos representativos (*features*) para cada dimensão de análise: temporal, técnica e social.
3. **Treinamento de Modelos Individuais:** construção de modelos especializados para cada dimensão, utilizando algoritmos distintos conforme a natureza dos dados.
4. **Fusão e Integração dos Resultados:** combinação dos resultados provenientes dos modelos individuais por meio da metodologia de *Late Fusion*.

5.3 Metodologia de Fusão de Modelos

O sistema proposto baseia-se em um modelo híbrido, no qual três submodelos independentes analisam dimensões distintas do comportamento de um ativo:

- **Modelo de Mercado** - responsável pela análise de séries temporais de preços, volume e liquidez;
- **Modelo On-Chain** - avalia características técnicas e de governança dos tokens;
- **Modelo de Sentimento** - analisa a opinião pública e o comportamento social em redes.

A combinação dos resultados desses modelos é realizada por meio da estratégia denominada *Late Fusion*, que consiste em integrar as saídas probabilísticas de cada modelo em um estágio posterior à inferência individual, preservando a especialização de cada submodelo.

5.3.1 Descrição da Estratégia *Late Fusion*

Na estratégia *Late Fusion*, cada modelo especializado produz um escore de probabilidade associado ao risco de *Rug Pull*, representado por S_p , S_c e S_s , correspondendo

respectivamente às dimensões de preço, token e sentimento. Esses *scores* são combinados em uma etapa posterior de fusão, segundo a Equação 5.1:

$$\text{RiskScore} = w_p \cdot S_p + w_c \cdot S_c + w_s \cdot S_s \quad (5.1)$$

onde w_p , w_c e w_s são os pesos associados a cada dimensão, tais que:

$$w_p + w_c + w_s = 1$$

Essa abordagem permite calibrar a influência relativa de cada tipo de informação de acordo com sua relevância empírica nos resultados. Os pesos podem ser definidos de duas formas principais:

1. **Pesos Fixos:** valores determinados a priori, com base em análises exploratórias ou evidências teóricas. Por exemplo, atribuir maior peso ao modelo de tokens, visto que aspectos técnicos de governança tendem a ser determinantes em esquemas de fraude.
2. **Pesos Aprendidos por Metamodelo:** nesse caso, um *meta-classificador* (como *XGBoost*, *LightGBM* ou regressão logística) é treinado utilizando as saídas dos modelos individuais como entradas, aprendendo automaticamente as ponderações ideais.

Dessa forma, a abordagem *Late Fusion* neste trabalho baseia-se em três fatores principais:

1. **Modularidade e Independência:** cada submodelo pode ser desenvolvido, treinado e avaliado de forma isolada, facilitando a substituição ou atualização de componentes sem necessidade de reprocessar todo o sistema.
2. **Interpretabilidade:** a ponderação explícita dos *scores* individuais permite compreender a contribuição relativa de cada dimensão (mercado, token e sentimento) para o risco total, conferindo maior interpretabilidade.
3. **Eficiência e Robustez:** a fusão posterior exige menos recursos computacionais e oferece maior estabilidade frente a falhas ou ausência de dados em uma das dimensões, característica importante no ambiente dinâmico das criptomoedas.

Portanto, a metodologia de fusão adotada equilibra complexidade, interpretabilidade e desempenho, constituindo uma solução adequada tanto sob o ponto de vista técnico quanto científico.

5.4 Modelo de Classificação On-Chain com XGBoost Probabilístico

A dimensão técnica do sistema proposto tem como objetivo analisar tokens SPL na blockchain Solana, identificando estruturas, permissões e comportamentos associados a riscos de fraude, em especial golpes do tipo *Rug Pull*. Dado que tokens SPL não são contratos inteligentes independentes, mas instâncias do programa nativo *SPL Token Program*, o risco on-chain manifesta-se principalmente por meio das *authorities* associadas ao token e pelo comportamento da liquidez em pools de AMM, como Orca e Raydium. Esta seção descreve o modelo supervisionado adotado para a tarefa, fundamentado no algoritmo *Extreme Gradient Boosting* (XGBoost), bem como sua motivação, formulação e integração ao modelo híbrido.

5.4.1 Contexto e Motivação

Tokens SPL possuem propriedades fundamentais que determinam sua segurança e governança, incluindo:

- **Mint Authority:** endereço capaz de emitir novos tokens;
- **Freeze Authority:** endereço com permissão para congelar contas;
- **Update Authority:** agente capaz de alterar metadados (nome, URI, imagem) via padrão Metaplex;
- **Distribuição inicial de liquidez:** criação e remoção de pools em AMMs, bem como concentração de LP tokens.

Em ataques comuns na Solana, como documentado em RugCheck e SolSniffer, é frequente observar:

- Mint Authority não revogada, permitindo criação arbitrária de tokens;
- Freeze Authority ativa e concentrada no criador;
- Update Authority centralizada, permitindo modificações enganosas nos metadados;
- Remoção rápida de liquidez em AMMs (*liquidity rug*);
- Concentração de LP tokens em poucas contas controladas pelo criador;
- Pools de liquidez criados com valores mínimos e retirados logo após a listagem.

Além disso, também estão sendo utilizados como dados relevantes:

- Tempo de inatividade do token: Obtido através do carimbo de tempo da última transação do bloco confirmado mais recente;
- Presença na Solana Rug Pull Dataset: Permite o uso da base de dados como uma lista selecionada de tokens associados com comportamentos suspeitos.

Todos esses atributos são quantificáveis e podem ser tratados como variáveis numéricas, booleanas ou categóricas, formando um conjunto de dados tabular adequado para modelos supervisionados baseados em árvores de decisão e técnicas de *gradient boosting*.

5.4.2 Abordagem Baseada em XGBoost

O XGBoost é um algoritmo baseado em *Gradient Boosting* que constrói iterativamente um conjunto de árvores de decisão rasas, cada uma corrigindo os erros residuais da anterior. A atualização do modelo segue:

$$\hat{y}_t = \hat{y}_{t-1} + \eta f_t(x), \quad (5.2)$$

onde η é a taxa de aprendizado, e f_t representa a árvore adicionada na iteração t . A função de perda geral é dada por:

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{t=1}^T \Omega(f_t), \quad (5.3)$$

em que ℓ é a perda logística e Ω incorpora regularização para evitar sobreajuste. Para classificação binária com saída probabilística, o modelo estima:

$$S_c = P(\text{fraude} \mid X_{\text{on-chain}}), \quad (5.4)$$

com $S_c \in [0, 1]$ representando o grau de suspeita técnica do token.

A adoção do XGBoost é motivada por sua alta capacidade discriminativa em dados tabulares e baixa sensibilidade à escala dos atributos.(CHEN; GUESTRIN, 2016)

5.4.3 Comparativo entre XGBoost e Random Forest

Tanto o *Random Forest* quanto o XGBoost são algoritmos amplamente utilizados em tarefas de classificação supervisionada baseadas em árvores. O Random Forest utiliza árvores independentes construídas por *bagging*, oferecendo robustez e menor risco de sobreajuste sem grande necessidade de ajuste fino.(BREIMAN, 2001) Entretanto, em

problemas estruturados e tabulares, métodos de *gradient boosting* como XGBoost tendem a apresentar desempenho superior.(CHEN; GUESTRIN, 2016)

No contexto específico de análise on-chain na Solana, em que variáveis como `has_mint_authority`, `freeze_authority_revoked`, `lp_creator_ratio` e `metadata_update_pattern` apresentam interações não lineares, o XGBoost se mostra particularmente adequado. Sua regularização explícita, eficiência computacional e compatibilidade com técnicas modernas de interpretabilidade (como SHAP) o tornam uma escolha sólida para a tarefa.

5.4.4 Treinamento e Calibração do Modelo

O modelo foi treinado sobre um conjunto de tokens rotulados em duas classes:

- **0 — Não Suspeito:** tokens com autoridades revogadas, pools estáveis e distribuição legítima.
- **1 — Suspeito:** tokens presentes em listas de golpes ou exibindo padrões típicos de manipulação de autoridade e liquidez.

A saída probabilística S_c é obtida pela função sigmoide ao final do processo de boosting.

A construção do conjunto de dados utilizado para o treinamento do modelo on-chain exigiu a integração de duas fontes distintas, de natureza complementar. A primeira corresponde à *Jupiter Curated List*(Jupiter Exchange, 2025), uma lista mantida pela agregadora de liquidez Jupiter contendo tokens considerados legítimos pela comunidade, com histórico verificado de operação, liquidez estável e autoridades adequadamente revogadas. Essa lista serve como base para a classe negativa (não suspeitos). A segunda fonte é o *Solana Rug Pull Dataset* (SRPDS)(ALHAIDARI et al., 2025), que reúne tokens associados a golpes, manipulações de liquidez ou condutas suspeitas observadas, constituindo a classe positiva (suspeitos). Essa junção fornece um conjunto curado de tokens representativos tanto de comportamentos normais quanto de padrões típicos de fraude.

Dado o ecossistema da Solana, estudos independentes, como os da empresa Solidus Labs, estimam que entre 92% e 99% dos tokens recém-criados apresentam características fraudulentas ou comportamentos maliciosos(SOLIDUS LABS RESEARCH, c. 2025). Esse cenário reflete-se na composição da base utilizada: 1000 tokens classificados como suspeitos e 100 tokens legítimos. Embora essa assimetria represente fielmente a realidade do ambiente analisado, ela também impõe desafios metodológicos importantes, especialmente na avaliação de desempenho e na calibragem probabilística do modelo.

A assimetria entre as classes introduz potenciais fontes de viés que precisam ser cuidadosamente consideradas. A baixa presença de tokens legítimos na base reduz o espaço de variação da classe negativa, podendo levar o modelo a uma fronteira de decisão excessivamente estreita para distinguir entre comportamentos legítimos e fraudulentos. Além disso, a forte separabilidade das variáveis on-chain pode amplificar o risco de *feature leakage*, quando uma ou mais características do conjunto de dados revelam de forma indireta informações correlacionadas ao rótulo. Foi realizada uma análise de correlação e inspeção manual das variáveis, não sendo identificada nenhuma coluna explicitamente vinculada ao processo de rotulação. No entanto, devido ao ambiente altamente enviesado da Solana, onde tokens fraudulentos tendem a compartilhar propriedades estruturais similares, parte da separabilidade observada pode refletir características intrínsecas do ecossistema, e não necessariamente generalizabilidade universal.

Para mitigar esses riscos, foram utilizados procedimentos como estratificação no particionamento entre treino e teste, validação baseada em métricas apropriadas para bases desbalanceadas e inspeção de interpretabilidade baseada em SHAP. Esses mecanismos reduzem o risco de que o modelo aprenda padrões artificiais e melhoram sua capacidade de generalização dentro da distribuição de dados considerada.

O treinamento supervisionado foi realizado utilizando o algoritmo XGBoost, configurado para produzir uma saída probabilística associada ao risco técnico do token. Os hiperparâmetros empregados incluem `n_estimators = 400`, `learning_rate = 0.05`, `max_depth = 5`, `subsample = 0.8` e `colsample_bytree = 0.8`, além do método de construção de árvores `hist`, adequado para conjuntos de dados tabulares de média escala. A métrica de otimização utilizada foi a AUC-PR (*Average Precision*), mais apropriada para bases altamente desbalanceadas, enquanto a função objetivo adotada foi a classificação logística binária (`binary:logistic`). A divisão entre treino e teste foi realizada com estratificação, garantindo proporções similares entre as classes e reduzindo variância na estimativa de desempenho.

Além disso, a interpretação local permite analisar a contribuição individual de cada variável para um token específico. A Figura 5 apresenta um exemplo de explicação local utilizando o gráfico *waterfall*, evidenciando como determinadas variáveis podem aumentar ou reduzir o score de risco para um caso particular. Essa abordagem fornece transparência ao sistema, permitindo auditoria das decisões e entendimento granular das condições que indicam risco elevado.




Figura 4 – Importância global das variáveis do modelo XGBoost segundo o método SHAP.




Figura 5 – Exemplo de explicação local do modelo para um token específico utilizando gráfico SHAP *waterfall*.

5.4.5 Interpretação e Integração com o Modelo Híbrido

A pontuação contínua S_c integra-se naturalmente ao mecanismo de fusão tardia (*Late Fusion*), combinando-se com os demais aspectos.

Dessa forma, a dimensão técnica contribui diretamente para a composição final do risco, permitindo ponderação e normalização consistentes entre as modalidades do sistema.

O desempenho será avaliado por métricas de classificação (acurácia, precisão, *recall*, *F1-score*) e pela métrica *AUC-ROC*, crucial para mensurar a capacidade discriminativa do

modelo.

5.5 Precificação Histórica de Ativos

A precificação histórica de um ativo corresponde ao registro e à análise dos valores pelos quais esse ativo foi negociado ao longo do tempo. Esse tipo de estudo permite compreender a dinâmica de mercado e fornece subsídios para decisões estratégicas de investimento, avaliação de desempenho e determinação de valor justo. Em ambientes digitais, especialmente no contexto de criptoativos e tokens, a análise histórica adquire relevância ainda maior, dado o caráter descentralizado e volátil desses mercados.

No caso de tokens digitais, o valor de mercado pode ser estabelecido segundo dois modelos principais de formação de preço:

1. **Preço fixado pelo emissor:** o valor do token é determinado diretamente pela entidade emissora, sem influência imediata de fatores externos de mercado. Esse modelo é comum em fases iniciais de lançamento, como em *Initial Coin Offerings* (ICO), em que o emissor define um preço base por unidade para captação de recursos. Nesses casos, o preço representa uma convenção contratual e reflete, em geral, o valor estimado do projeto subjacente, não necessariamente o valor de mercado resultante da negociação entre agentes. Essa modalidade também pode ocorrer em tokens de utilidade ou tokens lastreados, como *stablecoins*, cuja paridade com uma moeda fiduciária é mantida de forma fixa.
2. **Preço flutuante:** após o token passar a ser negociado em mercados secundários ou *exchanges*, seu preço torna-se dinâmico, variando conforme a interação entre oferta e demanda. O valor é ajustado continuamente de acordo com o volume de negociações e o comportamento dos agentes de mercado. Nesse cenário, o preço reflete a percepção de valor dos participantes e pode ser influenciado por fatores como liquidez, sentimento de mercado, volume negociado, eventos regulatórios e oscilações de outros ativos correlacionados. Esse modelo é o que prevalece nos ambientes de livre negociação e constitui a base para análises de volatilidade e risco.

A análise da precificação histórica, portanto, não se limita à observação de valores absolutos, mas também envolve o estudo da evolução temporal desses preços e de suas variações relativas. A partir do histórico, é possível calcular indicadores estatísticos, como médias móveis, desvios-padrão, volatilidade implícita e correlações com outros ativos. Essas métricas auxiliam tanto na compreensão macroeconômica do comportamento do ativo quanto em decisões operacionais, como o momento de compra, venda ou retenção de tokens. Em contextos de finanças descentralizadas (DeFi), tais análises são utilizadas ainda

para ajustar algoritmos de *market making* automatizado, definir estratégias de arbitragem e otimizar carteiras digitais.

A precificação histórica, portanto, constitui uma ferramenta essencial para a avaliação da eficiência de mercado e da maturidade de um token. Um histórico consistente e transparente de preços é um dos principais fatores que contribuem para a credibilidade e aceitação de um ativo digital, pois permite aos investidores rastrear a trajetória de valor e estimar sua resiliência frente às flutuações do mercado e seus resultados podem contribuir para a pontuação de confiabilidade e maturidade de um ativo.

5.5.1 Detecção de Anomalias em Ativos

A análise de séries temporais é aplicada à precificação de ativos utilizando a técnica LSTM (*Long Short-Term Memory*). Esta arquitetura de rede neural recorrente é projetada para identificar padrões sequenciais complexos, tornando possível não apenas a previsão de valores, mas também a detecção de anomalias, tal como grandes valorizações ou desvalorizações atípicas e que, em abordagens convencionais, poderiam ser erroneamente interpretadas como simples continuidade de tendência.

Utilizando a biblioteca **PyTorch**, uma rede foi treinada sobre vários *tokens* Solana diferentes em um *dataset* de um ano de transações durante uma quantidade determinada adequada de épocas após testes de desempenho, visando determinar com acurácia a ocorrência de anomalias a partir de uma fonte de dados estruturada e temporalmente definida. A arquitetura LSTM (OLAH, 2015) baseia-se em células de memória (*memory cells*), que compõem blocos de memória responsáveis por regular o fluxo de informação. O aprendizado ocorre através da minimização de erro, utilizando portões (*gates*) para filtrar ruídos e reter dependências de longo prazo. Esses portões utilizam camadas sigmóides para avaliar a permissividade dos dados na célula, atribuindo valores entre zero e um.

Na notação padrão, C_t representa o estado atual da célula. O mecanismo de controle de fluxo inicia-se pela porta de esquecimento (*forget gate*), que define qual parte do estado anterior (C_{t-1}) será descartada. Esta porta é definida pela equação 5.5:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (5.5)$$

Neste contexto, um valor de f_t próximo de 0 indica que a informação será esquecida, enquanto um valor próximo de 1 indica que será mantida. Sequencialmente, processam-se as informações de entrada e a atualização do estado candidato, conforme expresso em 5.6, e o cálculo da saída em 5.8 e 5.7:

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (5.6)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (5.7)$$

$$h_t = o_t * \tanh(C_t) \quad (5.8)$$

A interação entre estes componentes permite à arquitetura "aprender" o que esquecer e o que armazenar, otimizando a análise temporal. O detector, após o treinamento, busca minimizar o erro quadrático médio (RMSE) para identificar variações significativas na precificação. Quando os dados são extraídos via API com um volume considerável de *datapoints*, movimentos bruscos de alta ou queda podem ser isolados.

A detecção de anomalia propriamente dita é realizada através da definição de um limiar (*threshold*) baseado na regra dos três sigmas. Se a diferença entre o valor previsto e o real (ou o erro de reconstrução) ultrapassar o limiar T definido em 5.9, há um forte indício de anomalia. Estatisticamente, tal evento estaria fora do intervalo que compreende 99,7% dos casos em uma distribuição normal.

$$T = \mu + 3 \cdot \sigma \quad (5.9)$$

5.5.2 Aplicação do Detector em um Estudo de Caso

O algoritmo de detecção, após ser treinado com um *dataset* diversificado e um amplo histórico temporal, torna-se capaz de identificar variações abruptas de valor. Para exemplificar, utilizou-se o *token* Shoggoth, analisando seus últimos dois meses de atividade. Inicialmente, os preços diários foram obtidos através da API *CoinGecko*, conforme apresentado na Figura 6.




Figura 6 – Últimos 2 meses do *Token* Shoggoth




Figura 7 – Detector de Anomalia, com detecções em grandes variações, junto com seu preço e seu preço previsto junto com o volume.




Figura 8 – Distribuição residual, com valor médio e valores $3 \cdot \sigma$ acima e abaixo do valor.

A detecção é complementada pela análise da distribuição residual, que demonstra a dispersão dos pontos em relação à média e a frequência dessas ocorrências. Na Figura 8, observa-se a relação entre as anomalias, os valores nominais e os períodos destacados na Figura 7, proporcionando uma visualização clara dos riscos.

Por fim, ao processar essas informações, o Agente calcula um índice de risco baseado na densidade de anomalias e na janela temporal em que ocorrem.

5.6 Análise de Sentimentos de *Tweets*

A classificação de textos é realizada utilizando como principal ferramenta o *toolkit pysentimiento* (PEREZ et al., 2024) na linguagem Python, que tem como base para a análise de sentimentos na língua inglesa o LLM BERTweet. O modelo BERTweet (NGUYEN; VU; NGUYEN, 2020) é treinado para apresentar melhor desempenho na

criação de *tweets* e textos informais na língua inglesa, com funcionalidades acessadas da mesma forma que no modelo RoBERTa, adotado como base de desenvolvimento. A ferramenta possui funções embutidas de pré-processamento de *tweets* e tratamento de caracteres repetidos, emojis (com a biblioteca *emojis*, do Python), *links*, *hashtags* e outros elementos comuns de textos em redes sociais.

A determinação da intensidade de sentimento de cada *tweet* resulta em uma tripla, sendo seus dados as intensidades da classificação dos sentimentos do texto como um número de ponto flutuante entre 0 e 1, com polaridades possíveis POS (positivo), NEG (negativo) e NEU (neutro). O texto como um todo é classificado em um dos três grupos, dado o sentimento mais detectado.

Como os tweets são caracterizados por linguagem informal, heterogeneidade e ruído social, eles formam uma base de informações influenciada por *bots*, *influenciadores*, *shillers*, câmaras de eco de *hype* e outras técnicas de engenharia social. Isso significa que existe a necessidade de uma heurística para a ponderação do sentimento de diferentes *tweets*. A heurística utilizada para a avaliação neste projeto é uma mistura de práticas conhecidas em *social sensing*, processamento de linguagem natural em finanças e detecção de *bots*.

Durante o desenvolvimento, os custos significativos para o uso da API disponibilizada pelo site X ou alternativas consolidadoras de *tweets* e a inviabilização de técnicas de *web scraping* tornou impraticável o uso de *tweets* durante o projeto. Por esses fatores, a decisão de projeto tomada foi de realizar a análise de sentimento com coleções de publicações **simuladas** para diferentes tokens, buscando reproduzir de forma suficiente para o sistema o ambiente real de uma rede social utilizada popularmente para a divulgação e discussão de investimentos em criptomoedas.

5.6.1 Peso Agregado e Sentimento Público

Antes da análise de sentimento, é necessário realizar algumas etapas de pré-processamento. Usando as funções da biblioteca *pysentimiento*, o conteúdo de cada postagem passa por cinco etapas: a anonimização de usuários (trocando nomes de usuários por tokens distintos), o encurtamento de caracteres repetidos em sequência (permitindo no máximo duas repetições), a normalização de certos conjuntos de caracteres repetidos (como risadas), a substituição de *hashtags* por listas de palavras separadas e a substituição de *emojis* por suas palavras correspondentes. Isso permite uma análise mais consistente do contexto da publicação.

Como o *score* de sentimento do *pysentimiento* é uma tripla de probabilidades de classificação do texto como NEU, POS ou NEG (p_{neu} , p_{neg} e p_{pos}), o *sentimento* de um *tweet* x_i é definido como um valor entre 0 e 1, com valores próximos de 0 denotando emoções negativas, valores próximos de 1 denotando emoções positivas, e valores próximos

de 0.5 indicando neutralidade. O cálculo é realizado através das equações 5.10 e 5.11:

$$p_{neu}(x_i) + p_{neg}(x_i) + p_{pos}(x_i) = 1 \quad (5.10)$$

$$s(x_i) = s_i = \frac{(p_{pos}(x_i) - p_{neg}(x_i)) + 1}{2} \quad (5.11)$$

A intensidade I_i de um tweet x_i é definida pela equação 5.12:

$$I(x_i) = I_i = 1 - p_{neu}(x_i) = p_{pos}(x_i) + p_{neg}(x_i) \quad (5.12)$$

O peso w_i que um tweet x_i tem para a análise de sentimento como um todo é determinado pela equação 5.13:

$$w(x_i) = w_i = w_{usr}(x_i) \cdot w_{time}(x_i) \cdot w_{cred}(x_i) \quad (5.13)$$

Por padrão, todos os componentes do peso possuem valor 1, antes de análises para detecção de contas suspeitas ou repetitivas. Os pesos de usuário e tempo podem sofrer penalidades, se aproximando de 0, enquanto o peso de credibilidade pode ser 0, ou qualquer valor maior que 1 (na prática, mesmo os *tweets* mais curtidos e repostados de todos os tempos levam o peso de credibilidade a um valor próximo de 7, no máximo).

w_{usr} é o peso atribuído ao tweet pelo comportamento do usuário. Para identificar e reduzir o impacto de contas suspeitas ou repetitivas, como *bots* e *shills*, as táticas implementadas são:

- **Frequência de publicação:** Se o mesmo usuário posta mais que um certo número vezes durante uma certa janela de tempo, isso pode indicar um impulso suspeito de engajamento e FOMO. Neste caso, foi definido que uma frequência de postagens $f \geq 5$ postagens/hora leva a uma dedução do peso tal que $w_{usr,novo}(x_i) = \frac{w_{usr,antigo}(x_i)}{f}$;
- **Recência e seguidores:** Postagens realizadas por contas com menos de 15 dias de existência ou com menos de 50 seguidores levam uma dedução de peso tal que $w_{usr,novo}(x_i) = \frac{w_{usr,antigo}(x_i)}{2}$ para cada um dos casos.

A probabilidade de uma conta ser ilegítima p_{bot} é calculada como:

$$p_{bot}(x_i) = 1 - w_{usr}(x_i) \quad (5.14)$$

Por padrão, contas com $p_{bot} > 0.7$ são consideradas como sendo suspeitas, ou seja, se uma conta passa do limite de frequência de publicação ou apresenta simultaneamente

idade abaixo do limite de confiança e poucos seguidores, ela é considerada como uma origem suspeita de sentimento na análise.

w_{time} é o peso atribuído ao tweet por sua relevância temporal. Tweets mais recentes devem ser mais considerados para a determinação do sentimento popular, pois postagens defasadas são menos informativas para eventos de manipulação. Como nem sempre é possível ter um fluxo frequente de novas postagens para todas as moedas, o tempo de referência para o decaimento será o momento da postagem mais recente considerada para a análise de sentimento do token, τ_{ref} . Sendo o tempo contado em horas e τ_i o momento de publicação da postagem a ser analisada, o decaimento temporal do peso é determinado pela equação 5.15.

$$w_{time}(x_i) = e^{-0.17(\tau_{ref}-\tau_i)} \quad (5.15)$$

A determinação do parâmetro $\lambda = 0.17$ para o decaimento temporal foi motivada para que um *tweet* postado 12 horas antes do *tweet* mais recente fosse considerado com aproximadamente 10% do peso do mais recente, e para que uma publicação realizada 4 horas antes da mais recente fosse considerada com aproximadamente 50% do peso do mais recente.




Figura 9 – Gráfico do decaimento temporal do peso que uma postagem tem para uma análise de sentimentos atualizada em função das horas desde sua postagem.

w_{cred} é o peso atribuído baseado na credibilidade do usuário, ou seja, das métricas de reputação, influência e engajamento relacionadas a sua conta. *Tweets* virais ou publicados

por contas de grande alcance devem ser considerados com maior peso, mas não de forma a distorcer a análise da opinião pública. Assim, os índices utilizados são:

- **Contas influentes:** Publicações realizadas por contas com um grande número de seguidores, n_{flw} , devem ser consideradas com maior peso, pela ampliação na capacidade de engajamento;
- **Publicações influentes:** Publicações com uma grande quantidade de curtidas e republicações, n_{likes} e n_{rts} , respectivamente, devem ser consideradas como mais importantes para a análise de sentimento.

O cálculo do peso de credibilidade é realizado conforme a equação 5.16:

$$w_{cred}(x_i) = \log_{10}(1 + n_{likes} + 2 \cdot n_{rts} + 0.18 \cdot n_{flw}) \quad (5.16)$$

A escolha dos parâmetros foi feita para que postagens sem interações de contas com 50 seguidores sejam consideradas com o peso padrão (e por coerência com o patamar de seguidores estabelecido no cálculo de w_{usr}), e que postagens sem interações feitas por contas com nenhum seguidor tenham o seu peso de credibilidade desconsiderado (e consequentemente, a postagem não é considerada na análise de sentimentos).

Finalmente, o **score/pontuação de sentimento agregado do token** é calculado, fornecendo um índice entre 0% e 100% para a positividade acerca do *token* para um dado conjunto de *tweets*, como na equação 5.17:

$$S_s = \frac{\sum_i w_i \cdot s_i}{\sum_i w_i} \cdot 100\% \quad (5.17)$$

Após o cálculo da pontuação de sentimento agregado para um token, alguns indicadores também são retornados, de forma a auxiliar a determinação do peso do *score* de sentimento na avaliação do risco total da criptomoeda. Os indicadores retornados são $F_{postagens}$, que indica o número de postagens usadas como base para a análise de sentimentos (sendo $F_{postagens} \leq 10$ considerado baixo), F_{tempo} , que indica a idade média das postagens usadas para a análise de sentimento, permitindo a identificação de defasagens na análise (se o valor passa de um certo limite estabelecido, sendo este 10 horas para esse sistema), e $F_{intensidade}$, que indica a intensidade média para todos as postagens analisadas. Esses indicadores ajudam a determinar o peso da análise de sentimentos para a detecção de *rug pull* como um todo, e podem diminuir a dependência de resultados incertos durante a etapa de *Late Fusion*.

5.6.2 Geração e Organização de *Tweets*

Levando em consideração os custos significativos para o uso da API disponibilizada pelo site X e alternativas consolidadoras de *tweets*, as coleções de publicações utilizadas para análise de sentimento de diferentes tokens são **simuladas**. Uma quantidade de usuários, *tweets* e características relevantes para a análise de sentimentos são gerados, e então selecionados aleatoriamente para montar uma representação das comunicações reais que poderiam ser utilizadas para a análise de sentimentos. Para facilitar a reprodutibilidade, diferentes bases simuladas de usuários e postagens podem ser salvas e associadas a nomes e símbolos específicos de criptomoedas que possam servir de referência para a análise dos resultados (como, por exemplo, ter diferentes bases com usuários, postagens e *score* de sentimento agregado conhecidos, para identificar a correlação da análise de sentimento com o risco estipulado de um token confirmado como fraudulento). Essas bases, assim como o *dataframe* que estabelece a relação entre bases e criptomoedas para simulações, são armazenadas no formato PKL, que oferece maior escalabilidade e velocidade que formatos como CSV ou JSON.

Diferentes distribuições de probabilidades para diferentes tipos de mensagens também provocam alterações na geração de usuários, de forma a reproduzir fielmente um ambiente de comunicação virtual. Especificamente, a seleção das distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO provocam uma diminuição na idade média dos *tweets* e um aumento na variabilidade do número de seguidores do usuário, da idade da conta e da frequência de postagem (simulando o comportamento de *bots*).

A geração de dados para análise de sentimento é feita da seguinte forma:

- **Geração de Usuários Sintéticos:** Uma quantidade de usuários $q_{usuarios}$ aleatória é gerada sinteticamente através de uma distribuição log-normal, com parâmetros de média normalizada $\mu_{usuarios} = 6.17$ e desvio padrão normalizado $\sigma_{usuarios} = 0.30$. Isso significa que uma média de 500 usuários é gerada, com desvio padrão de 154 usuários e 99% das bases tendo até 960 usuários. O máximo de usuários é 1000, e uma probabilidade fixa (0.1%) de geração de bases com até 10 usuários (com distribuição uniforme de mínimo 1 e máximo 10, para testes com poucos usuários). O número de seguidores de cada usuário é gerado aleatoriamente usando a distribuição log-normal com parâmetros $\mu_{seguidores} = 3.5$ e $\sigma_{usuarios} = 1$, indicando uma média de 55 seguidores por usuário, com desvio padrão de 72 seguidores e 99% dos usuários tendo até 340 seguidores. Existe uma probabilidade fixa (0.1%) de geração de usuários que tenham entre 10000 e 300000000 seguidores (com distribuição uniforme de mínimo 10000 e máximo 300000000, para testes com poucas contas muito influentes e muitas contas pouco influentes). A determinação da idade de cada conta em dias é uma

variável escolhida por distribuição exponencial de parâmetro $\lambda_{idade} = \frac{1}{365}$, indicando uma idade média de conta de 365 dias e uma probabilidade de 4% de uma conta ter menos de 15 dias de idade. O número de postagens que cada usuário faz por hora é determinado por uma distribuição exponencial de parâmetro $\lambda_{posts} = 0.6$, indicando uma média de 1,67 postagens/hora com desvio padrão de 1,67 (e 95% usuários fazendo até 5 postagens/hora), e uma probabilidade fixa de (0.1%) de criar uma conta com mais de 5 postagens por hora (com distribuição uniforme de mínimo 5 e máximo 120, para teste de contas repetitivas e suspeitas).

No caso de seleção das distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO, a probabilidade fixa de geração de usuários com muitos seguidores sobe para 1%, e a distribuição log-normal segue os parâmetros $\mu_{seguidores} = 3.1$ e $\sigma_{usuarios} = 1$, (20% dos usuários terão mais que 50 seguidores). A idade das contas passa a seguir a distribuição exponencial com parâmetro $\lambda_{idade} = \frac{1}{15}$, indicando que 63% das contas terão menos que 15 dias de idade. A probabilidade de geração de contas com alta frequência de postagem aumenta para 10%, e a distribuição geral de frequência de postagem passa a seguir a distribuição exponencial de parâmetro $\lambda_{posts} = \frac{1}{5}$, indicando que 63% das contas postam menos que 5 postagens por hora;

- **Geração de *Tweets* Sintéticos:** Cada *tweet* gerado é atribuído como sendo postado por um usuário aleatório do conjunto de usuários sintéticos criados na etapa anterior. A quantidade de *tweets* gerados é determinada aleatoriamente por uma distribuição de Poisson de média igual à $\mu_{postagens} = n_{usuarios}$ (máximo de 2000 postagens, com média de 500 postagens, igual ao número de usuários médio), e uma probabilidade fixa (0.1%) de geração de uma base com um máximo de 10 postagens (com distribuição uniforme de mínimo 1 e máximo 10, para testes com poucas postagens). A idade de cada postagem é atribuída aleatoriamente por uma distribuição log-normal com parâmetros $\mu_{idade} = 1.163$ e $\sigma_{idade} = 0.668$, indicando uma média de idade de 4 horas para cada postagem, com desvio padrão de 3 horas e 99% das postagens analisadas sendo feita até 15 horas atrás. A quantidade de curtidas que a postagem recebeu é determinada aleatoriamente por uma distribuição de Poisson de média igual à $\mu_{curtidas} = \frac{n_{seguidores}}{200}$. A quantidade de republicações que a postagem recebeu é determinada aleatoriamente por uma distribuição de Poisson de média igual à $\mu_{curtidas} = \frac{n_{seguidores}}{500}$. O conteúdo dos *tweets* sintéticos é gerado por uma combinação de 40 modelos de *tweets* divididos em 4 diferentes contextos, como postagens promocionais da criptomoeda (com sentimento médio de aproximadamente 80% de positividade e intensidade média de 63%), postagens informativas (com sentimento médio de aproximadamente 65% e intensidade de 21%), postagens que buscam provocar FOMO (*Fear of Missing Out*, com sentimento médio de aproximadamente 45% e intensidade de 42%) e postagens que demonstram pânico

com uma posição desfavorável do token (com sentimento médio de aproximadamente 15% e intensidade de 70%). Para a simulação de diferentes ambientes para diferentes tokens, a distribuição de geração pode ser alterada para cada uma das classificações e seus respectivos modelos de *tweets*, modificando também a proporção de usuários gerados como pouco críveis. Uma proporção tomada como razoável para um token genuíno é de 20% de postagens promocionais, 50% de postagens informativas, 10% de postagens em pânico e 20% de postagens incitadoras de FOMO, enquanto uma proporção tomada como referência para ativos fraudulentos é de 50% de postagens promocionais, 10% de postagens informativas, 20% de postagens de postagens em pânico e 20% de postagens incitadoras de FOMO.

No caso de seleção das distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO, a idade média das postagens passa a seguir uma distribuição log-normal de parâmetros $\mu_{idade} = 0.1$ e $\sigma_{idade} = 1$, indicando que as postagens têm uma média de 1,8 horas e que 10% das postagens passam da idade de 4 horas.




Figura 10 – Gráfico da distribuição de probabilidade para a quantidade de usuários gerados para uma base de postagens simulada.




Figura 11 – Gráfico da distribuição de probabilidade para a quantidade de seguidores determinada para cada usuário para uma base de postagens simulada.




Figura 12 – Gráfico da distribuição de probabilidade para a quantidade de seguidores determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.




Figura 13 – Gráfico da distribuição de probabilidade para a idade da conta determinada para cada usuário para uma base de postagens simulada.




Figura 14 – Gráfico da distribuição de probabilidade para a idade da conta determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.




Figura 15 – Gráfico da distribuição de probabilidade para a frequência de postagens por hora determinada para cada usuário para uma base de postagens simulada.




Figura 16 – Gráfico da distribuição de probabilidade para a frequência de postagens por hora determinada para cada usuário para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.




Figura 17 – Gráfico da distribuição de probabilidade para a idade das postagens para uma base de postagens simulada.




Figura 18 – Gráfico da distribuição de probabilidade para a idade das postagens para uma base de postagens simulada, com distribuições de mensagens focadas em mensagens suspeitas, promocionais ou geradoras de FOMO.




Figura 19 – Gráfico da distribuição de probabilidade para a quantidade de postagens criadas para uma base de postagens simulada, no caso médio de 500 usuários simulados gerados.

5.7 Resultados

Os resultados para cada seção e para o agente integrador estão listados aqui:

5.7.1 Seção On-Chain

Os resultados obtidos pelo modelo XGBoost na tarefa de classificação on-chain são apresentados na Tabela 5.7.1, incluindo as métricas de desempenho mais adequadas para bases desbalanceadas, como AUC-PR.

Métrica	Valor
AUC-ROC	0,9955
AUC-PR	0,9996
Acurácia	0,98
Precisão (classe legítima)	0,90
<i>Recall</i> (classe legítima)	0,90
<i>F1-score</i> (classe legítima)	0,90
Precisão (classe fraudulenta)	0,99
<i>Recall</i> (classe fraudulenta)	0,99
<i>F1-score</i> (classe fraudulenta)	0,99

Tabela 1 – Métricas de desempenho do modelo XGBoost na classificação on-chain.

A matriz de confusão correspondente encontra-se na Tabela 5.7.1, destacando o número de classificações corretas e incorretas para cada classe.

	Predito: Legítimo (0)	Predito: Fraudulento (1)
Real: Legítimo (0)	18	2
Real: Fraudulento (1)	2	199

Tabela 2 – Matriz de confusão do modelo XGBoost aplicada ao conjunto de teste.

Os resultados indicam que o modelo apresenta excelente capacidade discriminativa para a tarefa, alcançando AUC-ROC de 0,9955 e AUC-PR de 0,9996, valores indicativos de boa separabilidade entre tokens legítimos e suspeitos. Em particular, o desempenho na classe majoritária (fraudulenta) alcança *precision*, *recall* e *F1-score* iguais a 0,99, evidenciando que o modelo raramente classifica erroneamente um token fraudulento como legítimo. A classe minoritária, composta por apenas 20 amostras no conjunto de teste, também apresenta desempenho satisfatório, com precisão e *recall* iguais a 0,90, demonstrando que o classificador preserva boa capacidade de identificação de tokens legítimos mesmo com forte desbalanceamento da base. A matriz de confusão confirma esse comportamento, com apenas dois falsos negativos e dois falsos positivos em 221 amostras totais.

Apesar dos resultados elevados, é necessário considerar criticamente possíveis fontes de viés e sobreajuste. A base de dados apresenta forte assimetria entre classes, refletindo o ecossistema real da Solana, no qual a maior parte dos tokens recém-criados apresenta comportamento fraudulento (SOLIDUS LABS RESEARCH, c. 2025). No entanto, essa assimetria reduz substancialmente a variabilidade da classe legítima, aumentando o risco de que o modelo aprenda fronteiras excessivamente estreitas e pouco generalizáveis. Além disso, investigou-se a possibilidade de *feature leakage*, uma vez que variáveis fortemente correlacionadas com o rótulo podem carregar informação indireta sobre a afiliação do token à base de golpes.

Variável	Correlação com <code>is_rugpull</code>
<code>mutable</code>	-0,008
<code>has_mint_authority</code>	-0,011
<code>supply</code>	0,016
<code>has_freeze_authority</code>	0,078
<code>idle_time_mins</code>	0,238
<code>top_3_percent</code>	0,574
<code>top_10_percent</code>	0,613

Tabela 3 – Correlação de Pearson entre atributos on-chain e o rótulo `is_rugpull`.

A Tabela 5.7.1 apresenta a correlação de Pearson entre cada atributo on-chain e o rótulo `is_rugpull`. Observa-se que nenhuma variável apresenta correlação perfeita ou extremamente elevada com o rótulo, o que sugere ausência de *feature leakage* direto no conjunto de dados. As correlações mais altas concentram-se nas variáveis `top_10_percent` (0,61) e `top_3_percent` (0,57), comportamento esperado, pois tokens fraudulentos tendem a exibir distribuição inicial altamente concentrada e picos artificiais de preço. Já atributos estruturais como `mutable`, `has_mint_authority` e `supply` apresentam correlação praticamente nula, reforçando que o modelo não depende de marcadores triviais ou sinalizadores artificiais de fraude. A distribuição moderada das correlações indica que as variáveis aportam informação complementar e plausível do ponto de vista analítico, fortalecendo a interpretação de que o desempenho elevado do modelo decorre de padrões genuínos da base e não de contaminação acidental do rótulo.

Do ponto de vista de sobreajuste, a elevada AUC-PR e o alto desempenho sugerem que o modelo captou padrões estruturais fortes e consistentes na base, mas também podem indicar um possível ajuste excessivo aos dados de treinamento. Técnicas mitigadoras foram empregadas, como estratificação, regularização implícita do XGBoost e análise de importância via SHAP, que demonstrou coerência entre as variáveis mais influentes e o comportamento esperado de tokens fraudulentos. Ainda assim, recomenda-se que o modelo seja reavaliado periodicamente com novas bases de dados, especialmente contendo maior diversidade de tokens legítimos, de modo a validar sua robustez em cenários futuros.

5.7.2 Seção LSTM

Para testar a Detecção de Anomalia, foi selecionada um Token com alguns sinais claros de anomalias, ou seja, variações muito além da sua média temporal. Para isto, foi selecionada a \$USX como Token para o estudo de caso de picos anômalos, estes são visíveis diante da série temporal que pode ser vista em 20.




Figura 20 – Gráfico de detecção de poucas, porém visíveis, anomalias na precificação.

E para a distribuição, pode-se analisar novamente a \$Shoggoth como Token que tem uma frequência de anomalias detectadas significativa fora da faixa $\mu \pm 3 \cdot \sigma$ como na figura 21, um comparativo do seu gráfico de precificação pode ser encontrado em 7.





Figura 21 – Distribuição residual, com uma frequência significativa abaixo de $\mu - 3 \cdot \sigma$

Neste exemplo da distribuição, foram encontradas 26 anomalias, sua pontuação fica, portanto, prejudicada, sua instabilidade recente contribui negativamente e aumenta sua possibilidade de Rug Pull no detector. Vale ressaltar que enquanto a \$USX não é listada como possível token *Rug-pull* no RPDS, a \$Shoggoth é listada, dado que a \$USX

tem muito menos anomalias e as mesmas são mais espaçadas, o risco é menor, e de fato, ao alimentar essas informações ao Agregador, o risco associado à \$Shoggoth é maior.

5.7.3 Interface Gráfica do Sistema

O *Rug Pull Detector*, para melhor experiência do usuário e visualização dos resultados do sistema, conta com uma Interface Gráfica em *Flask*. Para utilizar, basta introduzir o endereço *Mint* alvo da análise e uma das distribuições de Análise de Sentimento disponíveis e clicar em "Analyze Token". A interface também conta com rápidas explicações sobre cada modelo do sistema e como ele funciona. Ela é disponibilizada ao público, e sua página inicial lista os repositórios que abarcam o sistema de detecção desenvolvido e seus módulos auxiliares (LUI; MOTA; TAI, 2025).



Rug Pull Detector
Analyze Solana tokens for potential rug pull indicators.

Token Analysis
Enter a Solana mint address below to begin the on-chain and sentiment analysis process.

Enter mint address

Select a content distribution for the sentiment analysis:

Regular

☐ Fewer Tweets (max 10)

Analyze Token

How It Works

XGBoost On-Chain Analysis: Examines token authority structure, liquidity, and transaction patterns.

Sentiment Analysis: Evaluates tweets related to the token using NLP models to measure public sentiment.

LSTM Price Modeling: Detects abnormal price movements and volatility anomalies.

AI Agent Classification: Aggregates all findings to flag high-risk tokens based on historical rug pull behavior.

Learn More About the Project

Figura 22 – *Landing Page* da Interface Gráfica

Para a demonstração, foi utilizada o criptoativo \$Shoggoth, após seu endereço *Mint* ser inserido, a seguinte tela após as análises serem feitas aparece:




Figura 23 – Página de análise - Seção de Informações




Figura 24 – Página de análise - Seção de *Holder*



Figura 25 – Página de análise - Seção de *XGBoost*




Figura 26 – Página de análise - Seção de Detecção de Anomalias




Figura 27 – Página de análise - Seção de Análise de Sentimento




Figura 28 – Página de análise - Seção Final de Riscos agregados

6 Considerações Finais

6.1 Conclusões do Projeto de Formatura

O presente trabalho tem como objetivo fornecer uma possível alternativa para investidores em criptomoedas em avaliar se *Tokens* estariam sob o risco de um golpe de *Rug-Pull*. Este trabalho foi desenvolvido com sucesso nas partes propostas de análise de sentimento, precificação, captação de metadados e agregador de riscos como também sua integração foi bem sucedida, seu desempenho em detectar *Rug-Pulls* foi comparada contra banco de dados de *tokens* conhecidamente problemáticos com relação a esse golpe em específico, como também sites de *tokens* verificados.

Estas verificações tiveram um retorno positivo verificado via *Jupiter Verified* ([Jupiter Exchange, 2025](#)), um classificador de tokens verificados, onde pode ser feita a confirmação com base em *tag* de verificado em cada token por uma curadoria e também comparados contra o RPDS para sinalização ou não para *Rug-Pull*.

6.2 Contribuições

O Trabalho de Conclusão de Curso traz consigo uma suite de ferramentas que fizeram possível o seu desenvolvimento. Entre esses, há muitas ferramentas de Inteligência Artificial, Redes Neurais, *Frameworks* de criação de sistemas em IA e LLMs. Além do desenvolvimento, o estudo e as tomadas de decisão no projeto foram guiadas por vários trabalhos, *papers* e até mesmo fóruns destacados nas Referências.

Entre os trabalhos baseados, **YAREMUS, D. et al. D, MOURA, M. S. ET AL. H e RAMOS, C.; GOLUB, N. C** foram trabalhos imprescindíveis para melhor entender melhor as técnicas que foram empregadas e a tecnologia que possibilitou as análises em *Rug-Pulls*, **SOLIDUS LABS RESEARCH** e **QUILLAI NETWORK** forneceram informações valiosas de estudo e de base sobre o criptoativo Solana. Além destes, **ALHAIDARI, A. et al. Solrpds** forneceu um grande e indispensável *dataset* de *Tokens Rug-Pulls* como também o estudo de caso em sua pesquisa, além de outros.

Sobre as tecnologias utilizadas, várias bibliotecas Python sobre IA foram empregadas, como *pytorch*, *pysentimiento* para a análise de sentimento textual ([PEREZ et al., 2024](#)), *AutoGen* e *Magentic-One* para a criação e orquestração de agentes autônomos ([FOURNEY et al., 2024](#)), *Ollama* para a aplicação de modelos de linguagem em ambientes locais, e APIs de consulta sobre criptoativos *Helius* e *CoinGecko* para desenvolvimento em IA do sistema e o consumo de dados da rede, respectivamente. Outras ferramentas

específicas são o GPT-OSS, modelo LLM utilizado para receber prompts e gerar as explicações do módulo Agregador do sistema durante a etapa de desenvolvimento. Esses pontos de partida foram centrais para a ideação e construção do sistema como um todo. Para a organização de trabalho foi utilizada a ferramenta de versionamento de código Git, como também a plataforma de *hosting* Git, o GitHub.

Fora estas ferramentas citadas, o trabalho de modularizar o sistema, treinar os modelos e desenvolver as camadas necessárias de comunicação e interface, como também avaliar a robustez, é da equipe deste Trabalho de Conclusão de Curso.

6.3 Perspectivas de Continuidade

O sistema, apesar do seu desenvolvimento em caráter de Prova de Conceito, tem frentes bem desenvolvidas e modulares o suficiente para facilmente introduzir mudanças vindouras e portanto tem possibilidade de crescimento.

Para posteridade, o trabalho tem perspectivas de crescimento ao poder utilizar modelos LLM mais performáticos e/ou em *cloud*, como também possível utilização de planos pagos de consumo das APIs, dada a grande limitação de consumo de dados imposta por planos gratuitos, isso pode melhorar tanto a gama de verificações que podem ser feitas como também expandir para mais usuários poderem utilizar a ferramenta com mais consultas e poder consumir de fato a API de *tweets* do *X*. O projeto poderia, com mais tempo disposto, desenvolver melhor em encontrar mais *datasets* para treino e testes, melhor avaliando a robustez das verificações e detecções.

No que tange a análise de sentimentos, a heurística aplicada pode ser continuamente reforçada para a detecção de manipulação de sentimentos, como a aplicação de análises estatísticas da distribuição de sentimentos e o desenvolvimento de algoritmos mais complexos para a determinação da probabilidade de um usuário não ser legítimo. A aplicação de técnicas de ABSA (Análise de Sentimento Baseada em Aspectos) pode tornar a detecção de sentimento referente ao token analisado mais sensível. Além disso, o emprego de um modelo de linguagem treinado com conteúdo proveniente do ecossistema de criptomoedas pode levar a uma melhor interpretação de gírias e palavras insulares a esses ambientes. Finalmente, o acesso à API da rede social *X* permitiria a análise contínua de sentimento, viabilizando a percepção da taxa de mudança de sentimento, uma métrica valiosa para avaliações de segurança.

Referências

ALHAIDARI, A. et al. Solrpd: A dataset for analyzing rug pulls in solana decentralized finance. *Proceedings of the Fifteenth ACM Conference on Data and Application Security and Privacy*, Universidade de Pittsburgh, Pittsburgh, PA, EUA, 2025. Disponível em: <https://dl.acm.org/doi/10.1145/3714393.3726487>. Acesso em: 10 out. 2025. Citado 5 vezes nas páginas 11, 13, 14, 24 e 36.

ARS TECHNICA. *Teen creates memecoin, dumps it, earns \$50,000*. Cidade de Nova Iorque, Nova Iorque, Estados Unidos da América, 2024. Disponível em: <https://arstechnica.com/tech-policy/2024/12/teen-creates-memecoin-dumps-it-and-earns-50000/>. Acesso em: 10 out. 2025. Citado 3 vezes nas páginas 11, 14 e 22.

BOLZ, M. et al. Machine learning-based detection of pump-and-dump schemes in real-time. *arXiv preprint arXiv:2412.18848*, Universidade de Zurique, Zurique, Suíça, 2024. Disponível em: <https://arxiv.org/html/2412.18848v1>. Acesso em: 20 fev. 2025. Citado 2 vezes nas páginas 14 e 23.

BREIMAN, L. Random forests: A statistical ensemble method for classification and regression. *Machine Learning*, Springer, Stanford, EUA, v. 45, n. 1, p. 5–32, out. 2001. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 20 fev. 2025. Citado na página 35.

CERTIK. *What is a Soft Rugpull vs a Hard Rugpull?* Cidade de Nova Iorque, Nova Iorque, Estados Unidos da América, 2022. Disponível em: <https://www.certik.com/resources/blog/what-is-a-soft-rugpull-vs-a-hard-rugpull>. Acesso em: 10 out. 2025. Citado 4 vezes nas páginas 11, 14, 18 e 22.

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: ASSOCIATION FOR COMPUTING MACHINERY. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco, EUA: ACM, 2016. p. 785–794. Disponível em: <https://dl.acm.org/doi/10.1145/2939672.2939785>. Acesso em: 20 fev. 2025. Citado 2 vezes nas páginas 35 e 36.

CNN. *Caso \$LIBRA: Comissão aponta colaboração de Milei em suposta fraude*. [S.l.], c. 2025. Disponível em: <https://www.cnnbrasil.com.br/internacional/caso-libra-comissao-aponta-colaboracao-de-milei-em-suposta-fraude/>. Acesso em: 01 dec. 2025. Citado na página 12.

COINEXT. *O que é Total Value Locked (TVL)?* Belo Horizonte, MG, Brasil, 2025. Disponível em: <https://coinext.com.br/blog/total-value-locked>. Acesso em: 10 out. 2025. Citado na página 19.

COINMARKETCAP. *CoinMarketCap*. Cidade de Nova Iorque, Nova Iorque, Estados Unidos da América, c. 2025. Disponível em: <https://coinmarketcap.com>. Acesso em: 20 fev. 2025. Citado 3 vezes nas páginas 11, 14 e 24.

COINMARKETCAP. *CoinMarketCap Cripto Glossário*. Cidade de Nova Iorque, Nova Iorque, Estados Unidos da América, c. 2025. Disponível em: <https://>

[//coinmarketcap.com/academy/pt/glossary](https://coinmarketcap.com/academy/pt/glossary)>. Acesso em: 10 out. 2025. Citado 2 vezes nas páginas 17 e 18.

FOURNEY, A. et al. Magentic-one: A generalist multi-agent system for solving complex tasks. *arXiv 2411.04468v1*, Microsoft, One Microsoft Way, Redmond, Washington, Estados Unidos, 2024. Disponível em: <<https://doi.org/10.48550/arXiv.2411.04468>>. Acesso em: 20 fev. 2025. Citado 3 vezes nas páginas 21, 29 e 63.

HEWING, M.; LEINHOS, V. The prompt canvas: A literature-based practitioner guide for creating effective prompts in large language models. *arXiv.2412.05127v1*, FH Münster, University of Applied Sciences, Münster, Alemanha, 2024. Disponível em: <<https://doi.org/10.48550/arXiv.2412.05127>>. Acesso em: 20 fev. 2025. Citado 2 vezes nas páginas 24 e 30.

JIANG, A. Q. et al. Mixtral of experts. *arXiv 2401.04088v1*, Mistral AI, Paris, França, 2024. Disponível em: <<https://doi.org/10.48550/arXiv.2401.04088>>. Acesso em: 20 fev. 2025. Citado 2 vezes nas páginas 24 e 30.

Jupiter Exchange. *Verified Token Submissions*. [S.l.], 2025. Disponível em: <<https://verified.jup.ag/tokens/submissions?status=verified>>. Acesso em: 08 dez. 2025. Citado 2 vezes nas páginas 36 e 63.

KALACHEVA, A. et al. Detecting rug pulls in decentralized exchanges: The rise of meme coins. *Blockchain: Research and Applications*, Blockchain: Research and Applications, Skolkovo, Rússia, 2024. Disponível em: <https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4981529>. Acesso em: 10 out. 2025. Citado 4 vezes nas páginas 11, 14, 19 e 23.

LIU, C. et al. Enhancing cryptocurrency sentiment analysis with multimodal features. *arXiv:2508.15825v1*, arXiv:2508.15825v1, Auckland, Nova Zelândia, 2025. Disponível em: <<https://arxiv.org/html/2508.15825v1#S2>>. Acesso em: 10 out. 2025. Citado 4 vezes nas páginas 12, 14, 24 e 31.

LUI, I. R.; MOTA, L. F. de A.; TAI, R. R. S. *Rug Pull Detector*. São Paulo, São Paulo, Brasil: Departamento de Engenharia de Computação e Sistemas Digitais, 2025. Disponível em: <<https://rtaishan.github.io/rugpull-detector-site/>>. Acesso em: 09 dez. 2025. Citado 2 vezes nas páginas 31 e 58.

MAZORRA, B.; ADAN, V.; DAZA, V. Do not rug on me: Leveraging machine learning techniques for automated scam detection. *Mathematics*, MDPI, Barcelona, Espanha, 2022. Disponível em: <<https://www.mdpi.com/2227-7390/10/6/949>>. Acesso em: 10 out. 2025. Citado 4 vezes nas páginas 11, 14, 19 e 23.

MOURA, M. S. et al. Hd pump: A hybrid detection approach for pump-and-dump schemes in cryptocurrency exchanges. *Proceedings of the 39th Brazilian Symposium on Data Bases*, Centro Federal de Educação Tecnológica do Rio de Janeiro, RJ, Brasil, p. 1–7, out. 2024. Disponível em: <<https://sol.sbc.org.br/index.php/sbbd/article/view/30743/30546>>. Acesso em: 20 fev. 2025. Citado 3 vezes nas páginas 11, 14 e 23.

NGUYEN, D. Q.; VU, T.; NGUYEN, A. T. Bertweet: A pre-trained language model for english tweets. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, VinAI Research, Cidade de Ho Chi Minh,

Vietnam, 2020. Disponível em: <<https://arxiv.org/pdf/2005.10200>>. Acesso em: 10 out. 2025. Citado 3 vezes nas páginas 24, 31 e 42.

OLAH, C. Understanding lstm networks. *colah's blog*, 2015. Disponível em: <<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>>. Acesso em: 17 nov. 2025. Citado 3 vezes nas páginas 23, 30 e 40.

PEREZ, J. M. et al. pysentimiento: A python toolkit for opinion mining and social nlp tasks. *arXiv:2508.15825v1*, Universidad de Buenos Aires, Buenos Aires, Argentina, 2024. Disponível em: <<https://arxiv.org/pdf/2106.09462>>. Acesso em: 10 out. 2025. Citado 4 vezes nas páginas 24, 31, 42 e 63.

QUILLAI NETWORK. *Quill Check - Free Rug Pull Detector*. [S.l.], c. 2025. Disponível em: <<https://check.quillai.network>>. Acesso em: 20 fev. 2025. Citado 3 vezes nas páginas 11, 14 e 24.

RAMOS, C.; GOLUB, N. Cryptocurrency pumping predictions: A novel approach to identifying pump and dump schemes. *FALL 2017: CS 229 FINAL PROJECT. Trabalho de Conclusão de Curso (Graduação em Ciência de Computação)*, Stanford, Califórnia, Estados Unidos da América, p. 1–4, 2017. Disponível em: <<https://cs229.stanford.edu/proj2017/final-reports/5231579.pdf>>. Acesso em: 20 fev. 2025. Citado 3 vezes nas páginas 11, 14 e 23.

SOLIDUS LABS RESEARCH. *The 2025 Rug Pull Report: Rug Pulls and Pump-and-Dumps on Solana*. Cidade de Nova Iorque, Nova Iorque, Estados Unidos da América, c. 2025. Disponível em: <<https://www.soliduslabs.com/reports/solana-rug-pulls-pump-dumps-crypto-compliance>>. Acesso em: 10 out. 2025. Citado 6 vezes nas páginas 11, 13, 15, 22, 36 e 56.

YAREMUS, D. et al. Detecting rug pulls in decentralized exchanges: Machine learning evidence from the ton blockchain. *arXiv preprint arXiv:2509.01168v1*, Instituto de Física e Tecnologia de Moscou, Moscou, Rússia, 2025. Disponível em: <<https://arxiv.org/abs/2509.01168v1>>. Acesso em: 10 out. 2025. Citado 3 vezes nas páginas 11, 19 e 23.

ZHOU, C. et al. A comprehensive evaluation of large language models on aspect-based sentiment analysis. *arXiv:2412.02279v1*, Instituto de Tecnologia de Pequim, Pequim, China, 2024. Disponível em: <<https://arxiv.org/abs/2412.02279>>. Acesso em: 10 out. 2025. Citado 2 vezes nas páginas 24 e 31.