

Nathan Filipe Moreira dos Santos, Vitor Santos da Costa

EcoVision: Automação Inteligente de Coleta Seletiva

São Paulo, SP

2025

Nathan Filipe Moreira dos Santos, Vitor Santos da Costa

EcoVision: Automação Inteligente de Coleta Seletiva

Trabalho de conclusão de curso apresentado
ao Departamento de Engenharia de Computa-
ção e Sistemas Digitais da Escola Politécnica
da Universidade de São Paulo para obtenção
do Título de Engenheiro.

Universidade de São Paulo – USP

Escola Politécnica

Departamento de Engenharia de Computação e Sistemas Digitais (PCS)

Orientador: Prof. Dr. Artur Jordão Lima Correia

São Paulo, SP

2025

Resumo

Reciclagem, uma das formas mais efetivas de combater o problema crescente de descarte de resíduos sólidos, enfrenta diversos desafios, como a falta de infraestrutura para coleta seletiva, baixa conscientização da população e a contaminação dos materiais recicláveis. Com o objetivo de tornar esse processo mais eficiente, este projeto propõe um sistema automático de triagem de resíduos. O sistema utiliza modelos de visão computacional, em particular modelos de IA para detecção e classificação de objetos. Para especializar o modelo em reconhecer resíduos e, assim, promover maior precisão, ele foi treinado em uma base de dados específica para reconhecimento dos resíduos e seus respectivos materiais. Para estudar a efetividade da solução, este projeto explora a manufatura de uma esteira de testes, na qual os objetos serão detectados e separados por um mecanismo que simula um braço mecânico. Acreditamos que o projeto tem potencial de melhorar processos de reciclagem, diminuir trabalho manual e contribuir com práticas mais sustentáveis na coleta seletiva.

Palavras-chave: visão computacional. inteligência artificial. coleta seletiva. reciclagem.

Abstract

Recycling, one of the most effective ways to address the growing problem of solid waste disposal, faces several challenges, like the lack of infrastructure for selective collection, low public awareness, and contamination of recyclable material. To make this process more efficient and economically viable, this project proposes an automatic waste sorting system. This system uses computer vision, specifically AI models for object detection and classification. To specialize the model in recognizing objects and thereby improve accuracy, we trained the model in a dataset specifically designed for recyclable materials and material recognition. To evaluate the effectiveness of the solution, this project also includes the construction of a conveyor belt, to detect objects and separate them by a mechanism that simulates a robotic arm. We believe this project has the potential to improve recycling processes, reduce manual labor, and contribute to more sustainable waste management practices.

Keywords: computer vision. artificial intelligence. waste sorting. recycling.

Lista de ilustrações

Figura 1 – Processo de convolução	17
Figura 2 – Processo de <i>max pooling</i>	18
Figura 3 – Arquitetura de uma Rede Neural Convolutacional	18
Figura 4 – Detecção de objetos com YOLO	19
Figura 5 – Diagrama Funcional	25
Figura 6 – Esboço de Maquete	29
Figura 7 – Diagrama de Arquitetura de Hardware	30
Figura 8 – Resultado de classificações com YOLOv8s e TACO sobre fotos de resíduos	31
Figura 9 – Processo de anotação da nova base de dados	34
Figura 10 – Amostra da base de teste.	35
Figura 11 – Diagrama de Classes do projeto EcoVision	36
Figura 12 – Diagrama com Componentes do Frontend	37
Figura 13 – Descrição detalhada do <i>hardware</i> do sistema	37
Figura 14 – Evolução das perdas durante o processo de <i>fine-tuning</i> do modelo YOLOv8s.	39
Figura 15 – Desempenho do modelo YOLOv8s durante o <i>fine-tuning</i> , mostrando a evolução da precisão e da métrica mAP@50.	40
Figura 16 – Tela de login	41
Figura 17 – Tela principal de monitoração	41
Figura 18 – Tela de configuração de separação	42
Figura 19 – Tela de configuração de modelo, saída serial e câmera	43
Figura 20 – Esteira finalizada.	43
Figura 21 – Projeto em funcionamento para diferentes tipos de materiais.	44

Lista de tabelas

Tabela 1 – Componentes da arquitetura e seus respectivos valores	29
Tabela 2 – Configuração de cenários de teste	30
Tabela 3 – Precisão Média (%) por cenário	38

Lista de abreviaturas e siglas

AI	Artificial Intelligence
CNN	Convolutional Neural Networks
COCO	Common Objects in Context
Crisp-DM	Cross Industry Standard Process for Data Mining
DFL	Distribution Focal Loss
FPS	Frames por Segundo
IA	Inteligência Artificial
IoU	Intersection over Union
mAP	mean Average Precision
PoC	Proof of Concept
R-CNN	Regions with Convolutional Neural Networks Features
RF	Requisitos Funcionais
RFN	Requisitos Não Funcionais
TACO	Trash Annotations in Context
USB	Universal Serial Bus
YOLO	You Only Look Once

Sumário

1	INTRODUÇÃO	13
1.1	Motivação	13
1.2	Objetivos	14
1.3	Justificativa	14
1.4	Organização do Trabalho	15
2	ASPECTOS CONCEITUAIS	17
2.1	Redes Neurais Convolucionais	17
2.2	Detecção de Objetos	18
2.2.1	YOLO	19
2.3	<i>Common Objects in Context (COCO)</i>	20
2.4	<i>Trash Annotations in Context (TACO)</i>	21
2.5	<i>Fine-tuning</i>	22
3	ESPECIFICAÇÃO	25
3.1	Descrição Funcional	25
3.2	Requisitos Funcionais	26
3.2.1	RF01 - Detecção e Classificação dos Resíduos	26
3.2.2	RF02 - Movimentação dos Objetos	26
3.2.3	RF03 - Separação dos Objetos	26
3.2.4	RF04 - Comunicação entre Componentes	26
3.2.5	RF05 - Interrupção da Separação	27
3.3	Requisitos Não Funcionais	27
3.3.1	RNF01 - Robustez da Estrutura Física	27
3.3.2	RNF02 - Fonte de Alimentação Externa	27
3.3.3	RNF03 - Tempo de Resposta do Sistema	27
3.3.4	RNF04 - Escalabilidade do Algoritmo	28
3.3.5	RNF05 - Modelagem e Construção da Maquete	28
3.4	Arquitetura e Custos	28
3.5	Modelo para Detecção dos Resíduos	30
4	DESENVOLVIMENTO DO TRABALHO	33
4.1	Tecnologias Utilizadas	33
4.1.1	Modelo e Conjuntos de Dados	33
4.1.2	Software	33
4.1.3	Hardware	33

4.1.4	Dispositivos Externos	34
4.1.5	Ferramentas de Desenvolvimento e Versionamento	34
4.2	Projeto e Implementação	34
4.2.1	Base de Dados e Modelo	34
4.2.2	Módulo de Software	36
4.2.3	Descrição de Hardware	37
4.3	Resultados e Avaliação	38
4.3.1	Modelo	38
4.3.2	Módulo de Software	40
4.3.3	Sistema Completo	43
5	CONCLUSÕES E CONSIDERAÇÕES FINAIS	45
	REFERÊNCIAS	47

1 Introdução

O aumento da geração de resíduos sólidos urbanos é um dos grandes desafios ambientais da atualidade. Mesmo com o avanço de políticas públicas e campanhas de conscientização, estudos apontam que um dos principais obstáculos para o desenvolvimento da reciclagem no Brasil é a prevalência de processos pouco automatizados e a deficiência estrutural das centrais de triagem (CONKE, 2018). De acordo com a Associação Brasileira de Recuperação Energética de Resíduos (ABREMA, 2024), apenas 52,2% dos resíduos coletados são efetivamente encaminhados para reciclagem, o que representa um desperdício expressivo de materiais com potencial de reaproveitamento.

Nesse cenário, torna-se evidente a necessidade de soluções tecnológicas que ampliem a eficiência e a automação do processo de triagem. A visão computacional, ramo da inteligência artificial que permite a interpretação automática de imagens, surge como uma ferramenta promissora para identificar e classificar diferentes tipos de resíduos. Aliada a modelos de aprendizado profundo, como o YOLO (You Only Look Once), essa tecnologia possibilita a detecção de objetos em tempo real com alto grau de precisão, sendo amplamente utilizada em aplicações industriais e ambientais. Dessa forma, sistemas de triagem automatizada baseados em IA podem reduzir o trabalho manual, minimizar erros humanos e aumentar o volume de materiais reciclados processados de forma correta.

1.1 Motivação

A Política Nacional de Resíduos Sólidos (Lei nº 12.305, de 2 de agosto de 2010) determinou que os municípios com população superior a 50.001 habitantes deveriam garantir a disposição final ambientalmente adequada dos rejeitos e eliminar os lixões até agosto de 2023. No entanto, o cenário atual ainda está longe do ideal, aproximadamente 32% dos municípios brasileiros não possuem um sistema estruturado de coleta seletiva, e mais de 30% ainda destinam seus resíduos a lixões, em desacordo com a legislação vigente (BRITTO, 2024). Mesmo nos locais onde a coleta seletiva já é praticada, a eficiência da triagem permanece limitada.

Por outro lado, os avanços recentes em aprendizado profundo demonstram o potencial dessas técnicas em superar o desempenho humano em tarefas de classificação visual (MASLEJ et al., 2025). Em 2016, durante o ImageNet Challenge, uma competição que classifica imagens da *Internet* em uma das 1.000 categorias disponíveis, um modelo de visão computacional alcançou um índice de erro de apenas 3,6%, superando o desempenho médio dos humanos, que foi estimado em 5,1% na mesma base de dados (KRIZHEVSKY; SUTSKEVER; HINTON, 2012). Esses números mostram que os sistemas baseados em

aprendizado profundo já atingem, ou até superam, a precisão humana em tarefas complexas de classificação visual e evidenciam a maturidade e confiabilidade dessas tecnologias para aplicações práticas (MASLEJ et al., 2025).

Diante do desempenho preditivo promissor dos modelos de visão computacional e da carência de sistemas de coleta seletiva mais efetivos, este projeto busca unir as técnicas de detecção e classificação de objetos para desenvolver um sistema automático de triagem de resíduos. Essa abordagem visa contribuir para uma gestão mais sustentável dos resíduos sólidos, promovendo a inovação tecnológica em prol do meio ambiente.

1.2 Objetivos

Este projeto tem como objetivo desenvolver um sistema para triagem e separação de resíduos em esteiras de reciclagem de maneira automática, isto é, sem a participação humana no *loop*, utilizando visão computacional e aprendizado profundo. O sistema proposto busca identificar, classificar e direcionar diferentes tipos de materiais recicláveis, como plástico, metal, vidro e papelão, de forma autônoma, a partir de imagens capturadas por uma câmera instalada em uma esteira transportadora.

A proposta integra modelos de detecção de objetos em tempo real a uma estrutura física composta por sensores, atuadores e controladores, permitindo o acionamento automático de mecanismos de separação. Essa integração tem como metas reduzir a dependência de mão de obra humana, aumentar a produtividade das estações de triagem e otimizar a precisão do processo de reciclagem, tornando-o mais eficiente, seguro e economicamente viável.

1.3 Justificativa

Dado o crescimento das demandas por maior volume de resíduos reciclados, torna-se necessário adotar um processo de seleção mais efetivo, capaz de acompanhar essa expansão. Segundo relatórios técnicos de empresas especializadas em IA, a triagem manual apresenta limitações relevantes, como uma acurácia de separação que pode variar entre 60% e 80%, e uma velocidade de cerca de 40 a 60 itens por minuto, além dos riscos de contaminação (EVREKA, 2025).

Sistemas baseados em visão computacional, por sua vez, apresentam ganhos expressivos de desempenho, com redução de cerca de 80% no tempo de triagem quando comparados aos métodos tradicionais, com seres humanos (PICVISA, 2024). Portanto, além de este projeto contribuir fortemente para impulsionar a adoção de tecnologias inteligentes no campo da reciclagem, ele também aumenta a eficiência do processo de

triagem, minimizando erros humanos e diminuindo o tempo de separação, proporcionando um melhor aproveitamento dos materiais recicláveis.

1.4 Organização do Trabalho

Este documento foi dividido em diversos capítulos, facilitando a organização e entendimento das ideias. O Capítulo 1 apresenta as motivações, objetivos e contexto do projeto, o Capítulo 2 descreve as tecnologias de visão de computacional utilizadas para detecção, classificação de objetos e técnicas empregadas no contexto de detecção de materiais recicláveis. Em seguida, o Capítulo 3, apresenta os requisitos definidos na etapa de especificação detalhada do projeto e o Capítulo 4, aborda o desenvolvimento do projeto e os resultados obtidos. Por fim, são feitas as conclusões do trabalho no Capítulo 5.

2 Aspectos Conceituais

2.1 Redes Neurais Convolucionais

As Redes Neurais Convolucionais (CNNs) são um tipo de rede de aprendizagem profunda projetada principalmente para processamento de dados com uma grade de estruturas, como imagem, vídeo e áudio (IBM, 2025). As CNNs são compostas por diversas camadas que processam e transformam a estrutura de entrada, dentre as quais, temos a camada de convolução, a camada de *pooling* e a camada *fully-connected*.

A camada de convolução, a primeira do processo, aplica uma operação de convolução sobre a imagem utilizando um filtro, geralmente de tamanho 3×3 , que percorre toda a imagem, em um processo chamado de *sliding window*. Em cada posição, aplica-se um produto escalar entre o filtro e a imagem, o que permite detectar assim bordas, texturas e outros detalhes. Esse procedimento gera o mapa de características (*feature map*), conforme ilustra a Figura 1.




Figura 1 – Processo de convolução

Fonte: IBM, 2025 (IBM, 2025)

A camada de *pooling* percorre a imagem com um filtro, assim como a camada de convolução, porém, em vez de realizar operações de convolução, aplica uma função de agrupamento para extrair as informações mais relevantes daquela região. O *max pooling*, um dos métodos de *pooling*, seleciona o maior valor presente na região percorrida pelo filtro. Apesar desse processo resultar na perda de alguns detalhes, ele reduz a complexidade do modelo, aumenta a eficiência computacional e ajuda a evitar que o modelo tornar-se invariante a pequenas translações na imagem (IBM, 2025). A Figura 2 demonstra a aplicação do método de *max pooling*.




Figura 2 – Processo de *max pooling*

Fonte: Correia, 2025 ([CORREIA, 2025](#))

Por fim, a camada totalmente conectada *fully-connected* combina as características extraídas para realizar as tarefas de regressão e classificação, atribuindo probabilidades às classes identificadas.

2.2 Detecção de Objetos

A detecção de objetos, uma aplicação da visão computacional, busca desenvolver modelos e técnicas para identificar objetos de categorias predefinidas, como animais e carros, com alta precisão. De acordo com ([ZOU et al., 2019](#)), a partir de 2014, houve um grande avanço das técnicas de detecção de objetos, com a aplicação de Redes Neurais Convolucionais (*CNN - Convolutional Neural Networks*) para propor as regiões de detecção, a Figura 3 apresenta um exemplo de arquitetura desse modelo. Tal modelo utiliza múltiplas camadas de redes convolucionais para extrair áreas específicas de uma imagem onde há alta probabilidade de existir um objeto. Com essa evolução, surgiram dois tipos principais de detectores: os detectores de dois estágios, *two-stage*, e os detectores de um estágio, *one-stage*, cada um com suas características e vantagens em termos de precisão e desempenho.




Figura 3 – Arquitetura de uma Rede Neural Convolucional

Fonte: Joiya, 2022 ([JOIYA, 2022](#))

O primeiro modelo de detecção de dois estágios proposto foi o R-CNN (*Regions with Convolutional Neural Networks Features*) ([ZOU et al., 2019](#)). No primeiro estágio, o modelo gera diversas propostas de regiões, independentes de categorias, que podem conter um objeto. Em seguida, ocorre a extração das características dessas regiões processadas por uma rede convolucional e então passam por um classificador que as analisa e atribui

a cada região pontuações, de forma a selecionar as mais bem pontuadas. Embora essa abordagem seja capaz de alcançar uma alta precisão, seu processamento é lento e demanda GPUs de grande desempenho (CAO et al., 2022), já que cada uma das regiões propostas são analisadas separadamente. Dentro do contexto de detecção de materiais recicláveis, estudos sugerem que o modelo deve ser otimizado com o objetivo de diminuir o tempo de processamento (YANG et al., 2022). Essas otimizações permitem que o modelo alcance desempenho suficiente para aplicações em tempo real, ampliando seu uso em sistemas automatizados.

Quanto aos modelos de detecção de um estágio, destaca-se o YOLO (*You Only Look Once*) (REDMON et al., 2016). Esse modelo considera a imagem como uma única grade e, para cada célula, o modelo determina simultaneamente as caixas delimitadoras e a probabilidade de cada classe de interesse, neste caso, categoria de objeto. Dessa forma, o modelo torna-se consideravelmente mais rápido e ideal para aplicações de detecção de objetos em tempo real. Dessa forma, YOLO emerge como um dos principais candidatos para uso no contexto de detecção de resíduos em movimento, como objetos em rios (YANG et al., 2022).

2.2.1 YOLO

Um modelo popular de detecção de objetos em tempo real é o YOLO, que utiliza uma única rede convolucional para simultaneamente delimitar as caixas delimitadoras (*bounding boxes*) e a probabilidade de cada classe (Figura 4).




Figura 4 – Detecção de objetos com YOLO

Fonte: Redmon, 2016 (REDMON et al., 2016)

Ao receber uma imagem, o modelo a separa em uma grade $S \times S$. A célula cujo centro contém o objeto torna-se responsável por detectar o objeto. Para isso, cada célula prevê um conjunto de caixas delimitadoras e calcula uma pontuação de confiança para

cada caixa, a qual reflete tanto a probabilidade de que um objeto esteja presente quanto a precisão com que a caixa se ajusta ao objeto (DU, 2018). Dessa forma, cada caixa é definida por uma coordenada (x, y) que indica o centro relativo à célula que a contém, bem como pela largura (w) e altura (h) em relação à imagem completa, além do seu nível de confiança.

Adicionalmente, cada célula estima a probabilidade de pertencer a cada uma das classes possíveis. O modelo, então, multiplica essa probabilidade pela confiança da caixa para gerar uma previsão final sobre qual objeto se encontra naquela região. A Equação 2.1 apresenta o cálculo realizado pelo modelo.

$$P(\text{Classe}_i \mid \text{Objeto}) \cdot P(\text{Objeto}) \cdot \text{IoU}_{\text{truth, pred.}} = P(\text{Classe}_i) \cdot \text{IoU}_{\text{truth, pred.}} \quad (2.1)$$

Onde:

- $P(\text{Classe}_i \mid \text{Objeto})$ é a probabilidade condicional de que, dado que há um objeto na caixa, esse objeto pertença à classe i .
- $P(\text{Objeto})$ é a probabilidade de que haja um objeto na caixa delimitadora.
- $\text{IoU}_{\text{truth, pred.}}$ representa o *Intersection over Union* entre a caixa prevista e a caixa real (ground truth), medindo o quão bem a caixa se ajusta ao objeto.
- $P(\text{Classe}_i)$ é a probabilidade da classe i independentemente da presença do objeto, e a multiplicação por $\text{IoU}_{\text{truth, pred.}}$ gera o *score* final que combina a certeza na classe e a qualidade da predição da caixa.

De maneira geral, o YOLO se destaca em relação aos métodos tradicionais de detecção de objetos por realizar a tarefa como um problema de regressão, o que o torna significativamente mais rápido. Segundo (REDMON et al., 2016), o modelo básico processa 45 frames por segundo (fps), enquanto versões otimizadas alcançam taxas superiores a 150 fps.

2.3 Common Objects in Context (COCO)

Para o treinamento de modelos de detecção de objetos, como a família YOLO, é necessário uma boa qualidade, diversidade e precisão das anotações dos objetos nas imagens. Nesse cenário, surge o COCO (*Common Objects in Context*) (LIN et al., 2014), um conjunto de dados, composto por mais de 200 mil imagens anotadas e cerca de 1,5 milhão de instâncias distribuídas em 80 categorias de objetos, abrangendo, pessoas, animais, veículos, etc. As imagens foram coletadas em diferentes ambientes, contemplando variados

tamanhos de objetos e níveis de oclusão, isto é, situações em que parte do objeto está parcialmente encoberta por outro, tornando o *dataset* mais preciso em cenários reais.

O processo de anotação do COCO foi realizado de forma semiautomática. Inicialmente, foram geradas propostas automáticas de *bounding boxes*, que posteriormente passaram por revisão manual, incluindo correção das caixas e verificação da consistência das categorias atribuídas pelos algoritmos (KUMAR; KUMAR, 2023). Esse processo, conduzido por múltiplos anotadores, assegurou maior precisão e confiabilidade às anotações.

Para avaliar o desempenho de modelos de detecção, o COCO utiliza a métrica *mean Average Precision* (mAP), que corresponde à média das *Average Precision* (AP) calculadas para cada classe. Cada AP é obtida como a área sob a curva $Precision \times Recall$, que representa a relação entre a proporção de detecções corretas entre todas as predições (*Precision*) e a proporção de objetos presentes na imagem que foram encontradas pelo modelo (*Recall*) (KUMAR; KUMAR, 2023).

O COCO, utiliza a versão mais rigorosa da métrica, denominada mAP@[0.5:0.95], que calcula o desempenho em dez limiares de IoU, conferindo uma avaliação mais rigorosa e sensível à capacidade do modelo de detectar objetos pequenos, parcialmente ocluídos e presentes em contextos complexos.

Outra grande evolução que o COCO trouxe, foi a notação COCO. Essa notação, no formato JSON, representa imagens, categorias e anotações no *dataset*, contendo informações como *bounding boxes*, segmentações, identificação de categorias e metadados organizados de forma padronizada, permitindo que modelos de detecção interpretem de maneira consistente onde cada objeto aparece. Essa estrutura detalhada e revisada manualmente torna o COCO um dos benchmarks mais completos e utilizados para treinamento e avaliação de modelos.

2.4 *Trash Annotations in Context (TACO)*

O TACO (*Trash Annotations in Context*) é um *dataset* voltado para a detecção de resíduos em ambientes reais, reunindo imagens de resíduos descartados em variadas condições, como, sujos, deformados, sobrepostos ou degradados. Essas características tornam o conjunto de dados mais representativo dos desafios encontrados no mundo real e, consequentemente, mais adequado para treinar e avaliar modelos de detecção de objetos aplicados ao contexto ambiental (PROENÇA; SIMÕES, 2020).

O *dataset* contém cerca de 1500 imagens e 4784 anotações (SIMÕES PEDRO E PROENÇA, 2020a), classificadas em diferentes categorias de resíduos, como plástico, metal, papel, vidro, entre outras. As anotações seguem o formato COCO JSON, o que permite uma integração com modelos da família YOLO, permitindo o uso direto em tarefas de detecção e segmentação sem necessidade de conversões adicionais.

Dessa forma, o TACO desponta como um excelente *dataset* para o contexto do projeto, pois captura com fidelidade as condições em que resíduos realmente aparecem em processos de reciclagem. Isso possibilita modelos mais alinhados ao cenário operacional, aumentando a eficácia da detecção e classificação automática dos materiais recicláveis.

2.5 *Fine-tuning*

O *fine-tuning* é uma técnica particular do campo de *transfer learning* que possibilita a adaptação de um modelo já previamente treinado para um novo domínio ou conjunto de classes, diminuindo não apenas o custo computacional, mas também a demanda por grandes volumes de dados com rótulos. A literatura sobre *transfer learning* caracteriza esse procedimento como a reutilização de conhecimento previamente adquirido em um domínio-fonte (D_S, T_S) para aprimorar o desempenho de aprendizagem em um domínio-alvo (D_T, T_T) , ainda que esses domínios tenham apenas uma relação parcial (PAN; YANG, 2010). Nesse cenário, o *fine-tuning* aproveita representações já aprendidas, eliminando a necessidade de começar o treinamento com pesos aleatórios. Essa estratégia pode ser definida como um método de transferência baseado em parâmetros, no qual os pesos internos de redes profundas são reutilizados como ponto de partida para especialização no novo domínio (ZHUANG et al., 2021).

Em visão computacional, o *fine-tuning* passou a ser uma prática amplamente adotada e aceita, particularmente em arquiteturas convolucionais para classificação e identificação de objetos. Redes convolucionais pré-treinadas têm a capacidade de atuar tanto como extratoras fixas de características quanto como modelos capazes de ajuste adicional, sendo que essa segunda estratégia geralmente leva a um melhor desempenho nas tarefas-alvo (CETINIC; GRGIC; GRGIC, 2018). Isso ocorre porque as camadas iniciais das CNNs capturam padrões visuais essenciais, como bordas e texturas, que são úteis em muitos contextos, enquanto as últimas camadas representam informações mais específicas do conjunto de dados original. Assim, é comum, durante o *fine-tuning*, a utilização apenas de determinadas camadas mais internas, o que mantém as primeiras camadas fixas para evitar a perda de características gerais pré-aprendidas.

Para os modelos de detecção de objetos como YOLO, o *fine-tuning* possibilita a adaptação de um modelo pré-treinado para categorias específicas de resíduos sólidos. Pesquisas indicam que a adaptação seletiva de partes do modelo, utilizando pesos previamente treinados em bases como COCO, acelera a convergência e melhora o desempenho, mesmo quando a quantidade de dados disponível é limitada (ZHAO, 2024). Essa característica é importante para cenários de triagem, onde a anotação manual é custosa e os conjuntos de dados geralmente apresentam variações significativas.

Do ponto de vista da avaliação de desempenho dos modelos após aplicação dessa

técnica, as funções de perda (*loss functions*) se destacam como métricas fundamentais no novo treinamento dessas redes neurais, sendo responsáveis por quantificar o erro entre as previsões do modelo e os valores reais. No YOLOv8, essas perdas são compostas principalmente por três componentes: a *box loss*, baseada na métrica IoU, que quantifica o erro entre a caixa prevista e a caixa real; a *cls loss*, que mede o erro de classificação entre as categorias previstas e as verdadeiras; e a DFL (*Distribution Focal Loss*), que refina a regressão das coordenadas das caixas (Ultralytics, 2024b). A redução simultânea dessas perdas ao longo do *fine-tuning* indica que o modelo está aprendendo representações significativas do conjunto de dados. Entretanto, quando as perdas do conjunto de treino continuam diminuindo enquanto as perdas de validação deixam de acompanhar essa tendência, ocorre o fenômeno conhecido como *overfitting*, no qual o modelo memoriza padrões específicos do treinamento e perde capacidade de generalização.

Dessa forma, o *fine-tuning* permite que modelos de visão computacional previamente treinados em *datasets* amplos, como o COCO, sejam refinados para reconhecer categorias específicas de resíduos sólidos, utilizando para isso o TACO, um *dataset* especializado em resíduos sólidos. Com isso, o modelo aproveita representações visuais já aprendidas e otimiza apenas suas camadas finais, o que melhora o seu desempenho mesmo com poucas amostras anotadas.

3 Especificação

Esta seção determina o escopo do projeto de automação de coleta seletiva, descrevendo o comportamento esperado e especificando os requisitos do sistema, em particular, com ênfase no projeto técnico da esteira.

3.1 Descrição Funcional

Na etapa inicial do sistema, são colocados diversos resíduos sólidos na esteira para serem analisados. Uma câmera grava os objetos em movimento, transmitindo o vídeo para o modelo de visão computacional. O modelo detecta e classifica os objetos entre as categorias alvo: plástico, metal, vidro e papelão. Essas informações são repassadas para o controlador, responsável pelo acionamento da esteira e da cancela que atua como separador dos resíduos. Idealmente, o controlador mantém a velocidade da esteira constante, para não afetar a vazão de entrada e saída do sistema.

O separador mecânico recebe comandos de acordo com o tipo de material classificado pelo detector, retirando da esteira os materiais alvo. Os demais materiais, que não são de interesse do separador ou não foram identificados, prosseguem na esteira onde podem ser retirados por um segundo sistema de separação ou triagem manual. A Figura 5 ilustra essa descrição funcional do sistema.




Figura 5 – Diagrama Funcional

Fonte: Autoria própria

3.2 Requisitos Funcionais

3.2.1 RF01 - Detecção e Classificação dos Resíduos

Requisito: Detectar objetos em tempo real na esteira e classificá-los de acordo com seu tipo e material (plástico, papelão, metal e vidro) para viabilizar a triagem automatizada.

Prioridade: Alta.

Critério de Aceite: O sistema deve ser capaz de capturar imagens dos objetos. A partir das imagens, deve identificar o tipo de material.

3.2.2 RF02 - Movimentação dos Objetos

Requisito: Movimentar os objetos estudados para classificação e separação por meio de uma esteira transportadora.

Prioridade: Alta.

Critério de Aceite: A esteira ser capaz de movimentar objetos como garrafas PET e latas, e ter comprimento suficiente para instalar as cancelas de direcionamento.

3.2.3 RF03 - Separação dos Objetos

Requisito: Separar os objetos corretamente, direcionando-os para os compartimentos corretos, garantindo a separação eficiente dos materiais. Pode ser feito pelo acionamento de cancelas.

Prioridade: Alta.

Critério de Aceite: O sistema deve ser capaz de separar todos os tipos de materiais alvos definidos. Deve direcionar os resíduos aos compartimentos apropriados.

3.2.4 RF04 - Comunicação entre Componentes

Requisito: Comunicar com componentes de movimentação e separação de objetos a partir da detecção e classificação dos objetos.

Prioridade: Alta.

Critério de Aceite: Obter um controlador que receba e processe os dados do algoritmo e comande tanto o acionamento da esteira quanto das cancelas, de acordo com os resultados da classificação.

3.2.5 RF05 - Interrupção da Separação

Requisito: Ter uma forma fácil de interromper a separação dos materiais. A esteira deve permanecer em movimento.

Prioridade: Baixa.

Critério de Aceite: Deve ser possível acionar a interrupção em até 2 segundos após solicitado.

3.3 Requisitos Não Funcionais

3.3.1 RNF01 - Robustez da Estrutura Física

Requisito: A maquete deve ser resistente e durável, utilizando materiais adequados para suportar o transporte dos objetos definidos.

Prioridade: Alta.

Critério de Aceite: A maquete deve ser construída com MDF de 6mm e a esteira deve utilizar tecido vinílico resistente e impermeável.

3.3.2 RNF02 - Fonte de Alimentação Externa

Requisito: O sistema deve operar com uma fonte de alimentação que garanta o funcionamento contínuo dos componentes eletrônicos.

Prioridade: Alta.

Critério de Aceite: O sistema deve operar conectado à rede elétrica, garantindo fornecimento de energia estável para os componentes eletrônicos, como, por exemplo, o motor e o controlador.

3.3.3 RNF03 - Tempo de Resposta do Sistema

Requisito: A integração entre os componentes e processamento de imagens deve garantir um tempo de resposta adequado para a separação eficiente dos materiais.

Prioridade: Alta.

Critério de Aceite: A integração entre câmera, modelo e controlador deve garantir que a classificação e o acionamento das cancelas ocorram em tempo hábil para o correto direcionamento dos resíduos.

3.3.4 RNF04 - Escalabilidade do Algoritmo

Requisito: O modelo de visão computacional deve permitir a expansão futura do projeto geral, possibilitando a classificação de outros tipos de materiais.

Prioridade: Média.

Critério de Aceite: O modelo deve permitir futura expansão para classificar mais tipos de materiais além de plástico, papelão, vidro e metal. Ademais, deve haver espaço para treinamentos posteriores que possam ajudar na indicação de periculosidade de objetos.

3.3.5 RNF05 - Modelagem e Construção da Maquete

Requisito: A maquete deve permitir ajustes e otimizações, garantindo um melhor posicionamento da câmera e componentes.

Prioridade: Alta.

Critério de Aceite: Deve ser possível alterar a posição da câmera e dos componentes.

3.4 Arquitetura e Custos

Para o desenvolvimento da parte física do projeto, planejou-se inicialmente a descrição arquitetural de uma maquete composta por uma esteira rolante, um sistema de separação mecânico automatizado e uma câmera acoplada. O objetivo dessa construção foi criar um ambiente controlado para experimentação e validação do produto criado, em escala reduzida, permitindo avaliar o funcionamento integrado dos componentes.

O sistema é orquestrado por um controlador, responsável por acionar e interromper o movimento da esteira, bem como acionar o separador mecânico para direcionar o resíduo ao compartimento adequado, de acordo com as informações fornecidas pelo modelo de visão computacional.

A configuração inicial de base da esteira foi elaborada no *software SketchUp*, de *design* 3D, possibilitando ajustes de posicionamento e proporção antes da montagem física. A escolha dos materiais utilizados seguiu critérios de disponibilidade e viabilidade técnica, priorizando baixo custo e facilidade de montagem. A Figura 6 apresenta um esboço final da maquete.




Figura 6 – Esboço de Maquete

Fonte: Autoria própria

Ademais, a partir dessas ideias e dos requisitos expostos, foi possível especificar a arquitetura de hardware, conforme exposto na Figura 7. Neste contexto, optamos por utilizar para este trabalho um notebook como processador principal, sendo responsável pela execução do modelo de detecção em tempo real. A ESP32 foi definida como dispositivo intermediário, responsável por receber os comandos enviados pelo notebook e controlar os periféricos do sistema.

A Tabela 1 apresenta os componentes que consideramos para a arquitetura, e seus respectivos valores. Com esta decisão de componentes em mente, o custo de itens relacionados ao hardware totalizou R\$ 164,80, considerando o uso de quatro motores e uma cancela. O custo total do projeto, por sua vez, envolve o desenvolvimento da maquete. Para a produção, foram utilizadas duas chapas de MDF de 90×60 cm, com 6 mm de espessura, além de cantoneiras para sustentação. Os kits adquiridos custaram, respectivamente, R\$ 52,70 e R\$ 41,12, totalizando um valor final de R\$ 258,62.

Componente	Unidades	Preço [R\$]	Loja e Data de Acesso
ESP32	1	48,40	RoboCore. Acesso em 28/08/2025
Servo TowerPro MG996R	1	55,00	RoboCore. Acesso em 13/04/2025
Motor DC 3-6V	4	7,90	RoboCore. Acesso em 13/04/2025
Módulo Driver Ponte H - L298N	2	14,90	RoboCore. Acesso em 13/04/2025

Tabela 1 – Componentes da arquitetura e seus respectivos valores

Fonte: Autoria própria




Figura 7 – Diagrama de Arquitetura de Hardware

Fonte: Autoria própria

3.5 Modelo para Detecção dos Resíduos

O modelo de visão computacional processa as imagens capturadas pela câmera e envia as classificações ao controlador, que aciona os atuadores correspondentes. Nesse contexto, foram realizados testes para determinar a melhor posição da câmera, levando em conta parâmetros como ângulo de captura e iluminação, conforme a Tabela 2.

Sigla	Posição de Câmera	Iluminação
0CF	0°	com flash
0SF	0°	sem flash
45CF	45°	com flash
45SF	45°	sem flash

Tabela 2 – Configuração de cenários de teste

Fonte: Autoria própria

Os testes foram guiados por uma bateria de experimentos pré definida, que avaliou o desempenho do sistema em condições variadas, com diferentes tipos de resíduos e cenários operacionais. A viabilidade do projeto foi garantida pelo cumprimento dos requisitos e respectivos critérios de aceitação, como, por exemplo, taxa mínima de acerto durante

a classificação e tempo máximo de resposta. A partir dos resultados, foram realizados ajustes na calibração dos atuadores, para otimizar a eficiência e a precisão do processo de separação dos materiais.

Para detectar os resíduos de interesse, e identificar seus respectivos materiais, utilizamos modelos YOLO pré-treinados com a base de dados TACO. Esse *dataset* contém 64 subgrupos específicos de resíduos (SIMões PEDRO E PROENÇA, 2020b), que podem ser associados à 4 grandes grupos: plástico, vidro, metal ou papel.

Foram avaliadas três versões do YOLOv8: *nano* (n), *small* (s) e *medium* (m) (RICO, 2025). Embora compartilhem a mesma arquitetura, esses modelos diferem na profundidade e largura de cada uma das camadas que compõem a arquitetura, afetando diretamente a acurácia e o custo computacional necessário. Em geral, o modelo YOLOv8n é mais simples, apresentando um menor tempo de inferência, porém com uma redução de mAP quando comparado às versões maiores.

A Figura 8 apresenta as primeiras detecções realizadas com o modelo YOLOv8s e fotos de resíduos.




Figura 8 – Resultado de classificações com YOLOv8s e TACO sobre fotos de resíduos

Fonte: Autoria própria

4 Desenvolvimento do Trabalho

4.1 Tecnologias Utilizadas

Para o desenvolvimento do sistema de triagem automática na esteira, utilizou-se um conjunto de tecnologias descritas abaixo.

4.1.1 Modelo e Conjuntos de Dados

- **Python 3.11**: linguagem principal para orquestração do código.
- **Ultralytics YOLOv8 (n, s, m)**: modelos de detecção de objetos disponibilizados pela ([Ultralytics, 2024a](#)), utilizados para identificação e classificação de materiais recicláveis (papel/papelão, plástico, metal e vidro).
- **Anotador Roboflow**: ferramenta auxiliar para formatação e rotulação imagens YOLO, usadas nos testes de performance de modelos ([ROBOFLOW, 2025](#)).

4.1.2 Software

- **React 18 + TypeScript + Vite**: base da aplicação de dashboard e roteamento de painéis.
- **Tailwind CSS + shadcn/ui**: sistema de estilização e componentes de UI reutilizáveis para o layout responsivo.
- **WebSocket**: canal em tempo real para receber frames, detecções e enviar comandos para o backend/ESP32.
- **Ícones lucide-react**: feedback visual para controles, status e botões de ação.

4.1.3 Hardware

- **ESP32**: controle dos atuadores e comunicação com o *middleware*.
- **Motor DC**: movimentação física do chão da esteira.
- **Ponte H**: controla o acionamento do motor da esteira.
- **Servomotores**: movimentação das cancelas.

4.1.4 Dispositivos Externos

- **Câmera USB:** para envio das imagens para o sistema.
- **Notebook:** para executar o modelo treinado durante as classificações em tempo real.

4.1.5 Ferramentas de Desenvolvimento e Versionamento

- VS Code, Git/GitHub, venv/pip, PowerShell.
- Windows 10: sistema operacional utilizado durante as execuções.

4.2 Projeto e Implementação

4.2.1 Base de Dados e Modelo

Para as avaliações de desempenho, elaboramos uma base de dados composta por imagens de resíduos diversos sobre o chão da esteira, domínio do projeto, sendo eles distribuídos entre as quatro categorias principais previamente definidas (metal, papel, plástico e vidro). Todo o processo de anotação foi feito utilizando a plataforma Roboflow ([ROBOFLOW, 2025](#)), que permite criar e associar os rótulos as imagens e exportar o *dataset* em diversos formatos, de acordo com o modelo usado para treinamento.




Figura 9 – Processo de anotação da nova base de dados

Fonte: Autoria própria

As imagens foram capturadas em diferentes condições de iluminação (com ou sem flash) e distintas angulações da câmera (sem inclinação e com 45° em relação à base da esteira), como explicado na Tabela 2. A Figura 10 ilustra o trabalho realizado de captação de imagens.

A adoção dessas variações na aquisição das imagens justifica-se como uma forma de simulação de condições reais, ou seja, que podem ocorrer em um ambiente produtivo. Fatores como o grau de iluminação no chão de fábrica ou a presença de reflexos ocasionados por equipamentos externos à esteira transportadora podem impactar diretamente a confiabilidade das detecções em tempo real, uma vez que redes neurais convolucionais demonstram instabilidades significativas quando submetidas a diferentes condições de iluminação (SIVARAMAN; MURTHY, 2018).

Dessa forma, foi possível realizar benchmarks entre as versões do modelo YOLO, permitindo uma análise comparativa quanto à precisão dos modelos sob diferentes condições de captura de imagens.




Figura 10 – Amostra da base de teste.

Fonte: Autoria própria

Após comparar as versões de modelos disponíveis, escolhemos o melhor candidato para a fase de ajuste fino do modelo, utilizando a base coletada especificamente para este projeto, a fim de especializá-lo no domínio dos resíduos encontrados na esteira. O *fine-tuning*, explicado na Seção 2.5, teve como finalidade aprimorar a habilidade do modelo

em identificar objetos diante de variações na iluminação, ângulo da câmera e diferentes características dos resíduos, ajustando os pesos previamente treinados no TACO para o novo conjunto de dados coletado em ambiente controlado.

4.2.2 Módulo de Software

A arquitetura de software atual do EcoVision é compacta e concentrada no backend Python, conforme ilustra a Figura 11, que manda informações diretamente ao hardware. A webcam envia frames via USB para o backend, que executa a pipeline de visão baseada em YOLOv8. O módulo *YOLOPipeline* captura, faz a inferência, converte os resultados (classe, confiança e *bounding boxes*) e encaminha comandos ao *SerialController*, responsável por acionar o ESP32 pela porta serial para mover o servo e ligar ou desligar o motor. O estado operacional do sistema (motor ligado, fila de detecções, FPS e clientes conectados) é mantido pela classe *SystemState* e distribuído aos consumidores.

O frontend, presente na Figura 12, em React comunica-se com o backend por meio de *WebSocket* para receber frames anotados e enviar comandos de controle, como iniciar ou parar o processamento e ajustar o ângulo do servo, mais detalhados na Seção 4.3.2. O versionamento permanece no GitHub, e o fluxo de execução é local e direto, entretanto durante o desenvolvimento do projeto, integrações com Supabase, PostgreSQL ou autenticação Google OAuth foram estudadas e demonstraram-se promissoras para evoluções futuras que podem compor um sistema em nuvem.




Figura 11 – Diagrama de Classes do projeto EcoVision

Fonte: Autoria própria





Figura 12 – Diagrama com Componentes do Frontend

Fonte: Autoria própria

4.2.3 Descrição de Hardware

O hardware do sistema é composto por uma placa microcontroladora ESP32, um servo motor, uma ponte H e quatro motores de corrente contínua (DC).

Figura 13 – Descrição detalhada do *hardware* do sistema

Fonte: Autoria própria

A ESP32 é a unidade controladora do sistema, sendo responsável por enviar sinais PWM, através de sua GPIO, para acionamento do servo motor, que realiza a separação dos materiais de acordo com a classificação feita pelo modelo. Além disso, a ESP32, através de um módulo driver Ponte H, controla os motores de corrente contínua (DC), possibilitando o controle da velocidade da esteira transportadora.

O funcionamento do sistema pode ser descrito da seguinte forma:

- O modelo é executado em um *notebook*, responsável pela detecção e classificação dos objetos.
- Quando um dos materiais definidos é detectado, o tipo de material detectado pelo modelo é transmitido para a ESP32.
- A ESP32 gera o sinal PWM para controlar o servo motor no ângulo associado ao material detectado.
- A ESP32 também envia sinais para a ponte H, regulando a velocidade do motor DC da esteira transportadora.

4.3 Resultados e Avaliação

Os testes foram conduzidos em cinco níveis: modelo, software, hardware, sistema completo e validação geral.

4.3.1 Modelo

Para melhor entendimento de performance das três opções disponíveis de modelos, pré-treinados com TACO, foi calculada a precisão média (Tabela 3), em diferentes cenários de iluminação, com *flash* (CF) e sem *flash* (SF), e de angulação da câmera, 0° e 45°. Essa métrica mostra a proporção entre predições corretas em relação ao total. A partir dos valores de precisão média, foi possível avaliar o quanto o modelo evita falsos positivos, o que é importante para gerar acionamentos corretos das cancelas durante o funcionamento da esteira.

Modelo	0CF	0SF	45CF	45SF
YOLOv8s	65,19	75,52	59,32	76,98
YOLOv8n	30,00	67,63	46,63	40,23
YOLOv8m	45,53	66,29	46,62	52,97

Tabela 3 – Precisão Média (%) por cenário

Fonte: Autoria própria

Esses resultados evidenciaram que, mesmo com as variações de cenários de angulação e iluminação, o YOLOv8s manteve um desempenho coerente e estável, com robustez superior aos seus concorrentes. Assim, alcançou-se uma melhor relação entre acurácia e viabilidade de operação para o protótipo desenvolvido.

Além do *benchmark* inicial entre os modelos pré-treinados, foi realizado o *fine-tuning* do YOLOv8s com as imagens adquiridas na esteira. Durante o treinamento, as métricas apresentaram evolução consistente, conforme ilustrado nos gráficos da Figura 14. Os valores de perda de caixa (*box_loss*), de classificação (*cls_loss*) e de *distribution focal loss* (*dfl_loss*) diminuíram de forma contínua ao longo das épocas, indicando que o modelo conseguiu adaptar-se às características particulares dos resíduos processados pelo sistema. Observa-se essa redução tanto nos gráficos de *train loss* quanto nos de *validation loss*, que convergem de maneira estável após aproximadamente 80 a 100 épocas.




Figura 14 – Evolução das perdas durante o processo de *fine-tuning* do modelo YOLOv8s.

As curvas superiores representam as perdas de treino (*train/box_loss*, *train/cls_loss* e *train/dfl_loss*), enquanto as curvas inferiores mostram as respectivas perdas no conjunto de validação (*val/box_loss*, *val/cls_loss* e *val/dfl_loss*).

Fonte: Autoria própria

O conjunto de validação apresentou comportamento semelhante: o *val/box_loss* reduziu de cerca de 1.25 nas primeiras épocas para aproximadamente 1.0 ao final do treinamento, enquanto o *val/cls_loss* caiu de aproximadamente 4.5 para valores em torno de 1.4, evidenciando maior capacidade discriminativa entre as classes. Essas curvas sugerem que o modelo conseguiu se especializar sem apresentar sinais de *overfitting*, uma vez que as perdas de validação acompanharam de perto a tendência observada no conjunto de

treinamento.

No que diz respeito às métricas de desempenho, presentes na Figura 15, o gráfico de precisão ($precision(B)$) revela um crescimento rápido nas primeiras épocas, seguido por estabilização em torno de 0.75, indicando que o modelo aprendeu a classificar corretamente a maior parte dos resíduos, com baixa ocorrência de falsos positivos.




Figura 15 – Desempenho do modelo YOLOv8s durante o *fine-tuning*, mostrando a evolução da precisão e da métrica mAP@50.

Fonte: Autoria própria

Ao comparar com os resultados obtidos a partir dos modelos apenas pré-treinados, a métrica mAP50 apresentou a evolução mais significativa. Iniciando-se em torno de 0.40 nas primeiras iterações, atingiu valores próximos de 0.80 nas épocas finais, demonstrando que o modelo conseguiu ajustar adequadamente tanto a localização quanto os limites das *bounding boxes*. Por fim, é válido ressaltar que, devido ao volume reduzido de imagens em cada um dos subgrupos apresentados na Tabela 2, o processo de refinamento foi feito com o conjunto completo, sem distinção dos cenários. Logo, o *fine-tuning* foi aplicado com o objetivo de melhora na performance geral do modelo YOLOv8s, independente das divisões estudadas anteriormente.

4.3.2 Módulo de Software

Embora seja possível executar o modelo através de linhas de comando, optamos por fazer uma interface *user-friendly* para controle e monitoramento em tempo real do sistema. A seguir, são apresentadas algumas telas do sistema EcoVision. As telas foram planejadas pensando em uma boa experiência do usuário, com explicações distribuídas pelo site sobre o objetivo de cada página e organização coesa de seus componentes, para uma navegação mais intuitiva. Na Figura 16, temos a página inicial do projeto, nela o usuário pode realizar a autenticação em Modo Demo. No momento atual, o botão de

autenticação com o Google está somente como recurso visual, já pensando em potenciais melhorias para o futuro do projeto.



Figura 16 – Tela de login

Fonte: Autoria própria




Figura 17 – Tela principal de monitoração

Fonte: Autoria própria

Após esse primeiro contato, o sistema é aberto na tela de monitoramento, apresentada na Figura 17, onde é possível não somente enxergar os objetos sendo detectados e classificados de acordo com as respostas do modelo, mas também enviar os sinais de liga e desliga para a esteira física. Junto disso, é possível acompanhar o *status* dos principais componentes diretamente dessa página central.

Em seguida, temos a tela de separação, mostrada na Figura 18, em que é possível realizar as configurações de angulação do servo motor que assumiu o papel de atuador neste projeto. Cada posição faz com que a cancela empurre o objeto para uma direção específica, logo os ângulos passados são associados a cada um dos quatro tipos de materiais trabalhados (papel, plástico, vidro e metal). Os botões de teste servem para mandar o sinal serial diretamente para o controlador, sem precisar da detecção, facilitando o processo de calibração inicial do dispositivo, com relação ao posicionamento da cancela. Além disso, o controle manual possibilita avaliar como a qualidade da detecção influencia a eficácia do sistema como um todo.




Figura 18 – Tela de configuração de separação

Fonte: Autoria própria

Por fim, temos uma tela de configurações gerais sobre modelo, saída serial, para comunicação com a ESP32, e o índice da câmera conectada ao computador, que realiza a captação das imagens a serem analisadas pelo algoritmo de visão computacional. Após

todas essas configurações serem salvas, o sistema deve ser reiniciado para que elas passem a ser utilizadas. Esses pontos ficam claros na Figura 19.




Figura 19 – Tela de configuração de modelo, saída serial e câmera

Fonte: Autoria própria

4.3.3 Sistema Completo

O sistema pode ser executado em qualquer computador que seja compatível com Python 3.8+ (ULTRALYTICS, 2025), que tenha NodeJS 16+ instalado e também o Arduino IDE 2.0+ ou PlatformIO disponível. Na Figura 20 temos a configuração final da esteira, já recebendo os sinais do controlador conectado serialmente ao *notebook*, que rodará as detecções e classificações.



Figura 20 – Esteira finalizada.

Fonte: Autoria própria

O sistema completo é apresentado na Figura 21 classificando respectivamente metal, plástico e papel. Ele é composto pela esteira transportadora, o mecanismo de separação automatizado, a câmera de captura de imagens e o controlador ESP32, responsável pela comunicação entre o modelo de visão computacional e os atuadores. O modelo YOLO realiza a detecção e classificação dos resíduos em tempo real, transmitindo a classe detectada ao microcontrolador, que posiciona o servo motor no ângulo correspondente para direcionar cada material ao compartimento adequado. Além disso, a posição da câmera pode ser ajustada por meio de um tripé, permitindo posicioná-la no melhor ângulo de detecção possível para o cenário de operação.




Figura 21 – Projeto em funcionamento para diferentes tipos de materiais.

Fonte: Autoria própria

5 Conclusões e Considerações Finais

O EcoVision, uma esteira de reciclagem automatizada, demonstrou a viabilidade técnica de integrar um modelo de visão computacional a um sistema físico para triagem de resíduos. A construção do sistema, composto por uma esteira transportadora, câmera, ESP32, servo motor e motores DC, permitiu avaliar, em um ambiente controlado e de menor escala, o comportamento do sistema e a integração entre os componentes de hardware e software. Os diversos testes realizados evidenciaram que o projeto atingiu o objetivo de validar a possibilidade de automatizar o processo de triagem e separação de resíduos em esteiras de reciclagem.

Do ponto de vista do modelo, os testes realizados mostraram que o YOLOv8s, pré-treinado com TACO, um *dataset* especializado em resíduos sólidos, apresentou o melhor desempenho em variadas condições de iluminação e ângulos de captura quando comparado aos modelos *nano* e *medium*. Quanto à integração física, isto é, o protótipo completo, observou-se que as diversas partes do sistema comportaram-se como esperado, com a detecção, envio de comandos e acionamento dos atuadores funcionando corretamente.

Apesar dos resultados promissores, algumas limitações ficaram evidentes, dentre elas, destacamos as seguintes:

- **Imprecisão na detecção:** devido ao baixo número de imagens presentes no *dataset*, o modelo apresentou dificuldades em identificar o mesmo resíduo sob diferentes tipos de iluminação e ângulos de captura. Isso resultou em classificações incorretas em cenários específicos, ocasionando acionamentos indevidos do separador mecânico e impactando a eficácia da triagem automática dos materiais, problema que não ocorre quando o separador é acionado manualmente.
- **Separação descompassada:** devido à latência da comunicação entre o modelo, a ESP32 e o servo motor, observamos que, nos casos em que a detecção ocorre com atraso, isto é, quando o objeto se encontra em uma posição mais avançada na esteira, o servo não alcança o ângulo adequado a tempo, resultando em separações incorretas do material.
- **Múltiplas detecções:** em alguns instantes durante a captura das imagens, o modelo gera mais de uma detecção para o mesmo resíduo, enviando diversos comandos ao servo motor. Isso provoca acionamentos indevidos, mesmo quando já não há materiais na esteira. Outro fator nessa direção ocorre quando o campo de visão da câmera abrange uma área muito grande, aumentando a probabilidade de duplicidade nas detecções.

Mesmo com as limitações acima, o sistema mostrou-se bastante promissor, evidenciando o potencial da abordagem proposta para automatizar etapas da triagem de resíduos. Os resultados obtidos sugerem que o sistema pode ser aprimorado em trabalhos futuros.

Uma das principais melhorias que pode ser explorada em trabalhos futuros é o aumento do conjunto de dados, incorporando novas imagens de resíduos em diferentes angulações, iluminações e condições físicas dos resíduos, isto é, amassados, sujos, degradados, etc. Esse enriquecimento do *dataset* permitiria que o modelo detectasse com maior precisão os materiais em cenários reais de produção industrial.

Outro ponto de evolução é o aperfeiçoamento da estrutura física da esteira, com a adição de um controle aperfeiçoado da velocidade da esteira e a adição de melhores separadores mecânicos. Entre as possibilidades, destaca-se a substituição da cancela por um braço mecânico, capaz de realizar movimentos mais rápidos e precisos. Ressaltamos que o projeto custou R\$258,62, demonstrando que a solução pode ser construída com baixo custo, contudo, um investimento maior possibilitaria a adoção de componentes mais precisos e a incorporação de funcionalidades avançadas.

Por fim, é necessário realizar testes mais robustos da esteira, com maior vazão de materiais e em condições mais realistas, como situações em que os resíduos aparecem parcialmente cobertos, sobrepostos ou em posições irregulares. Esses experimentos permitirão verificar a resiliência do sistema e identificar ajustes adicionais para melhorar sua precisão e confiabilidade operacional.

Referências

- ABREMA. *Reciclagem chega a 8% no país com trabalho informal*. 2024. Disponível em: <<https://www.abrema.org.br/2024/12/12/reciclagem-de-residuos-chega-a-8-no-pais-com-trabalho-informal-aponta-estudo/>>. Citado na página 13.
- BRITTO, V. *MUNIC 2023: 31,9% dos municípios brasileiros ainda despejam resíduos sólidos em lixões*. 2024. Disponível em: <<https://agenciadenoticias.ibge.gov.br/agencia-noticias/2012-agencia-de-noticias/noticias/41994-munic-2023-31-9-dos-municipios-brasileiros-ainda-despejam-residuos-solidos-em-lixoes>>. Citado na página 13.
- CAO, J. et al. From handcrafted to deep features for pedestrian detection: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 44, n. 9, p. 4913–4934, 2022. Citado na página 19.
- CETINIC, E.; GRGIC, S.; GRGIC, M. Fine-tuning convolutional neural networks for fine art classification. *Expert Systems with Applications*, Elsevier, v. 114, p. 107–118, 2018. Disponível em: <https://www.vcl.fer.hr/papers_pdf/Fine-tuning%20Convolutional%20Neural%20Networks%20for%20fine%20art%20classification.pdf>. Citado na página 22.
- CONKE, L. S. Barriers to waste recycling development: Evidence from brazil. *Resources, Conservation and Recycling*, v. 134, p. 129–135, 2018. ISSN 0921-3449. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0921344918301009>>. Citado na página 13.
- CORREIA, A. J. L. *Figura fornecida pelo autor*. 2025. Arquivo de imagem enviado pelo autor. Comunicação pessoal. Citado na página 18.
- DU, J. Understanding of object detection based on cnn family and yolo. *Journal of Physics: Conference Series*, IOP Publishing, v. 1004, n. 1, p. 012029, apr 2018. Disponível em: <<https://dx.doi.org/10.1088/1742-6596/1004/1/012029>>. Citado na página 20.
- EVREKA. *AI-Powered Waste Sorting: The Future of Recycling Efficiency*. 2025. Relatório técnico sobre limitações da triagem manual e ganhos de eficiência com IA. Disponível em: <<https://evreka.co/blog/ai-powered-waste-sorting-the-future-of-recycling-efficiency/>>. Citado na página 14.
- IBM. *What are convolutional neural networks?* 2025. Disponível em: <<https://www.ibm.com/think/topics/convolutional-neural-networks>>. Citado na página 17.
- JOIYA, F. International research journal of modernization in engineering technology and science. *CoRR*, Volume:04, 2022. Disponível em: <https://www.irjmets.com/uploadedfiles/paper/issue_9_september_2022/30226/final/fin_irjmets1664212182.pdf>. Citado na página 18.
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, Curran Associates Inc., v. 25, 2012. Citado na página 13.

KUMAR, P.; KUMAR, V. Exploring the frontier of object detection: A deep dive into yolov8 and the coco dataset. In: *2023 IEEE International Conference on Computer Vision and Machine Intelligence (CVMI)*. [S.l.: s.n.], 2023. p. 1–6. Citado na página 21.

LIN, T.-Y. et al. Microsoft coco: Common objects in context. In: FLEET, D. et al. (Ed.). *Computer Vision – ECCV 2014*. Springer, 2014. (Lecture Notes in Computer Science, v. 8693), p. 740–755. Disponível em: <https://people.cs.uchicago.edu/~mmaire/papers/pdf/coco_eccv2014.pdf>. Citado na página 20.

MASLEJ et al. *AI Index Report 2025*. Stanford, CA, 2025. Disponível em: <https://hai.stanford.edu/assets/files/hai_ai_index_report_2025.pdf>. Citado 2 vezes nas páginas 13 e 14.

PAN, S. J.; YANG, Q. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, IEEE, v. 22, n. 10, p. 1345–1359, 2010. Disponível em: <https://www.cse.ust.hk/~qyang/Docs/2009/tkde_transfer_learning.pdf>. Citado na página 22.

PICVISA. *Revolutionizing Recycling: The Evolution of Sorting with Machine Vision*. 2024. Relatório técnico sobre eficiência e automação em triagem de resíduos. Disponível em: <<https://picvisa.com/revolutionizing-recycling-the-evolution-of-sorting-with-machine-vision/>>. Citado na página 14.

PROENÇA, P. F.; SIMÕES, P. Taco: Trash annotations in context for litter detection. *arXiv preprint arXiv:2003.06975*, 2020. Citado na página 21.

REDMON, J. et al. You only look once: Unified, real-time object detection. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. [S.l.: s.n.], 2016. Citado 2 vezes nas páginas 19 e 20.

RICO, J. *Litter Detection – YOLOv5 Training Runs*. 2025. <<https://github.com/jeremy-rico/litter-detection/tree/master/runs/detect/train>>. Acesso em: 23 nov. 2025. Citado na página 31.

ROBOFLOW. 2025. <<https://roboflow.com/>>. Acesso em: 06 dez. 2025. Citado 2 vezes nas páginas 33 e 34.

SIMÕES PEDRO E PROENÇA, P. *TACO Dataset Statistics*. 2020. TACO Dataset – Trash Annotations in Context: Dataset Statistics. Disponível em: <<http://tacodataset.org/stats>>. Citado na página 21.

SIMÕES PEDRO E PROENÇA, P. *TACO Dataset Taxonomy*. 2020. Taxonomia oficial do conjunto de dados TACO. Disponível em: <<http://tacodataset.org/taxonomy>>. Citado na página 31.

SIVARAMAN, K.; MURTHY, A. Object recognition under lighting variations using pre-trained networks. In: *2018 IEEE Applied Imagery Pattern Recognition Workshop (AIPR)*. [S.l.: s.n.], 2018. p. 1–7. Citado na página 35.

Ultralytics. *Models*. 2024. Disponível em: <<https://docs.ultralytics.com/pt/models/>>. Citado na página 33.

Ultralytics. *Ultralytics YOLOv8 – Loss Functions*. 2024. <<https://docs.ultralytics.com/reference/utils/loss/>>. Acesso em: 23 nov. 2025. Inclui a definição: “Calculate the sum of the loss for box, cls and dfl multiplied by batch size.”. Citado na página 23.

ULTRALYTICS. *FAQ – How do I install the Ultralytics package?* 2025. Acesso em: 30 nov. 2025. Disponível em: <<https://docs.ultralytics.com/pt/help/FAQ/#how-do-i-install-the-ultralytics-package>>. Citado na página 43.

YANG, X. et al. Detection of river floating garbage based on improved yolov5. *Mathematics*, v. 10, n. 22, 2022. ISSN 2227-7390. Disponível em: <<https://www.mdpi.com/2227-7390/10/22/4366>>. Citado na página 19.

ZHAO, Y. Enhancing object detection with yolov8 transfer learning: A voc2012 dataset study. In: *Proceedings of the International Conference on Engineering Management, Information Technology and Intelligence*. SCITEPRESS, 2024. Acesso em: 2025-05-12. Disponível em: <<https://www.scitepress.org/Papers/2024/129396/129396.pdf>>. Citado na página 22.

ZHUANG, F. et al. A comprehensive survey on transfer learning. *Proceedings of the IEEE*, IEEE, v. 109, n. 1, p. 43–76, 2021. Disponível em: <<https://arxiv.org/pdf/1911.02685.pdf>>. Citado na página 22.

ZOU, Z. et al. Object detection in 20 years: A survey. *CoRR*, abs/1905.05055, 2019. Disponível em: <<http://arxiv.org/abs/1905.05055>>. Citado na página 18.